

MATA KULIAH DATA SCIENCE

PERTEMUAN 4

Pembelajaran Tak Terawasi (Unsupervised Learning) dan Probabilitas

Sub-CPMK 4

D4 Teknologi Rekayasa Perangkat Lunak - Politeknik Negeri Madiun

Tujuan Pembelajaran

SUB-CPMK 4

1

Mahasiswa memahami prinsip clustering dan dasar probabilitas

Peta Materi Pertemuan (1/2)

1 **Pengenalan Unsupervised Learning**

2 **Tinjauan Ulang Konsep Dasar Probabilitas**

3 **Algoritma K-Means**

4 **Algoritma Lloyd dan Menentukan Jumlah Cluster**

5 **Ketidakpastian dan Kebutuhan akan Probabilitas**

6 **Distribusi Probabilitas Gabungan (Joint Distribution)**

7 **Estimasi Kepadatan dan Maximum Likelihood Estimation (MLE)**

8 **Bias Estimator dan Distribusi Gaussian Multivariat**

Peta Materi Pertemuan (2/2)

9 Model Campuran Gaussian (Gaussian Mixture Model)

10 Algoritma Expectation-Maximization (EM) untuk GMM

11 Dalil Bayes (Bayes' Theorem)

12 Studi Kasus: Wake Word Detector

Pengenalan Unsupervised Learning

Berbeda dengan supervised learning yang menggunakan data berlabel, unsupervised learning bekerja pada data tanpa label untuk menemukan struktur atau pola tersembunyi, misalnya pengelompokan (clustering).

- Tidak memerlukan label target (y) pada data latih
- Tujuan umum: menemukan struktur, kelompok, atau pola tersembunyi dalam data
- Contoh aplikasi: segmentasi pelanggan, deteksi anomali, kompresi data

Tinjauan Ulang Konsep Dasar Probabilitas

Probabilitas menjadi fondasi banyak algoritma unsupervised, termasuk clustering berbasis model. Pemahaman ulang konsep dasar probabilitas diperlukan sebelum masuk ke algoritma seperti Gaussian Mixture Model.

- Probabilitas sebagai ukuran ketidakpastian suatu kejadian
- Distribusi probabilitas: cara mendeskripsikan sebaran nilai suatu variabel acak
- Distribusi Gaussian (normal) sebagai distribusi yang paling umum digunakan dalam ML

Algoritma K-Means

K-Means adalah algoritma clustering yang membagi data ke dalam K kelompok berdasarkan kedekatan jarak ke titik pusat (centroid) masing-masing kelompok. Algoritma ini bekerja secara iteratif.

- Tentukan jumlah kelompok K di awal
- Iterasi: assign setiap titik data ke centroid terdekat, lalu perbarui posisi centroid
- Proses berulang hingga posisi centroid tidak lagi berubah signifikan
- Kelemahan: sensitif terhadap inisialisasi centroid dan bentuk kelompok yang tidak bulat

MATERI 4

Algoritma Lloyd dan Menentukan Jumlah Cluster

Algoritma Lloyd adalah prosedur klasik di balik K-Means: langkah assignment dan update dilakukan berulang hingga konvergen. Karena jumlah cluster K harus ditentukan di awal, diperlukan cara sistematis untuk memilih nilai K yang tepat.

- Langkah 1 (Assignment): setiap titik data ditetapkan ke centroid terdekat
- Langkah 2 (Update): posisi tiap centroid diperbarui menjadi rata-rata (mean) seluruh titik pada clusternya - inilah sebabnya disebut 'K-Means'
- Lloyd's Algorithm dijamin konvergen (nilai objektif tidak pernah naik), tetapi tidak dijamin mencapai hasil yang optimal secara global
- Metode Elbow: menjalankan K-Means untuk beberapa nilai K , lalu memilih titik 'siku' pada grafik error vs K sebagai jumlah cluster yang wajar
- Interpretasi hasil cluster perlu hati-hati - cluster belum tentu merepresentasikan kategori yang bermakna secara langsung

Ketidakpastian dan Kebutuhan akan Probabilitas

K-Means memberikan penugasan cluster yang 'keras' (hard assignment) - setiap titik pasti masuk ke satu cluster. Padahal dalam praktiknya, prediksi model selalu mengandung ketidakpastian yang perlu dikuantifikasi.

- Epistemic Uncertainty (dapat direduksi): ketidakpastian akibat data latih yang terbatas dan proses pemodelan
- Aleatoric Uncertainty (tidak dapat direduksi): ketidakpastian akibat noise pada proses observasi/pengukuran data itu sendiri
- Probabilitas adalah kerangka kerja (framework) untuk mengukur dan memanipulasi ketidakpastian secara matematis
- Kebutuhan ini yang mendorong pengembangan model probabilistik seperti Gaussian Mixture Model

MATERI 6

Distribusi Probabilitas Gabungan (Joint Distribution)

Distribusi probabilitas gabungan menggambarkan probabilitas dari kombinasi beberapa variabel acak sekaligus, dan menjadi dasar berbagai aturan probabilitas yang penting dalam ML.

- Sum Rule (Marginalization): menjumlahkan probabilitas gabungan pada salah satu variabel untuk mendapatkan distribusi marginal variabel lainnya
- Conditional Probability: probabilitas suatu kejadian dengan syarat kejadian lain sudah diketahui, $P(A|B) = P(A,B) / P(B)$
- Product Rule: $P(A,B) = P(A|B) \times P(B)$, menghubungkan probabilitas gabungan dengan probabilitas bersyarat
- Independent Random Variables: dua variabel disebut independen jika $P(A,B) = P(A) \times P(B)$

Estimasi Kepadatan dan Maximum Likelihood Estimation (MLE)

Density estimation adalah proses menduga parameter suatu distribusi probabilitas dari data yang teramati. Maximum Likelihood Estimation (MLE) adalah metode paling umum untuk melakukan estimasi ini.

- Likelihood function: mengukur seberapa 'mungkin' suatu himpunan data teramati, jika data bersifat independen dan identically distributed (IID)
- Log-likelihood digunakan sebagai pengganti likelihood agar perhitungan matematis lebih sederhana (perkalian menjadi penjumlahan)
- MLE mencari parameter yang memaksimalkan (log-)likelihood tersebut
- Contoh penerapan: MLE untuk distribusi Bernoulli (data biner) dan distribusi Gaussian (data kontinu)
- Konsep MLE ini bahkan mendasari cara model bahasa besar (seperti ChatGPT) dilatih untuk memprediksi token berikutnya

Bias Estimator dan Distribusi Gaussian Multivariat

Selain akurat, estimator parameter yang baik idealnya juga tidak bias secara sistematis. Untuk data multi-dimensi, distribusi Gaussian diperluas menjadi bentuk multivariat.

- Bias suatu estimator: selisih antara nilai ekspektasi estimator dengan nilai parameter sebenarnya
- Estimator rata-rata (sample mean) pada distribusi Gaussian bersifat tidak bias (unbiased)
- Estimator variansi MLE standar justru bersifat bias - diperlukan koreksi (pembagi $n-1$, bukan n) untuk mendapatkan estimator variansi yang tidak bias
- Distribusi Gaussian Multivariat memperluas distribusi normal ke banyak dimensi, dicirikan oleh vektor mean dan matriks kovarians

Model Campuran Gaussian (Gaussian Mixture Model)

GMM adalah pendekatan clustering berbasis probabilitas yang mengasumsikan data berasal dari campuran beberapa distribusi Gaussian. Berbeda dengan K-Means yang bersifat 'hard assignment', GMM memberikan probabilitas keanggotaan (soft assignment).

- Setiap kelompok direpresentasikan sebagai satu distribusi Gaussian dengan mean dan varians tersendiri
- Titik data punya probabilitas keanggotaan ke setiap kelompok (soft assignment), bukan keanggotaan tunggal seperti K-Means
- GMM adalah model variabel laten (latent variable model): identitas cluster suatu titik data adalah variabel tersembunyi yang tidak teramati langsung
- GMM juga merupakan model generatif - dapat digunakan untuk membangkitkan (sampling) data baru yang mirip data asli

Algoritma Expectation-Maximization (EM) untuk GMM

GMM adalah model variabel laten (latent variable model) dan sekaligus model generatif. Parameter GMM diestimasi menggunakan algoritma Expectation-Maximization (EM) karena ada ketergantungan siklis antara parameter model dan penugasan cluster.

- Masalah siklis: jika parameter model diketahui, penugasan cluster mudah dihitung; sebaliknya jika penugasan cluster diketahui, parameter model mudah diestimasi
- E-step (Expectation): menghitung probabilitas keanggotaan (posterior) tiap titik data ke setiap komponen Gaussian, dengan parameter model saat ini
- M-step (Maximization): memperbarui parameter model (mean, kovarians, bobot campuran) berdasarkan probabilitas keanggotaan dari E-step
- Kedua langkah diulang secara bergantian hingga konvergen

Dalil Bayes (Bayes' Theorem)

Dalil Bayes adalah salah satu konsep probabilitas paling penting dalam machine learning, menjelaskan bagaimana memperbarui keyakinan (belief) berdasarkan bukti/data baru.

- Rumus Dalil Bayes: $P(A|B) = P(B|A) \times P(A) / P(B)$
- Hukum probabilitas total (law of total probability) digunakan untuk menghitung $P(B)$ sebagai penyebut
- Konsep ini menjadi dasar pandangan probabilistik pada model ML, termasuk interpretasi 'prior beliefs' pada regularisasi yang akan dibahas di pertemuan regresi linier

Studi Kasus: Wake Word Detector

Wake word adalah kata pemicu (misalnya 'Alexa') yang membuat asisten suara mulai mendengarkan aktif. Dalil Bayes dapat dipakai untuk menganalisis performa detektor wake word ini secara kuantitatif.

- Model wake word detector berjalan terus-menerus pada setiap suara yang terdengar, sehingga kejadian wake word yang sesungguhnya sangat jarang (rare event)
- Dalil Bayes membantu menghitung probabilitas 'benar-benar ada wake word' dengan mempertimbangkan tingkat false positive dan kelangkaan kejadian tersebut
- Implikasi praktis: meski recall model tinggi, false positive rate yang sedikit saja bisa mendominasi hasil deteksi karena kejadian aslinya sangat jarang
- Studi kasus ini menunjukkan pentingnya menganalisis metrik evaluasi bersama dengan proporsi kejadian yang sebenarnya (base rate)

Metode dan Media Pembelajaran

Bentuk & Metode

Ceramah dan latihan implementasi K-Means serta GMM

Media & Sumber Belajar

PyTorch/scikit-learn, visualisasi plot hasil clustering

Estimasi Waktu

Kuliah (Praktikum): PB 180' + Praktik tatap muka 90' + PT 60' + BM 60' → Total 390 menit (~6,5 jam)

Evaluasi dan Tugas

Indikator Penilaian

- Mahasiswa dapat menjalankan dan menjelaskan hasil clustering

Bentuk & Kriteria Tugas

- Tugas coding: implementasi clustering dengan hasil dan visualisasi yang sesuai

Bobot penilaian pertemuan ini: 5%

Ringkasan Pertemuan

- Pengenalan Unsupervised Learning
- Tinjauan Ulang Konsep Dasar Probabilitas
- Algoritma K-Means
- Algoritma Lloyd dan Menentukan Jumlah Cluster
- Ketidakpastian dan Kebutuhan akan Probabilitas
- Distribusi Probabilitas Gabungan (Joint Distribution)
- Estimasi Kepadatan dan Maximum Likelihood Estimation (MLE)
- Bias Estimator dan Distribusi Gaussian Multivariat
- Model Campuran Gaussian (Gaussian Mixture Model)
- Algoritma Expectation-Maximization (EM) untuk GMM
- Dalil Bayes (Bayes' Theorem)
- Studi Kasus: Wake Word Detector

Pertemuan berikutnya akan melanjutkan pembahasan sesuai Rencana Pembelajaran Semester (RPS).

Referensi

Sumber Utama

- Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.), O'Reilly, 2022
- Rahmad Syah, Pengantar Machine Learning: Teori dan Aplikasi dengan Python, Andi, 2021

Sumber Pendukung

- Andriy Burkov, The Hundred-Page Machine Learning Book, 2019
- Ian Goodfellow et al., Deep Learning, MIT Press, 2016
- Jake VanderPlas, Python Data Science Handbook, O'Reilly, 2016

Materi diperkaya dari CS189/289 UC Berkeley - Discussion Mini Lecture 1, Lecture 4: K-Means and Probability, dan Lecture 5: Density Estimation and Gaussian Mixture Models.