

MATA KULIAH DATA SCIENCE

PERTEMUAN 5

Regresi Linier (1): Formulasi Dasar dan Minimasi Error

Sub-CPMK 5

D4 Teknologi Rekayasa Perangkat Lunak - Politeknik Negeri Madiun

Tujuan Pembelajaran

SUB-CPMK 5

1

Mahasiswa memahami formulasi regresi linier dan minimasi error

Peta Materi Pertemuan (1/2)

1 **Formulasi Dasar Regresi Linier**

2 **Fungsi Basis**

3 **Perhitungan Vektorisasi**

4 **Fungsi Kesalahan (Error Function)**

5 **Minimasi Fungsi Kesalahan dan Interpretasi Geometris**

6 **Evaluasi Model**

7 **Machine Learning sebagai Aproksimasi Fungsi**

8 **Menentukan Rank Matriks**

Peta Materi Pertemuan (2/2)

9 Keluarga Model Regresi Linier

10 Notasi Matriks dan Kompleksitas Normal Equation

11 R-Squared sebagai Perbandingan terhadap Model Baseline

Formulasi Dasar Regresi Linier

Regresi linier memodelkan hubungan antara variabel input (fitur) dan output (target) sebagai kombinasi linier. Model ini sederhana namun menjadi fondasi bagi banyak metode ML lainnya.

- Bentuk umum: $y = w_0 + w_1 \cdot x_1 + w_2 \cdot x_2 + \dots + w_n \cdot x_n$
- w (bobot/koeffisien) adalah parameter yang dipelajari dari data
- Cocok untuk memodelkan hubungan yang mendekati linier antar variabel

Berapa lama perjalanan ini?

Dinas Perhubungan ingin memperkirakan waktu tempuh bus kota berdasarkan jarak rute.

Data yang tersedia:

Jarak (km)	Waktu (menit)
2	8
4	14
6	22
8	26

**Pertanyaannya sederhana:
garis seperti apa yang paling
baik menggambarkan pola ini?**

Dan yang lebih penting — apa yang kita maksud dengan kata "paling baik"?

$$\text{waktu} \approx w \times \text{jarak} + b$$

Diskusi 5 menit: menurut Anda, apa arti w dan b dalam konteks perjalanan bus?

Anatomi model regresi linier

$$f(x) = w \cdot x + b$$

$f(x)$

Prediksi

Keluaran model — nilai yang kita perkirakan, bukan nilai sebenarnya.

x

Fitur

Masukan yang kita amati.
Dalam kasus kita: jarak rute.

w

Bobot / Koefisien


Seberapa besar x memengaruhi keluaran.
Inilah yang dipelajari model.

b


Bias / Intersep

Nilai keluaran saat $x = 0$.
Juga dipelajari model.

w dan b disebut parameter. Nilainya tidak kita tentukan sendiri — model yang mencarinya dari data.



Simple linear regression



Multiple linear regression

Angka itu artinya apa?

$$\text{waktu} = 3.1 \times \text{jarak} + 1.8$$


 $w = 3.1$

Setiap tambahan 1 km rute
memperpanjang waktu tempuh
sekitar 3,1 menit.

Ini laju, bukan total.


 $b = 1.8$

Saat jarak nol, model tetap
memperkirakan 1,8 menit —
waktu naik-turun penumpang.

Tidak selalu bermakna fisik.

Peringatan: hubungan yang ditemukan model adalah korelasi, bukan sebab-akibat. Model tidak tahu bahwa jarak "menyebabkan" waktu — ia hanya menemukan pola dalam angka.

Seberapa meleset garis kita?

Untuk tiap titik data, ada selisih antara nilai sebenarnya dan nilai prediksi. Selisih itu disebut residual atau galat.


$$e_i = y_i - f(x_i)$$

- Residual positif: model menebak terlalu rendah
- Residual negatif: model menebak terlalu tinggi
- Residual nol: tebakan tepat (jarang terjadi)

Kenapa tidak dijumlahkan begitu saja?

Karena residual positif dan negatif akan saling meniadakan — garis yang buruk bisa tampak sempurna.

Data aktual vs prediksi garis



Fungsi Basis


Fungsi basis memungkinkan regresi linier memodelkan hubungan non-linier dengan cara mentransformasi fitur input terlebih dahulu, sementara model tetap linier terhadap parameternya.

- Contoh fungsi basis: polinomial (x , x^2 , x^3), fungsi logaritmik, fungsi trigonometri
- Model tetap disebut 'linier' karena linier terhadap parameter w , bukan terhadap x
- Trade-off: fungsi basis yang lebih kompleks meningkatkan fleksibilitas tapi juga risiko overfitting

$$h_w(x) = w_1x + w_2x^2 + \dots + w_nx^n + b$$


Here, n -th power indicates the degree of the polynomial.

Polynomial regression is a type of linear regression. Although its features are non-linear, the relationship between its weight parameters w is still linear.




Comparison between linear and polynomial regression

Representative Basis Functions from Different Families



Linear vs Polynomial Regression



$$y(\vec{x}, \vec{w}) = \sum_{j=0}^5 w_j x^j$$

$$y(x) = 0.000 + 4.355x^1 - 0.203x^2 - 14.426x^3 + 0.164x^4 + 9.368x^5$$

$$y(x) = 0.120 - 0.320x$$

Perhitungan Vektorisasi

Vektorisasi mengganti perhitungan berulang (loop) dengan operasi matriks/vektor, yang jauh lebih efisien secara komputasi terutama pada data berukuran besar.

- Representasi data dan parameter dalam bentuk matriks X dan vektor w
- Prediksi dihitung sekaligus untuk seluruh data: $y_{\text{pred}} = X \cdot w$
- Library seperti NumPy mengoptimalkan operasi matriks secara internal (jauh lebih cepat dari loop Python biasa)

Fungsi Kesalahan (Error Function)

Fungsi kesalahan mengukur seberapa jauh prediksi model dari nilai sebenarnya. Pada regresi linier, fungsi yang umum digunakan adalah Mean Squared Error (MSE).

- MSE menghitung rata-rata kuadrat selisih antara prediksi dan nilai aktual
- Kuadrat membuat kesalahan besar diberi bobot lebih besar (lebih sensitif terhadap outlier)
- Fungsi kesalahan menjadi objektif yang diminimalkan selama proses pelatihan

MATERI 5

Minimasi Fungsi Kesalahan dan Interpretasi Geometris

Meminimalkan fungsi kesalahan berarti mencari nilai parameter w yang membuat prediksi paling mendekati data aktual. Secara geometris, ini setara dengan mencari garis/hyperplane terbaik yang paling 'pas' dengan sebaran titik data.

- Secara geometris: mencari garis (2D) atau hyperplane (multi-dimensi) yang meminimalkan jarak vertikal ke titik data
- Solusi analitik tertutup (closed-form) tersedia melalui Normal Equation untuk kasus tertentu
- Solusi juga dapat dicari secara iteratif melalui gradient descent

Evaluasi Model

Evaluasi model regresi dilakukan dengan metrik yang mengukur seberapa akurat prediksi terhadap data uji.

- MSE/RMSE: rata-rata kuadrat/akar kuadrat kesalahan prediksi
- MAE (Mean Absolute Error): rata-rata selisih absolut prediksi dan aktual
- R-squared: proporsi variansi target yang dapat dijelaskan oleh model



3689302

Mean Squared Error (MSE)

$$\frac{1}{N} \left(\sum_{n=1}^N (t_n - y(x_n, w))^2 \right)$$

Root Mean Squared Error (RMSE)

$$\sqrt{\frac{1}{N} \left(\sum_{n=1}^N (t_n - y(x_n, w))^2 \right)}$$

R-Squared (R^2) Score

$$1 - \frac{\sum_{n=1}^N (t_n - y(x_n, w))^2}{\sum_{n=1}^N (t_n - \bar{t})^2}$$

Mean Absolute Error (MAE)

$$\frac{1}{N} \left(\sum_{n=1}^N |t_n - y(x_n, w)| \right)$$

In the same unit as the data; similar to MSE but differs in how the penalization applies.

Machine Learning sebagai Aproksimasi Fungsi

Secara matematis, machine learning dapat dipandang sebagai proses mencari fungsi h_w yang memetakan input (X) ke output (Y), dengan w adalah parameter yang dipelajari dari data.

- Fungsi h_w disebut juga model, dengan w adalah parameter yang dipelajari dari data
- Sifat fungsi penting untuk dipahami: injective (satu output untuk tiap input), surjective (setiap output punya minimal satu pasangan input), dan bijective (pemetaan sempurna satu-satu)
- Pada regresi linier, fungsi yang dicari adalah fungsi linier dari fitur input

Menentukan Rank Matriks

Rank matriks penting dipahami dalam regresi linier, terutama untuk mengetahui apakah solusi Normal Equation dapat dihitung (matriks harus invertible/dapat dibalik).

- Cara 1 - Python: menggunakan fungsi bawaan library, misalnya `numpy.linalg.matrix_rank`
- Cara 2 - Inspeksi manual: menghitung berapa banyak baris/kolom yang saling bebas linier (linearly independent)
- Cara 3 - Nilai singular (singular values): rank sama dengan banyaknya nilai singular yang tidak nol

Keluarga Model Regresi Linier

Keluarga model regresi linier terdiri dari seluruh garis (atau hyperplane) yang dapat diparameterisasi oleh nilai slope dan intercept.

- Ruang hipotesis regresi linier adalah seluruh kemungkinan garis lurus dengan berbagai nilai kemiringan (slope) dan titik potong (intercept)
- Memilih keluarga model linier berarti memasukkan asumsi (bias induktif) bahwa hubungan antar variabel bersifat linier

Notasi Matriks dan Kompleksitas Normal Equation

Seluruh data latih dapat disusun dalam satu matriks yang disebut design matrix, sehingga solusi Normal Equation dapat dituliskan secara ringkas dalam notasi matriks.

- Design matrix X : setiap baris merepresentasikan satu sampel data, setiap kolom merepresentasikan satu fitur (termasuk kolom bias/intercept)
- Solusi Normal Equation: $w = (X^T X)^{-1} X^T y$, diperoleh dengan menyamakan turunan fungsi kesalahan terhadap w sama dengan nol
- Kompleksitas waktu menghitung invers matriks $X^T X$ berukuran $D \times D$ adalah sekitar $O(D^3)$, sehingga menjadi mahal ketika jumlah fitur (D) sangat besar
- Untuk kasus tersebut, pendekatan iteratif seperti gradient descent (dibahas pada pertemuan mendatang) lebih efisien

R-Squared sebagai Perbandingan terhadap Model Baseline

R-squared (R^2) mengukur kualitas model regresi secara relatif terhadap model paling sederhana, yaitu model yang hanya memprediksi nilai rata-rata (mean) dari target.

- R^2 menghitung proporsi pengurangan total kesalahan (sum of squared error) dibandingkan model intercept/rata-rata sebagai baseline
- Nilai R^2 bersifat unitless (tanpa satuan), sehingga memudahkan perbandingan antar model atau antar dataset
- R^2 mendekati 1 berarti model jauh lebih baik dibanding sekadar menebak rata-rata; R^2 mendekati 0 berarti model tidak lebih baik dari baseline tersebut

Metode dan Media Pembelajaran

Bentuk & Metode

Ceramah, latihan coding vektorisasi, dan diskusi teori

Media & Sumber Belajar

Google Colab, NumPy

Estimasi Waktu

Kuliah (Praktikum): PB 180' + Praktik tatap muka 90' + PT 60' + BM 60' → Total 390 menit (~6,5 jam)

Evaluasi dan Tugas

Indikator Penilaian

- Mahasiswa mampu menerapkan linear regression

Bentuk & Kriteria Tugas

- Kuis konsep singkat
- Praktikum coding regresi linier

Bobot penilaian pertemuan ini: 5%

Ringkasan Pertemuan

- Formulasi Dasar Regresi Linier
- Fungsi Basis
- Perhitungan Vektorisasi
- Fungsi Kesalahan (Error Function)
- Minimasi Fungsi Kesalahan dan Interpretasi Geometris
- Evaluasi Model
- Machine Learning sebagai Aproksimasi Fungsi
- Menentukan Rank Matriks
- Keluarga Model Regresi Linier
- Notasi Matriks dan Kompleksitas Normal Equation
- R-Squared sebagai Perbandingan terhadap Model Baseline

Pertemuan berikutnya akan melanjutkan pembahasan sesuai Rencana Pembelajaran Semester (RPS).

Referensi

Sumber Utama

- Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.), O'Reilly, 2022
- Rahmad Syah, Pengantar Machine Learning: Teori dan Aplikasi dengan Python, Andi, 2021

Sumber Pendukung

- Andriy Burkov, The Hundred-Page Machine Learning Book, 2019
- Ian Goodfellow et al., Deep Learning, MIT Press, 2016
- Jake VanderPlas, Python Data Science Handbook, O'Reilly, 2016

Materi diperkaya dari CS189/289 UC Berkeley - Discussion Mini Lecture 1 (Linear Algebra Review), Lecture 3 (Model Family), dan Lecture 6 (Linear Regression 1).