

MATA KULIAH DATA SCIENCE

## PERTEMUAN 6

# Regresi Linier (2): Regularisasi

Sub-CPMK 6

D4 Teknologi Rekayasa Perangkat Lunak - Politeknik Negeri Madiun

# Tujuan Pembelajaran

SUB-CPMK 6

1

Mahasiswa memahami regularisasi, MLE, dan bias-variance trade-off

# Peta Materi Pertemuan (1/2)

**1** Lanjutan dari Minimasi Kesalahan

**2** Regularisasi pada Regresi Linier (Regularized Least Squares)

**3** Tantangan Ketika Normal Equation Tidak Dapat Digunakan

**4** Overfitting, Underfitting, dan Sweet Spot

**5** Regularisasi sebagai Batasan pada Proses Pembelajaran

**6** Regularisasi sebagai Optimisasi Berbatas (Lagrangian Duality)

**7** Ilustrasi Praktis: Ill-Conditioning dan Ridge Trick

**8** Alternatif Solusi: Moore-Penrose Pseudo-Inverse

# Peta Materi Pertemuan (2/2)

## 9 Pembelajaran Sekuensial (LMS) sebagai Pendahuluan Gradient Descent

## Lanjutan dari Minimasi Kesalahan

*Sebelum masuk ke regularisasi, penting untuk mengulas kembali bagaimana solusi regresi linier tanpa regularisasi bisa menjadi tidak stabil, terutama saat fitur saling berkorelasi tinggi (multikolinearitas) atau jumlah fitur besar.*

- Solusi Ordinary Least Squares (OLS) bisa memiliki bobot  $w$  yang sangat besar/tidak stabil
- Model dengan bobot besar cenderung overfit dan sensitif terhadap noise
- Regularisasi hadir sebagai solusi untuk mengontrol besaran bobot

## Regularisasi pada Regresi Linier (Regularized Least Squares)

*Regularisasi menambahkan penalti pada fungsi kesalahan untuk mencegah bobot model menjadi terlalu besar, sehingga mengurangi risiko overfitting.*

- Ridge Regression (L2): menambahkan penalti kuadrat bobot (sum of  $w^2$ )
- Lasso Regression (L1): menambahkan penalti nilai absolut bobot (sum of  $|w|$ ), dapat membuat sebagian bobot menjadi nol (seleksi fitur otomatis)
- Parameter regularisasi ( $\lambda$ ) mengontrol seberapa kuat penalti diterapkan
- Regularisasi menyeimbangkan antara kesesuaian data (fit) dan kompleksitas model

## Tantangan Ketika Normal Equation Tidak Dapat Digunakan

*Normal Equation memberikan solusi analitik langsung untuk regresi linier, tetapi memiliki keterbatasan praktis pada kondisi tertentu.*

- Matriks  $X^T X$  harus invertible (dapat dibalik); jika singular, solusi tidak dapat dihitung langsung
- Kondisi ini sering muncul saat fitur saling berkorelasi tinggi atau jumlah fitur  $>$  jumlah data
- Perhitungan invers matriks berukuran besar juga mahal secara komputasi
- Solusi alternatif: regularisasi (Ridge) membuat matriks menjadi invertible, atau gunakan pendekatan iteratif (gradient descent)

## Overfitting, Underfitting, dan Sweet Spot

*Kompleksitas model yang lebih tinggi tidak selalu berarti lebih baik. Ada titik seimbang antara model yang terlalu sederhana dan terlalu kompleks.*

- Underfitting: model terlalu sederhana, gagal menangkap pola penting dalam data
- Overfitting: model terlalu kompleks, sangat cocok dengan data latih tapi buruk pada data baru
- 'Sweet spot': tingkat kompleksitas model yang memberikan generalisasi terbaik
- Grafik akurasi data latih vs data validasi sering menunjukkan pola ini - akurasi latih terus membaik, sementara akurasi validasi meningkat lalu menurun

## MATERI 5

# Regularisasi sebagai Batasan pada Proses Pembelajaran

*Regularisasi adalah proses menambahkan batasan atau penalti pada proses pembelajaran untuk meningkatkan kemampuan generalisasi model.*

- Regularisasi membantu menggeser model dari kondisi overfitting menuju sweet spot
- Kekuatan regularisasi biasanya diatur melalui hyperparameter dan disetel menggunakan data validasi
- Teknik penyetelan regularisasi ini akan dibahas lebih lanjut pada tahap optimisasi dalam siklus ML

## MATERI 6

# Regularisasi sebagai Optimisasi Berbatas (Lagrangian Duality)

*Secara matematis, menambahkan penalti regularisasi pada fungsi kesalahan dapat dipandang sebagai bentuk lain dari optimisasi dengan batasan (constrained optimization), melalui konsep Lagrangian.*

- Ide dasar Lagrangian: memperkenalkan penalti untuk setiap pelanggaran batasan (constraint) yang ditetapkan
- Regularized Least Squares = meminimalkan error data + (hyperparameter regularisasi) x (fungsi regularisasi)
- Ridge (L2) setara dengan membatasi bobot  $w$  berada dalam bola (lingkaran), sedangkan Lasso (L1) setara dengan membatasi  $w$  berada dalam bentuk berlian (diamond) - inilah sebabnya Lasso cenderung menghasilkan bobot yang benar-benar nol

### Ilustrasi Praktis: Ill-Conditioning dan Ridge Trick

*Ketika dua fitur pada data hampir identik (berkorelasi sangat tinggi/multikolinearitas), matriks  $X^T X$  menjadi 'ill-conditioned' - solusi Normal Equation menjadi sangat tidak stabil meski hasil prediksinya tetap terlihat wajar.*

- Contoh nyata: dua fitur yang hampir sama menyebabkan bobot hasil Normal Equation biasa berayun sangat ekstrem (misalnya salah satu bobot menjadi belasan, yang lain menjadi negatif belasan)
- Ridge Trick: menambahkan  $\lambda \times I$  (matriks identitas) pada  $X^T X$  sebelum dibalik, membuat matriks tersebut selalu invertible dan solusinya jauh lebih stabil
- Bilangan kondisi (condition number) matriks yang besar adalah indikator bahwa solusi rentan terhadap noise kecil pada data

## MATERI 8

### Alternatif Solusi: Moore-Penrose Pseudo-Inverse

*Selain Ridge Trick, solusi Normal Equation yang sulit dihitung (karena matriks singular atau tidak persegi) juga dapat diatasi menggunakan Moore-Penrose Pseudo-Inverse, yang dihitung melalui dekomposisi SVD (Singular Value Decomposition).*

- Pseudo-inverse memberikan solusi  $w$  dengan norma (Euclidean) terkecil di antara solusi-solusi yang mungkin, ketika solusi tidak unik
- Pendekatan ini secara numerik lebih stabil dibandingkan menghitung invers langsung pada matriks yang hampir singular
- Library seperti NumPy/scikit-learn umumnya sudah menerapkan pseudo-inverse secara otomatis di balik layar

# Pembelajaran Sekuensial (LMS) sebagai Pendahuluan Gradient Descent

*Selain solusi analitik (Normal Equation/Ridge Trick/Pseudo-Inverse), regresi linier juga dapat dilatih secara iteratif menggunakan pembelajaran sekuensial, yang dikenal sebagai Least Mean Squares (LMS).*

- LMS memperbarui bobot  $w$  sedikit demi sedikit berdasarkan satu (atau beberapa) sampel data setiap kali, dikendalikan oleh learning rate
- Pendekatan ini jauh lebih hemat komputasi untuk dataset besar dibanding menghitung invers matriks secara langsung
- LMS adalah bentuk awal dari Gradient Descent yang akan dibahas lebih mendalam pada pertemuan mengenai Optimisasi dan Gradient Descent

# Metode dan Media Pembelajaran

## Bentuk & Metode

Ceramah, diskusi studi kasus, dan praktikum

## Media & Sumber Belajar

Google Colab, scikit-learn

## Estimasi Waktu

Kuliah (Praktikum): PB 180' + Praktik tatap muka 90' + PT 60' + BM 60' → Total 390 menit (~6,5 jam)

# Evaluasi dan Tugas

## Indikator Penilaian

- Mahasiswa dapat membandingkan model regularisasi dan non-regularisasi

## Bentuk & Kriteria Tugas

- Analisis model: membandingkan Ridge/Lasso vs OLS pada dataset yang sama

**Bobot penilaian pertemuan ini: 5%**

# Ringkasan Pertemuan

- Lanjutan dari Minimasi Kesalahan
- Regularisasi pada Regresi Linier (Regularized Least Squares)
- Tantangan Ketika Normal Equation Tidak Dapat Digunakan
- Overfitting, Underfitting, dan Sweet Spot
- Regularisasi sebagai Batasan pada Proses Pembelajaran
- Regularisasi sebagai Optimisasi Berbatas (Lagrangian Duality)
- Ilustrasi Praktis: Ill-Conditioning dan Ridge Trick
- Alternatif Solusi: Moore-Penrose Pseudo-Inverse
- Pembelajaran Sekuensial (LMS) sebagai Pendahuluan Gradient Descent

*Pertemuan berikutnya akan melanjutkan pembahasan sesuai Rencana Pembelajaran Semester (RPS).*

# Referensi

## Sumber Utama

- Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.), O'Reilly, 2022
- Rahmad Syah, Pengantar Machine Learning: Teori dan Aplikasi dengan Python, Andi, 2021

## Sumber Pendukung

- Andriy Burkov, The Hundred-Page Machine Learning Book, 2019
- Ian Goodfellow et al., Deep Learning, MIT Press, 2016
- Jake VanderPlas, Python Data Science Handbook, O'Reilly, 2016

*Materi diperkaya dari CS189/289 UC Berkeley - Lecture 3: ML Mechanics dan Lecture 7: Linear Regression (2).*