

MATA KULIAH DATA SCIENCE

PERTEMUAN 7

Regresi Linier (3): MLE dan Bias-Variance Trade-off

Sub-CPMK 6

D4 Teknologi Rekayasa Perangkat Lunak - Politeknik Negeri Madiun

Tujuan Pembelajaran

SUB-CPMK 6

1

Mahasiswa memahami regularisasi, MLE, dan bias-variance trade-off

Peta Materi Pertemuan (1/2)

1 Rekapitulasi Regularisasi

2 Regresi Linier sebagai Pendekatan Maximum Likelihood Estimation (MLE)

3 Memilih Model Distribusi Noise yang Berbeda

4 Pengenalan Konsep Kepercayaan Awal (Prior Beliefs)

5 Trade-off antara Bias dan Varians (Bias-Variance Trade-off)

6 Bias Induktif dan No Free Lunch Theorem

7 Akurasi Training vs Validasi

8 Asumsi Noise Aditif Gaussian dan Turunan Least Squares = MLE

Peta Materi Pertemuan (2/2)

9 Kondisi Singularitas pada Normal Equation

10 Maximum A Posteriori (MAP) dan Hubungannya dengan Ridge Regression

11 Dekomposisi Formal: Noise, Bias, dan Variansi Model

12 Menentukan Kompleksitas Model Optimal melalui Validasi

Rekapitulasi Regularisasi

Sebelum melanjutkan ke pandangan probabilistik, materi regularisasi (Ridge & Lasso) yang telah dipelajari sebelumnya direview kembali sebagai jembatan pemahaman.

- Ridge (L2) menstabilkan solusi dan mengecilkan bobot secara merata
- Lasso (L1) dapat menghasilkan model yang lebih sparse (banyak bobot menjadi nol)
- Pemilihan jenis regularisasi bergantung pada karakteristik data dan tujuan interpretasi model

MATERI 2

Regresi Linier sebagai Pendekatan Maximum Likelihood Estimation (MLE)

Regresi linier dengan fungsi kesalahan MSE ternyata dapat diturunkan dari sudut pandang probabilistik, yaitu sebagai estimasi parameter yang memaksimalkan likelihood data dengan asumsi noise berdistribusi Gaussian.

- MLE mencari parameter model yang membuat data yang teramati paling 'mungkin' terjadi
- Dengan asumsi noise Gaussian, memaksimalkan likelihood setara dengan meminimalkan MSE
- Sudut pandang ini menghubungkan regresi linier dengan teori probabilitas & statistik inferensial

MATERI 3

Memilih Model Distribusi Noise yang Berbeda

Asumsi distribusi noise mempengaruhi bentuk fungsi kesalahan yang sesuai. Mengganti asumsi distribusi noise dapat menghasilkan fungsi loss yang berbeda dari MSE.

- Noise Gaussian → fungsi loss MSE (L2)
- Noise Laplace → fungsi loss MAE (L1), lebih robust terhadap outlier
- Pemilihan distribusi noise sebaiknya mempertimbangkan karakteristik data (ada outlier atau tidak)

MATERI 4

Pengenalan Konsep Kepercayaan Awal (Prior Beliefs)

Dalam pendekatan Bayesian, prior beliefs adalah asumsi awal tentang nilai parameter sebelum melihat data. Regularisasi dapat diinterpretasikan sebagai penerapan prior tertentu pada bobot model.

- Prior Gaussian pada bobot w berkorespondensi dengan regularisasi Ridge (L2)
- Prior Laplace pada bobot w berkorespondensi dengan regularisasi Lasso (L1)
- Pendekatan ini disebut Maximum A Posteriori (MAP) estimation

MATERI 5

Trade-off antara Bias dan Varians (Bias-Variance Trade-off)

Bias-variance trade-off menjelaskan hubungan antara kompleksitas model dan kemampuan generalisasinya. Model yang terlalu sederhana memiliki bias tinggi, model yang terlalu kompleks memiliki varians tinggi.

- Bias tinggi: model terlalu sederhana, gagal menangkap pola data (underfitting)
- Varians tinggi: model terlalu sensitif terhadap data latih, tidak stabil pada data baru (overfitting)
- Total error = $\text{bias}^2 + \text{varians} + \text{noise irreducible}$
- Regularisasi adalah salah satu cara mengontrol trade-off ini

Bias Induktif dan No Free Lunch Theorem

Bias induktif adalah asumsi yang dipilih dalam desain model untuk memungkinkan generalisasi di luar data latih. Tidak ada satu model yang secara universal terbaik untuk semua masalah.

- Tanpa asumsi tertentu, tak terhingga banyak model yang bisa cocok dengan data latih yang sama
- Memilih keluarga model (misalnya linier) berarti memasukkan bias induktif tertentu
- No Free Lunch Theorem: tidak ada model yang secara universal terbaik - pemilihan model harus disesuaikan dengan bias induktif yang tepat untuk masalah yang dihadapi

Akurasi Training vs Validasi

Saat menyetel hyperparameter regularisasi menggunakan data validasi, pola umum yang terlihat adalah akurasi data latih dan data validasi bergerak berbeda seiring bertambahnya kekuatan regularisasi.

- Akurasi pada data latih cenderung terus membaik secara konsisten seiring bertambahnya kompleksitas model
- Akurasi pada data validasi biasanya meningkat lalu menurun - titik puncaknya adalah 'sweet spot' regularisasi yang optimal
- Pola grafik ini membantu menentukan tingkat regularisasi yang tepat

MATERI 8

Asumsi Noise Aditif Gaussian dan Turunan Least Squares = MLE

Hubungan antara regresi linier dan MLE dapat diturunkan secara formal dengan mengasumsikan bahwa target sebenarnya adalah hasil prediksi model ditambah noise acak yang berdistribusi Gaussian (additive Gaussian noise).

- Asumsi: $y = f(x) + \epsilon$, dengan ϵ (noise) berdistribusi Gaussian dengan mean 0
- Karena data diasumsikan independen, likelihood seluruh dataset adalah perkalian likelihood tiap sampel data
- Menuliskan log-likelihood dari distribusi Gaussian tersebut dan menyederhanakannya menghasilkan bentuk yang identik dengan meminimalkan Sum of Squared Error (SSE)
- Kesimpulan: solusi least squares yang biasa dipakai secara aljabar ternyata sama persis dengan solusi Maximum Likelihood Estimation di bawah asumsi noise Gaussian - bukan sekadar kebetulan komputasi

Kondisi Singularitas pada Normal Equation

Memahami kapan Normal Equation dapat diselesaikan secara langsung membantu menjelaskan mengapa terkadang diperlukan regularisasi atau pseudo-inverse.

- Jika jumlah data (N) sama dengan jumlah parameter ($D+1$) dan matriks X berpangkat penuh (full rank), Normal Equation dapat diselesaikan secara langsung dan error pada data latih akan selalu bernilai nol
- Matriks $X^T X$ berisiko singular (tidak dapat dibalik) ketika jumlah fitur lebih banyak dari jumlah data ($D+1 > N$), atau ketika ada fitur yang saling berkorelasi sangat tinggi
- Kondisi inilah yang menjadi alasan praktis di balik penggunaan Ridge Trick maupun Moore-Penrose Pseudo-Inverse yang telah dibahas pada pertemuan sebelumnya

Maximum A Posteriori (MAP) dan Hubungannya dengan Ridge Regression

Selain MLE, pendekatan Bayesian juga mengenal Maximum A Posteriori (MAP), yang memasukkan keyakinan awal (prior) tentang parameter selain hanya mengandalkan data. MAP inilah yang menjadi dasar teoritis dari regularisasi Ridge.

- Dalil Bayes: Posterior proporsional terhadap Likelihood dikali Prior
- MAP mencari parameter yang memaksimalkan posterior tersebut, bukan sekadar likelihood seperti pada MLE
- Jika prior atas bobot w diasumsikan berdistribusi Gaussian (kecil, terpusat di nol), maksimasi posterior menghasilkan bentuk yang identik dengan Ridge Regression
- Kesimpulan penting: Least-Squares + Prior Gaussian pada bobot = Ridge Regression - ini menjelaskan makna probabilistik di balik regularisasi L2

Dekomposisi Formal: Noise, Bias, dan Variansi Model

Tantangan fundamental dalam pembelajaran adalah menyeimbangkan antara mencocokkan data (fit) dan menggeneralisasi ke dunia nyata. Total error suatu model dapat diuraikan secara matematis menjadi tiga komponen.

- Noise: variabilitas noise acak pada proses yang dimodelkan (pengukuran, stokastisitas, informasi yang hilang) - di luar kendali model
- Bias: rata-rata penyimpangan antara prediksi model dan nilai sebenarnya, dipengaruhi oleh pilihan keluarga fungsi f dan prosedur pembelajaran
- Model Variance: variabilitas prediksi model jika dilatih ulang pada dataset latih yang berbeda-beda - mencerminkan sensitivitas model terhadap data latih tertentu
- Total expected error = Noise + Bias² + Model Variance - ketiganya tidak bisa diminimalkan bersamaan, ini fondasi teoritis dari bias-variance trade-off

Menentukan Kompleksitas Model Optimal melalui Validasi

Nilai hyperparameter regularisasi (λ) secara langsung mengendalikan posisi model pada trade-off bias-variance, dan nilai optimalnya ditentukan melalui data validasi.

- λ semakin besar $\rightarrow$ regularisasi semakin kuat $\rightarrow$ bias meningkat, variansi menurun
- λ semakin kecil $\rightarrow$ regularisasi semakin lemah $\rightarrow$ bias menurun, variansi meningkat
- Kompleksitas model juga dapat dikendalikan melalui jumlah fitur dan pemilihan fitur, tidak hanya regularisasi
- Semakin banyak data latih yang tersedia, semakin kompleks model yang dapat didukung tanpa risiko overfitting berlebihan

Metode dan Media Pembelajaran

Bentuk & Metode

Ceramah, diskusi studi kasus, dan praktikum

Media & Sumber Belajar

Google Colab, scikit-learn

Estimasi Waktu

Kuliah (Praktikum): PB 180' + Praktik tatap muka 90' + PT 60' + BM 60' → Total 390 menit (~6,5 jam)

Evaluasi dan Tugas

Indikator Penilaian

- Mahasiswa dapat membandingkan model regularisasi dan non-regularisasi

Bentuk & Kriteria Tugas

- Analisis model: membandingkan Ridge/Lasso vs OLS

Bobot penilaian pertemuan ini: 5%

Ringkasan Pertemuan

- Rekapitulasi Regularisasi
- Regresi Linier sebagai Pendekatan Maximum Likelihood Estimation (MLE)
- Memilih Model Distribusi Noise yang Berbeda
- Pengenalan Konsep Kepercayaan Awal (Prior Beliefs)
- Trade-off antara Bias dan Varians (Bias-Variance Trade-off)
- Bias Induktif dan No Free Lunch Theorem
- Akurasi Training vs Validasi
- Asumsi Noise Aditif Gaussian dan Turunan Least Squares = MLE
- Kondisi Singularitas pada Normal Equation
- Maximum A Posteriori (MAP) dan Hubungannya dengan Ridge Regression
- Dekomposisi Formal: Noise, Bias, dan Variansi Model
- **Menentukan Kompleksitas Model Optimal melalui Validasi**

Pertemuan berikutnya akan melanjutkan pembahasan sesuai Rencana Pembelajaran Semester (RPS).

Referensi

Sumber Utama

- Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.), O'Reilly, 2022
- Rahmad Syah, Pengantar Machine Learning: Teori dan Aplikasi dengan Python, Andi, 2021

Sumber Pendukung

- Andriy Burkov, The Hundred-Page Machine Learning Book, 2019
- Ian Goodfellow et al., Deep Learning, MIT Press, 2016
- Jake VanderPlas, Python Data Science Handbook, O'Reilly, 2016

Materi diperkaya dari CS189/289 UC Berkeley - Lecture 3, Lecture 8, dan Lecture 9: Regression (Cont.) and Bias-Variance Trade-off.