MATA KULIAH DATA SCIENCE

PERTEMUAN 9

Regresi Logistik (1): Klasifikasi Linier dan Fungsi Sigmoid

Sub-CPMK 7

D4 Teknologi Rekayasa Perangkat Lunak - Politeknik Negeri Madiun

Tujuan Pembelajaran

SUB-CPMK 7

1	Mahasiswa memahami klasifikasi linier, fungsi sigmoid, dan regularisasi

Peta Materi Pertemuan (1/2)

1. Klasifikasi sebagai Tugas Pembelajaran
2. Model Klasifikasi Linier dan Fungsi Diskriminan
3. Fungsi Sigmoid untuk Klasifikasi
4. Tujuan, Regularisasi, dan Optimisasi Regresi Logistik
5. Pengambilan Keputusan dalam Klasifikasi
6. Masalah Klasifikasi: Biner vs Multi-Kelas
7. Keluarga Model Regresi Logistik
8. Mengapa Tidak Memakai Least Squares untuk Klasifikasi?

Peta Materi Pertemuan (2/2)

9 **Sifat-Sifat Fungsi Sigmoid**

10 **Mengapa Cross-Entropy, Bukan Squared Error?**

11 **Regularisasi Mencegah Solusi Degenerate**

12 **Pengambilan Keputusan: Posterior dan Fungsi Loss**

MATERI 1

Klasifikasi sebagai Tugas Pembelajaran

Berbeda dengan regresi yang memprediksi nilai kontinu, klasifikasi memprediksi label kategori (kelas). Regresi logistik adalah salah satu metode klasifikasi paling fundamental.

- Target berupa kategori diskrit, misalnya ya/tidak, spam/bukan spam
- Klasifikasi biner: dua kelas; klasifikasi multi-kelas: lebih dari dua kelas
- Meski namanya 'regresi', regresi logistik digunakan untuk klasifikasi, bukan prediksi nilai kontinu

MATERI 2

Model Klasifikasi Linier dan Fungsi Diskriminan

Model klasifikasi linier memisahkan kelas menggunakan garis atau hyperplane linier di ruang fitur. Fungsi diskriminan linier menentukan sisi mana suatu titik data berada.

- Fungsi diskriminan linier: kombinasi linier dari fitur input, mirip regresi linier
- Batas keputusan (decision boundary) berbentuk garis lurus (2D) atau hyperplane (multi-dimensi)
- Model probabilistik diskriminatif memodelkan probabilitas kelas $P(y|x)$ secara langsung

MATERI 3

Fungsi Sigmoid untuk Klasifikasi

Fungsi sigmoid mengubah nilai kontinu dari kombinasi linier fitur menjadi probabilitas antara 0 dan 1, sehingga cocok untuk merepresentasikan probabilitas kelas.

- Bentuk fungsi: sigma(z) = 1 / (1 + e^-z)
- Output sigmoid selalu berada di rentang (0, 1), diinterpretasikan sebagai probabilitas
- Ambang batas (threshold), umumnya 0.5, digunakan untuk menentukan kelas akhir

MATERI 4

Tujuan, Regularisasi, dan Optimisasi Regresi Logistik

Regresi logistik dilatih dengan meminimalkan fungsi kesalahan yang disebut cross-entropy loss (log loss), dan dapat diberi regularisasi seperti pada regresi linier.

- Tujuan: menemukan bobot yang memaksimalkan probabilitas prediksi benar pada data latih
- Cross-entropy loss mengukur selisih antara distribusi probabilitas prediksi dan label sebenarnya
- Regularisasi L1/L2 dapat diterapkan untuk mencegah overfitting
- Optimisasi umumnya menggunakan gradient descent karena tidak ada solusi closed-form

MATERI 5

Pengambilan Keputusan dalam Klasifikasi

Setelah model menghasilkan probabilitas, diperlukan aturan keputusan untuk mengubahnya menjadi label kelas akhir.

- Threshold default 0.5, tetapi bisa disesuaikan sesuai konteks (misalnya deteksi penyakit)
- Trade-off antara false positive dan false negative tergantung pemilihan threshold
- Penting mempertimbangkan konsekuensi bisnis/domain saat menentukan threshold

MATERI 6

Masalah Klasifikasi: Biner vs Multi-Kelas

Pada masalah klasifikasi, label bersifat diskrit (kategori), berbeda dengan regresi yang labelnya kontinu.

- Label kategori sering dikodekan sebagai angka, namun tetap harus diperlakukan sebagai kelas, bukan nilai kontinu
- Klasifikasi biner: hanya dua kelas, misalnya spam vs bukan spam
- Klasifikasi multi-kelas: lebih dari dua kelas, misalnya jenis pakaian (kaos, celana, sweater, dll.)

MATERI 7

Keluarga Model Regresi Logistik

Regresi logistik menghasilkan batas keputusan (decision boundary) yang linier, memisahkan kelas menggunakan garis atau hyperplane.

- Ruang hipotesis regresi logistik adalah seluruh kemungkinan batas keputusan linier
- Cocok sebagai baseline untuk masalah klasifikasi sebelum mencoba model non-linier yang lebih kompleks

MATERI 8

Mengapa Tidak Memakai Least Squares untuk Klasifikasi?

Sebelum sampai ke regresi logistik, penting dipahami mengapa regresi linier biasa (least squares) tidak cocok digunakan langsung untuk masalah klasifikasi.

- Least Squares mengasumsikan noise berdistribusi Gaussian - asumsi ini gagal ketika target hanya bernilai 0 atau 1 (biner)
- Prediksi regresi linier bisa menghasilkan nilai di luar rentang 0-1, sehingga sulit diinterpretasikan sebagai probabilitas
- Model least squares untuk klasifikasi juga sangat sensitif terhadap outlier, dapat menggeser batas keputusan secara signifikan
- Solusi: gunakan fungsi sigmoid untuk 'memampatkan' output linier ke rentang (0,1) sehingga dapat diinterpretasikan sebagai probabilitas

MATERI 9

Sifat-Sifat Fungsi Sigmoid

Fungsi sigmoid, juga disebut fungsi logistik, memiliki beberapa sifat matematis penting yang membuatnya cocok untuk klasifikasi biner.

- Sigmoid disebut 'squashing function' karena memetakan seluruh garis bilangan real ke interval terbatas (0,1)
- Kurvanya berbentuk S (S-shaped), dengan titik infleksi simetris di sekitar nol
- Dapat digeser dan diskalakan (sigma(Ax+B)): nilai A lebih besar membuat kurva lebih curam, nilai B menggeser posisi kurva secara horizontal
- Fungsi inversnya disebut fungsi logit, yang mengubah probabilitas kembali menjadi nilai log-odds

MATERI 10

Mengapa Cross-Entropy, Bukan Squared Error?

Menggunakan squared error sebagai fungsi objektif pada regresi logistik ternyata bermasalah, sehingga digunakan fungsi cross-entropy (log loss) sebagai gantinya.

- Squared error pada regresi logistik menghasilkan permukaan error yang non-convex, sehingga optimisasi dapat terjebak pada minimum lokal
- Squared error juga bersifat 'bounded' - nilainya tidak bisa menjadi sangat besar meski prediksi sangat salah, sehingga kurang tegas menghukum kesalahan fatal
- Cross-entropy diturunkan dari MLE dengan mengambil negatif logaritma dari likelihood - menghasilkan fungsi yang convex dan tidak terbatas (unbounded) saat model 'sangat yakin tapi salah arah'
- Karena convex, cross-entropy menjamin proses optimisasi (gradient descent) dapat menemukan solusi optimal global

MATERI 11

Regularisasi Mencegah Solusi Degenerate

Pada data yang dapat dipisahkan secara linier sempurna (linearly separable), regresi logistik tanpa regularisasi dapat menghasilkan bobot yang terus membesar tanpa batas (divergen).

- Tanpa regularisasi, model menjadi terlalu percaya diri (overly confident) pada prediksinya, bobot w dapat tumbuh menuju tak hingga
- Kondisi ini disebut solusi degenerate - secara matematis 'optimal' namun tidak stabil dan tidak realistis
- Menambahkan regularisasi (L1/L2) mencegah bobot tumbuh tanpa batas, menghasilkan solusi yang lebih stabil dan masuk akal

MATERI 12

Pengambilan Keputusan: Posterior dan Fungsi Loss

Keputusan akhir suatu model klasifikasi idealnya tidak hanya bergantung pada probabilitas (posterior) yang dihasilkan model, tetapi juga pada besarnya kerugian (loss) dari tiap jenis kesalahan.

- Keputusan optimal = probabilitas posterior dikombinasikan dengan matriks kerugian (loss) dari setiap kemungkinan keputusan
- Expected loss dihitung dengan mengalikan probabilitas tiap kelas dengan biaya kesalahan jika keputusan tersebut salah
- Rejection Option: jika model tidak cukup yakin (probabilitas mendekati 0.5), sistem dapat memilih untuk tidak membuat keputusan otomatis dan menyerahkan ke manusia

Metode dan Media Pembelajaran

Bentuk & Metode

Ceramah dan latihan klasifikasi dengan fungsi sigmoid

Media & Sumber Belajar

Google Colab, scikit-learn

Estimasi Waktu

Kuliah (Praktikum): PB 180' + Praktik tatap muka 90' + PT 60' + BM 60' → Total 390 menit (~6,5 jam)

Evaluasi dan Tugas

Indikator Penilaian

- Mahasiswa membuat model klasifikasi biner

Bentuk & Kriteria Tugas

- Tugas coding klasifikasi biner beserta penjelasan fungsi aktivasi yang digunakan

Bobot penilaian pertemuan ini: 5%

Ringkasan Pertemuan

- Klasifikasi sebagai Tugas Pembelajaran
- Model Klasifikasi Linier dan Fungsi Diskriminan
- Fungsi Sigmoid untuk Klasifikasi
- Tujuan, Regularisasi, dan Optimisasi Regresi Logistik
- Pengambilan Keputusan dalam Klasifikasi
- Masalah Klasifikasi: Biner vs Multi-Kelas
- Keluarga Model Regresi Logistik
- Mengapa Tidak Memakai Least Squares untuk Klasifikasi?
- Sifat-Sifat Fungsi Sigmoid
- Mengapa Cross-Entropy, Bukan Squared Error?
- Regularisasi Mencegah Solusi Degenerate
- Pengambilan Keputusan: Posterior dan Fungsi Loss

Pertemuan berikutnya akan melanjutkan pembahasan sesuai Rencana Pembelajaran Semester (RPS).

Referensi

Sumber Utama

- Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.), O'Reilly, 2022
- Rahmad Syah, Pengantar Machine Learning: Teori dan Aplikasi dengan Python, Andi, 2021

Sumber Pendukung

- Andriy Burkov, The Hundred-Page Machine Learning Book, 2019
- Ian Goodfellow et al., Deep Learning, MIT Press, 2016
- Jake VanderPlas, Python Data Science Handbook, O'Reilly, 2016

Materi diperkaya dari CS189/289 UC Berkeley - Lecture 3 dan Lecture 10: Logistic Regression (1).