


The background of the slide is a complex network diagram. It consists of numerous nodes of varying sizes and colors (dark blue, light blue, and grey) connected by thin, light grey lines. Some nodes are highlighted with larger, concentric circles. The overall aesthetic is modern and technological.

PENGANTAR DATA SCIENCE

Data science

1. PENGANTAR DATA SCIENCE

Apa itu Data Science?

Data Science adalah bidang interdisipliner yang menggunakan metode ilmiah, proses, algoritma, dan sistem untuk mengekstrak pengetahuan dan wawasan dari data terstruktur maupun tidak terstruktur.

Komponen Utama:

- **Statistika** - Analisis dan interpretasi data
- **Pemrograman** - Implementasi algoritma
- **Domain Knowledge** - Pemahaman bidang spesifik
- **Machine Learning** - Pembelajaran otomatis dari data

Proses Data Science:

Pengumpulan Data


Pembersihan Data

Eksplorasi Data

Pemodelan

Evaluasi

Deployment



2. MENGAPA MENGGUNAKAN DATA SCIENCE?

- **Pengambilan Keputusan Berbasis Data**

- Membuat keputusan yang objektif berdasarkan data, bukan intuisi semata

- **Menemukan Pola Tersembunyi**

- Mengidentifikasi tren dan pola yang tidak terlihat dengan analisis manual

- **Efisiensi Operasional**

- Mengoptimalkan proses bisnis dan meningkatkan produktivitas

- **Inovasi Produk**


- Mengembangkan produk dan layanan baru berdasarkan insight data

- **Prediksi Masa Depan**

- Membangun model prediktif untukantisipasi tren mendatang

- **Personalisasi**

- Memberikan pengalaman yang dipersonalisasi untuk setiap pengguna



3. SIAPA ITU DATA SCIENTIST?

A. DEFINISI DAN RUANG LINGKUP DATA SCIENCE

Data Scientist adalah profesional yang menggabungkan keahlian statistik, pemrograman, dan pengetahuan bisnis untuk menganalisis data kompleks dan menghasilkan insight yang dapat ditindaklanjuti.

B. DATA, INFORMASI, PENGETAHUAN, DAN KEBIJAKSANAAN (DIKW HIERARCHY)

DATA

Fakta mentah, angka, teks, atau simbol tanpa konteks

Contoh: 25, "Jakarta", 2024

INFORMASI

Data yang telah diproses dan diberi konteks

Contoh: Suhu Jakarta 25°C pada tahun 2024

PENGETAHUAN


Informasi yang dikombinasikan dengan pengalaman dan pemahaman

Contoh: Jakarta memiliki iklim tropis dengan suhu rata-rata 25°C

KEBIJAKSANAAN

Pengetahuan yang diaplikasikan dengan bijak untuk pengambilan keputusan

Contoh: Strategi adaptasi perubahan iklim untuk Jakarta



4. DATA SCIENCE DAN BUSINESS INTELLIGENCE

c. Mengubah Data Mentah Menjadi Sesuatu yang Bermakna
Proses Transformasi:

1. **Data Collection:** Mengumpulkan data dari berbagai sumber
2. **Data Cleaning:** Membersihkan dan memvalidasi data
3. **Data Analysis:** Menganalisis pola dan tren
4. **Insight Generation:** Menghasilkan wawasan yang dapat ditindaklanjuti
5. **Decision Making:** Menggunakan insight untuk keputusan strategis

A. PERBEDAAN DATA SCIENCE DAN BUSINESS INTELLIGENCE

DATA SCIENCE

- **Fokus:** Prediksi masa depan
- **Data:** Terstruktur & tidak terstruktur
- **Metode:** Machine Learning, AI
- **Output:** Model prediktif, algoritma
- **Pertanyaan:** "Apa yang akan terjadi?"
- **Skill:** Programming, statistik tingkat lanjut

BUSINESS INTELLIGENCE

- **Fokus:** Analisis data historis
- **Data:** Terstruktur (database)
- **Metode:** Query, reporting, dashboard
- **Output:** Laporan, visualisasi
- **Pertanyaan:** "Apa yang telah terjadi?"
- **Skill:** SQL, tools BI


B. LIFECYCLE

Data Science Lifecycle:

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling
5. Evaluation
6. Deployment
7. Monitoring

BI Lifecycle:

1. Requirement Analysis
2. Data Integration
3. Data Warehousing
4. Dashboard Creation
5. Report Generation
6. User Training
7. Maintenance



5. KELEBIHAN DAN KEKURANGAN DATA SCIENCE




KELEBIHAN

- **Pengambilan Keputusan Berbasis Bukti**
Keputusan didukung data objektif, bukan asumsi
- **Prediksi Akurat**
Model ML dapat memprediksi tren dengan tingkat akurasi tinggi
- **Otomatisasi Proses**
Mengotomatisasi tugas berulang dan kompleks
- **Identifikasi Peluang Baru**
Menemukan insight tersembunyi untuk inovasi
- **Efisiensi Operasional**
Optimasi resource dan pengurangan biaya
- **Personalisasi**
Memberikan pengalaman yang disesuaikan



KEKURANGAN

- **Kompleksitas Tinggi**
Membutuhkan keahlian teknis yang mendalam
- **Ketergantungan pada Data**
Kualitas output tergantung kualitas input data
- **Biaya Implementasi Tinggi**
Investasi besar untuk infrastruktur dan SDM
- **Isu Privasi dan Etika**
Risiko penyalahgunaan data pribadi
- **Black Box Problem**
Sulit menjelaskan cara kerja model ML
- **Overfitting**
Model terlalu spesifik pada data training



6. ALAT YANG DIBUTUHKAN DALAM DATA SCIENCE



Bahasa Pemrograman

Python: Syntax sederhana, library lengkap (pandas, scikit-learn, TensorFlow)

R: Fokus statistik dan visualisasi data

Big Data Processing

Framework untuk penyimpanan dan pemrosesan dataset besar secara terdistribusi

Komponen: HDFS, MapReduce, YARN

Database Management

Bahasa query untuk mengakses dan memanipulasi data dalam database relasional

Essential untuk data extraction



Fast Data Processing

Engine pemrosesan data terdistribusi yang lebih cepat dari Hadoop MapReduce

Support untuk ML dan graph processing


Statistical Software

Platform analytics untuk statistical analysis, advanced analytics, dan business intelligence

Banyak digunakan di enterprise

Data Visualization



Tableau, Power BI, matplotlib, seaborn untuk membuat visualisasi data yang informatif



7. KETERAMPILAN YANG DIPERLUKAN DALAM DATA SCIENCE

A. KETERAMPILAN TEKNIS

- **Programming:** Python, R, SQL, Java
- **Statistics & Math:** Probabilitas, statistik, linear algebra
- **Machine Learning:** Supervised, unsupervised learning
- **Data Visualization:** Matplotlib, Tableau, D3.js



B. PEMAHAMAN DATA


- **Data Types:** Structured, semi-structured, unstructured
- **Data Quality:** Completeness, accuracy, consistency
- **Data Sources:** APIs, databases, files, web scraping
- **Data Ethics:** Privacy, bias, fairness

Supervised: Linear/Logistic Regression, Decision Trees, SVM

Unsupervised: K-means, Hierarchical Clustering, PCA

Deep Learning: Neural Networks, CNN, RNN

Ensemble: Random Forest, Gradient Boosting



D. PEMROGRAMAN



DATA MANIPULATION:
PANDAS, DPLYR, NUMPY



VERSION CONTROL:
GIT, GITHUB



CLOUD PLATFORMS:
AWS, GCP, AZURE



DEPLOYMENT: DOCKER,
KUBERNETES, APIS

E. ALAT ANALITIK

IDEs: Jupyter Notebook, RStudio, PyCharm

Databases: MySQL, PostgreSQL, MongoDB, Neo4j

Big Data: Spark, Hadoop, Kafka

BI Tools: Tableau, Power BI, Looker



F. MENGELOLA DATA TAK TERSTRUKTUR

Data Tidak Terstruktur

Universitas ini memiliki 5600 mahasiswa. Baskara (Nomor Mahasiswa: 160801), prodi Komunikasi berusia 18 tahun. Alka dengan nomor mahasiswa 160802, mengambil jurusan Akuntansi dan berusia 20 tahun. Tasya dari prodi Psikologi, berusia 19 tahun nomor mahasiswanya 160803

Data Semi-Terstruktur

```
<Universitas>
<Nomor="160801">
  <Nama="Baskara">
    <Usia="18">
      <Prodi="Komunikasi">
        <Nomor="160802">
          <Nama="Alka">
            <Usia="20">
              <Prodi="Akuntansi">
                .....
              </Universitas>
```

Data Terstruktur


Nomor	Nama	Usia	Prodi
160801	Baskara	18	Komunikasi
160802	Alka	20	Akuntansi
160803	Tasya	19	Psikologi

Text Mining: NLP, sentiment analysis, topic modeling

Image Processing: OpenCV, PIL, computer vision

Audio/Video: Speech recognition, multimedia analysis

Web Data: Web scraping, API integration



8. APLIKASI DATA SCIENCE

A. DETEKSI RISIKO DAN PENIPUAN

Aplikasi:

Credit scoring dan risk assessment

Fraud detection dalam transaksi keuangan

Anti-money laundering (AML)

Insurance fraud detection

Teknik: Anomaly detection, classification algorithms, network analysis

B. KESEHATAN

Aplikasi:

Diagnosis penyakit berbasis AI

Medical imaging analysis

Epidemic modeling dan forecasting

Personalized medicine

Teknik: Computer vision, predictive modeling, deep learning

C. GENETIKA DAN GENOMIK

Aplikasi:

DNA sequencing analysis

Gene expression profiling

Personalized therapy

Disease susceptibility prediction

Teknik: Bioinformatics algorithms, sequence analysis, statistical genetics

D. PENGEMBANGAN OBAT

Aplikasi:

Drug discovery dan screening

Clinical trial optimization

Molecular modeling

Toxicity prediction

Teknik: Cheminformatics, molecular dynamics, QSAR modeling

MESIN PENCARIAN INTERNET

Every search engine uses various data signs to provide the user with the best results of any quer

REKOMENDASI WEBSITE

users or customers to improve their experience

such as Netflix, Amazon, IMDB and Twitter, use historical data

PENGENALAN GAMBAR

suggestion to tag your friends in the picture based on your previous pictures

Google also allows you to search for some images by uploading specific images.



VISUAL ASSISTANCE

patients visit doctors virtually

chatbots on different websites



SPEECH RECOGNITION

Siri, Cortana, Google voice and other voice assistant products

Speech recognition

PENJADWALAN RUTE PESAWAT TERBANG

Predict delays in flights

Decide the type of aircraft to use or buy

Determine which flight you should suggest to a customer without any halt or stop

Developing customer loyalty programs

GAMING

Bagianaman user bermain game


EA Sports, Sony, Zynga and Nintendo



AUGMENTED REALITY

Virtual Reality Headset

Virtual Reality Glasses



BIG DATA & DATA SCIENCE




BIG DATA ??

Big data adalah Kumpulan data yang sangat besar, kompleks, dan terus bertambah setiap waktu.

Sumber :

- Aktivitas internet
- Informasi dari berbagai sensor, transaksi pribadi/bisnis




SEJARAH INDUSTRI 4.0

Revolusi Industri 1.0: Penemuan mesin uap (1760-1840) menggantikan tenaga manual, mempercepat produksi di berbagai sektor.

Revolusi Industri 2.0: Tenaga listrik dan assembly line (1870-an) buat produksi massal lebih efisien, terutama saat Perang Dunia II.

Revolusi Industri 3.0: Komputer dan otomasi (1970-an) mulai menggantikan peran manusia, memicu digitalisasi industri.

Revolusi Industri 4.0: Teknologi internet, AI, IoT, dan data analytics mengotomatiskan produksi dan distribusi dengan fokus keberlanjutan.



Industri 4.0 dicirikan oleh penggunaan teknologi canggih seperti:

Internet of Things (IoT)



Artificial Intelligence (AI)

Robotika

Cloud System

Machine Learning

Teknologi nirkabel generasi kelima (5G).



DATA SCIENCE & DATA MINING

Data Mining adalah tentang menemukan tren dalam kumpulan data dan menggunakan pola tersebut untuk mengidentifikasi langkah apa yang harus diambil


Data science adalah bidang studi yang mencakup segala hal mulai dari big data, data mining, pemodelan, visualisasi, matematika statistik dan komputasi

PEMBANDING	DATA MINING	DATA SCIENCE
Konteks	Sebuah teknik	Area / keilmuan
Fokus	Proses bisnis (fokus ke prosesnya)	Studi ilmiah (fokus ke konteks keilmuan data)
Goal (long-term)	Memberi manfaat kepada data yang ada	Membangun solusi data terpusat untuk perusahaan/organisasi
Output	Pola / patterns	Berbagai macam
Tujuan (short-term)	Mencari tren dari data yang sebelumnya belum diketahui	Social analysis, membangun predictive models, menggali fakta yang tidak diketahui, dan banyak lagi
Keahlian yang diperlukan	Seseorang dengan pengetahuan tentang data, teknik statistik, dan proses pengambilan data	Seseorang yang memahami machine learning, programming, teknik visualisasi, statistik, deep learning, dan pengetahuan tentang proses bisnis di lapangan
Ringkasan	Data mining dapat menjadi bagian dari data science, di mana mining adalah bagian dari urutan proses (pipeline) data science	Multidisiplin – data science terdiri dari data visualizations, computational social sciences, statistics, data mining, data engineer, natural language processing, machine learning, dll
Tipe data yang diolah	Kebanyakan structured	Semua tipe data – structured, semi-structured and unstructured
Nama lain yang kurang populer	Data archaeology, information harvesting, information discovery, knowledge extraction	Data-driven science



DATA SCIENCE TIMELINE

v. 2.0



@favioaz
@heizelvazquez




Big Data

VS




Traditional Data



MACHINE LEARNING




MACHINE LEARNING



SEJARAH MACHINE LEARNING

4. Basic Machine Learning / **Excursion: A (very) Brief History of AI** Machine Learning Timeline



LOEARNING UNTUK KLOMPUTER

Berdasarkan Teknik pembelajaran komputer dikelompokkan menjadi 4

1. supervised learning
2. unsupervised learning
4. Reinforcement learning

Learning phase

1. training data
- 2 Feature vektor
3. Algorith
4. model

THE DATA SCIENCE **HIERARCHY OF NEEDS**

LEARN/OPTIMIZE

AGGREGATE/LABEL

EXPLORE/TRANSFORM

MOVE/STORE

COLLECT

