

Tugas Terstruktur 1

Analisis Awal Dataset: Konteks, Kualitas, dan Perumusan Masalah

Mata Kuliah Data Science (TI24425) · 3 sks (Teori) **Program Studi** Teknologi Informasi · Politeknik Negeri Madiun **Semester** Genap · Tahun Akademik 2026/2027 **Cakupan materi** Pertemuan 1, 2, dan 3 **Bobot** 4% dari nilai akhir **Bentuk** Kerja kelompok, tiga orang

Identitas Kelompok

Nama Lengkap	NPM	Peran	Bagian yang Dikerjakan
1		Analisis Konteks dan Etika	Bagian A
2		Analisis Kualitas Data	Bagian B
3		Perancang Learning Problem	Bagian C

Kelas

Judul dataset

Penyedia data

Tautan Google Dataset Search

Tanggal pengumpulan

Petunjuk Pengerjaan

Sebelum mulai, baca seluruh bagian ini.

1. Memilih dataset

Cari dataset melalui **Google Dataset Search** di <https://datasetsearch.research.google.com/>.

Ketentuan dataset:

- Berformat CSV dan dapat diunduh secara langsung.
- Berukuran sekurang-kurangnya **300 baris** dan **5 kolom**, dengan campuran kolom numerik dan kategorik.

- Memiliki **lisensi yang jelas** dan memperbolehkan penggunaan untuk keperluan pendidikan.
- **Diutamakan** berdomain transportasi berkelanjutan atau layanan publik, sesuai capaian pembelajaran program studi.
- **Tidak boleh sama** dengan kelompok lain. Daftarkan pilihan Anda kepada dosen sebelum mulai mengerjakan.
- **Dilarang** memakai dataset yang memuat data pribadi yang dapat mengidentifikasi individu tanpa anonimisasi.

2. Cara mengerjakan

- Setiap anggota mengerjakan **satu bagian** sesuai perannya, lalu **Bagian D dikerjakan bersama**.
- Sel bertanda `[KODE]` diisi dengan kode Python. Sel bertanda `[URAIAN]` diisi dengan tulisan Anda sendiri.
- **Kode yang berjalan tanpa uraian tidak memperoleh nilai**. Yang dinilai adalah penalaran Anda, bukan keluaran programnya.
- Jangan menghapus sel pertanyaan. Tulis jawaban tepat di bawahnya.

3. Cara menyimpan sebagai PDF

1. Jalankan seluruh sel dari atas ke bawah: menu **Run → Run All Cells**.
2. Pastikan tidak ada sel yang menghasilkan pesan galat.
3. Pilih **File → Print** (atau tekan `Ctrl + P`), lalu pilih tujuan **Save as PDF**.
4. Beri nama berkas: `TT1_<Kelas>_<NamaKelompok>.pdf`
5. Unggah berkas PDF **dan** berkas `.ipynb` ke LMS.

4. Catatan tentang status kode

Mata kuliah ini adalah mata kuliah teori. Kegiatan berbasis komputer pada tugas ini berlangsung di luar jam tatap muka sebagai **Penugasan Terstruktur**. Kode yang diminta di sini sengaja dibuat sederhana dan dapat dikerjakan dengan menyalin lalu menyesuaikan nama kolom. **Yang dinilai tetap kualitas analisis, bukan kerumitan kodenya**.

5. Penggunaan AI generatif

Diperbolehkan sebagai alat bantu, dengan syarat dicantumkan pada Lampiran di akhir berkas ini: bagian mana yang dibantu dan bagaimana hasilnya Anda verifikasi. Menyerahkan keluaran AI tanpa verifikasi dan tanpa pengakuan diperlakukan sebagai pelanggaran akademik.

Persiapan

Sel di bawah ini menyiapkan pustaka yang diperlukan. Jalankan sekali di awal.

```
In [ ]: # [KODE] Persiapan pustaka – jalankan apa adanya
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

pd.set_option('display.max_columns', 50)
pd.set_option('display.width', 120)
plt.rcParams['figure.figsize'] = (8, 4)
plt.rcParams['figure.dpi'] = 110
plt.rcParams['axes.grid'] = True
plt.rcParams['grid.alpha'] = 0.3

print('Pustaka siap. Versi pandas:', pd.__version__)
```

Memuat dataset

Isi variabel di bawah ini sesuai dataset kelompok Anda, lalu jalankan selnya.

```
In [ ]: # [KODE] Isi bagian ini sesuai dataset kelompok Anda
NAMA_BERKAS = 'nama_berkas_dataset.csv' # letakkan berkas CSV di folder
PEMISAH      = ','                      # ganti menjadi ';' bila datas

df = pd.read_csv(NAMA_BERKAS, sep=PEMISAH)

print('Jumlah baris :', df.shape[0])
print('Jumlah kolom :', df.shape[1])
df.head()
```

Bagian A — Konteks, Sumber, dan Etika

Dikerjakan oleh Anggota 1 • Analisis Konteks dan Etika Materi rujukan: Pertemuan 1

Bagian ini tidak memerlukan kode. Yang dinilai adalah ketelitian menelusuri asal-usul data dan kejujuran menilai risikonya.

A.1 Identitas dan Legalitas Dataset

Isi tabel berikut berdasarkan halaman sumber dataset, **bukan** berdasarkan dugaan. Bila suatu informasi tidak tersedia, tulis "tidak dicantumkan sumber"

— jangan dikosongkan.

Butir	Isian
Judul dataset	
Lembaga atau perorangan penyedia	
Tahun data dikumpulkan	
Tautan halaman asli (bukan tautan unduhan)	
Lisensi	
Apakah lisensi memperbolehkan penggunaan pendidikan?	
Bagaimana data dikumpulkan (survei, sensor, catatan administrasi, lainnya)	
Satuan tiap baris data mewakili apa	

[URAIAN A.1] Jelaskan dalam 3-5 kalimat: apa yang sebenarnya diukur oleh dataset ini, dan siapa yang berkepentingan atas datanya?

Tulis jawaban Anda di sini.

A.2 Peran Data Science pada Sektor Ini

Pada pertemuan 1 kita membahas bahwa enam sektor yang berbeda hanya memakai tiga bentuk masalah yang sama: peramalan angka, klasifikasi, dan penemuan pola.

[URAIAN A.2] Jawab ketiga pertanyaan berikut.

1. Termasuk sektor apa dataset ini, dan keputusan nyata apa yang dapat dibantu olehnya?
2. Siapa pengguna hasil analisis ini, dan tindakan apa yang mungkin mereka ambil berdasarkan hasilnya?
3. Bila dataset ini bukan berdomain transportasi, jelaskan padanan persoalannya seandainya diterapkan pada layanan transportasi publik.

Tulis jawaban Anda di sini.

A.3 Telaah Privasi dan Data Pribadi

Rujuk Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi sebagaimana dibahas pada pertemuan 1.

[URAIAN A.3] Periksa seluruh kolom dataset, lalu isi tabel berikut.

Nama kolom	Termasuk data pribadi? (umum / spesifik / bukan)	Alasan

Kemudian jawab:

1. Apakah ada kombinasi beberapa kolom yang **bersama-sama** dapat mengenali seseorang, meskipun tidak ada satu pun kolom berisi nama? Sebutkan kombinasinya.
2. Bila ada, langkah pengurangan ketelitian apa yang Anda usulkan? (Rujuk pembahasan batas anonimisasi pada pertemuan 1.)
3. Bila tidak ada sama sekali, jelaskan dasar Anda menyimpulkan demikian.

Tulis jawaban Anda di sini.

A.4 Telaah Bias

Pada pertemuan 1 dibahas empat sumber bias: **historis**, **keterwakilan**, **pengukuran**, dan **umpan balik**.

[URAIAN A.4] Untuk dataset Anda, isi tabel berikut. Cukup isi sumber bias yang memang relevan; tulis "tidak relevan" beserta alasannya untuk sisanya.

Sumber bias	Apakah ada pada dataset ini?	Bukti atau dugaan Anda	Siapa yang berpotensi dirugikan
Historis			
Keterwakilan			
Pengukuran			
Umpan balik			

Tulis jawaban tambahan Anda di sini.

A.5 Enam Pertanyaan Pemeriksa

Jawab keenam pertanyaan pemeriksa dari pertemuan 1. Jawaban satu kalimat sudah memadai, tetapi harus spesifik terhadap dataset Anda — jawaban umum tidak memperoleh nilai.

No	Pertanyaan	Jawaban Anda
1	Siapa yang diuntungkan, dan siapa yang menanggung akibatnya?	
2	Apakah orang yang datanya dipakai mengetahui dan menyetujuinya?	
3	Kelompok mana yang kurang terwakili dalam data ini?	
4	Apa akibat terburuk bila model yang dibangun dari data ini keliru?	
5	Apakah keputusannya dapat dijelaskan kepada orang yang terdampak?	

No	Pertanyaan	Jawaban Anda
6	Bagaimana kekeliruan akan diketahui setelah model dipakai?	

[URAIAN A.5] Dari keenam pertanyaan di atas, mana yang paling sulit Anda jawab, dan mengapa?

Tulis jawaban Anda di sini.

Bagian B — Profil dan Kualitas Data

Dikerjakan oleh Anggota 2 · Analisis Kualitas Data Materi rujukan: Pertemuan 2

Bagian ini menggabungkan kode dan uraian. Setiap keluaran kode **wajib** disertai penafsiran.

B.1 Struktur Dasar

Jalankan sel di bawah, lalu tafsirkan hasilnya.

```
In [ ]: # [KODE] Struktur dasar dataset
print('Ukuran data :', df.shape)
print()
print('Tipe tiap kolom:')
print(df.dtypes)
print()
print('Nama kolom:')
print(list(df.columns))
```

[URAIAN B.1] Jelaskan struktur dataset ini: berapa baris dan kolom, kolom mana yang numerik dan mana yang kategorik, dan apakah tipe data yang terbaca sudah sesuai dengan arti kolomnya. Sebutkan bila ada kolom yang terbaca sebagai teks padahal seharusnya angka, atau sebaliknya.

Tulis jawaban Anda di sini.

B.2 Profil Kualitas Data

Sel di bawah menghitung enam ukuran deskriptif yang dibahas pada pertemuan 2, ditambah perhitungan nilai hilang dan nilai unik.

```
In [ ]: # [KODE] Profil kualitas data – jalankan apa adanya
profil = pd.DataFrame({
    'tipe' : df.dtypes.astype(str),
```

```

    'terisi'      : df.notna().sum(),
    'hilang'      : df.isna().sum(),
    'persen_hilang' : (df.isna().mean() * 100).round(2),
    'nilai_unik'  : df.nunique(),
})
profil['persen_unik'] = (profil['nilai_unik'] / len(df) * 100).round(2)
profil

```

```

In [ ]: # [KODE] Statistik deskriptif kolom numerik
df.describe().T.round(3)

```

```

In [ ]: # [KODE] Pemeriksaan duplikat
jml_dup_penuh = df.duplicated().sum()
print('Baris yang sama persis di seluruh kolom :', jml_dup_penuh)

# Ganti daftar di bawah dengan kolom penanda identitas pada dataset Anda
# Contoh: KOLOM_PENANDA = ['id_perjalanan'] atau ['tanggal', 'id_rute']
KOLOM_PENANDA = []

if KOLOM_PENANDA:
    jml_dup_penanda = df.duplicated(subset=KOLOM_PENANDA).sum()
    print('Baris dengan kombinasi penanda yang sama :', jml_dup_penanda)
else:
    print('KOLOM_PENANDA belum diisi. Isi terlebih dahulu, lalu jalankan

```

[URAIAN B.2] Berdasarkan ketiga keluaran di atas, isi tabel diagnosis berikut. Untuk tiap masalah, sebutkan **kolom mana** yang terdampak, **seberapa besar**, dan **akibatnya bila dibiarkan**.

Masalah kualitas	Ada / tidak	Kolom terdampak dan besarannya	Akibat bila dibiarkan
Nilai hilang			
Pencilan			
Duplikasi			
Ketidakseimbangan kelas			

Tulis jawaban tambahan Anda di sini.

B.3 Telaah Nilai Hilang

Pada pertemuan 2 dibahas tiga jenis nilai hilang: **hilang acak sepenuhnya**, **hilang acak bersyarat**, dan **hilang tidak acak**.

```

In [ ]: # [KODE] Kolom dengan nilai hilang terbanyak
hilang = profil[profil['hilang'] > 0].sort_values('persen_hilang', ascend
if len(hilang) == 0:
    print('Tidak ada nilai hilang pada dataset ini.')
else:
    print(hilang[['hilang', 'persen_hilang']])

```

[URAIAN B.3] Pilih **satu** kolom yang paling banyak nilai hilangnya, lalu jawab:

1. Menurut Anda termasuk jenis mana kekosongannya, dan apa dasar dugaan Anda?
2. Apa akibatnya bila kolom itu diisi begitu saja dengan rata-rata atau nol?
3. Apa penanganan yang Anda usulkan, dan mengapa?

Bila dataset Anda tidak memiliki nilai hilang sama sekali, jelaskan mengapa hal itu justru perlu dicurigai, dan bagaimana Anda memastikan bahwa kekosongan tidak disamarkan sebagai nilai lain (misalnya 0, -1, atau "tidak diketahui").

Tulis jawaban Anda di sini.

B.4 Visualisasi dan Penafsiran

Buat **dua** grafik yang berbeda jenis. Rujuk peta pemilihan grafik pada pertemuan 2: bentuk grafik dipilih berdasarkan pertanyaan yang ingin dijawab.

Sesuaikan nama kolom pada sel di bawah dengan dataset Anda.

```
In [ ]: # [KODE] Grafik 1 – sebaran satu kolom numerik (histogram)
        KOLOM_NUMERIK = 'ganti_dengan_nama_kolom_numerik'

        fig, ax = plt.subplots()
        ax.hist(df[KOLOM_NUMERIK].dropna(), bins=30, edgecolor='white')
        ax.set_xlabel(KOLOM_NUMERIK)
        ax.set_ylabel('Frekuensi')
        ax.set_title(f'Sebaran nilai {KOLOM_NUMERIK}')
        plt.tight_layout()
        plt.show()
```

```
In [ ]: # [KODE] Grafik 2 – pilih salah satu: boxplot, diagram batang, atau diagr
        # Contoh boxplot untuk melihat pencilan:
        fig, ax = plt.subplots()
        ax.boxplot(df[KOLOM_NUMERIK].dropna(), vert=False)
        ax.set_xlabel(KOLOM_NUMERIK)
        ax.set_title(f'Sebaran dan pencilan pada {KOLOM_NUMERIK}')
        plt.tight_layout()
        plt.show()
```

[URAIAN B.4] Untuk **setiap** grafik, jawab:

1. Pertanyaan apa yang hendak dijawab grafik ini, dan mengapa bentuk grafik itu yang dipilih?
2. Apa yang terlihat: apakah sebarannya menceng, apakah ada dua puncak, apakah ada pencilan?
3. Apa artinya temuan itu bagi rencana pemodelan?

Tulis jawaban Anda di sini.

B.5 Rencana Praproses

Susun rencana praproses beserta **alasannya**. Rencana tanpa alasan tidak memperoleh nilai penuh.

Kolom	Masalah yang ditemukan	Tindakan yang direncanakan	Alasan
-------	------------------------	----------------------------	--------

[URAIAN B.5] Jawab dua pertanyaan berikut.

1. Untuk kolom kategorik pada dataset Anda: apakah kategorinya **berjenjang** atau **tidak berjenjang**? Berdasarkan itu, encoding mana yang Anda pilih — one-hot atau ordinal — dan mengapa?
2. Apakah dataset Anda memerlukan penskalaan? Jawab dengan menyebut **model apa** yang direncanakan, karena kebutuhan penskalaan bergantung pada modelnya.

Tulis jawaban Anda di sini.

Bagian C — Learning Problem dan Pembagian Data

Dikerjakan oleh Anggota 3 · Perancang Learning Problem Materi rujukan: Pertemuan 3

C.1 Rumusan Learning Problem

Rumuskan learning problem untuk dataset kelompok Anda. Isi ketiga komponen yang dibahas pada pertemuan 3.

Komponen	Isian
Pertanyaan yang hendak dijawab (satu kalimat, spesifik dan terukur)	
Data — kolom apa saja yang menjadi x	
Data — kolom apa yang menjadi y	
Model — kandidat pertama	
Model — kandidat kedua sebagai pembanding	
Loss function yang dipilih	

[URAIAN C.1] Jelaskan mengapa loss function itu yang Anda pilih. Kaitkan dengan **biaya kesalahan** pada konteks masalah Anda: kesalahan seperti apa yang paling ingin dihindari?

Tulis jawaban Anda di sini.

C.2 Bentuk Masalah, Ruang Hipotesis, dan Bias Induktif

[URAIAN C.2] Jawab keempat pertanyaan berikut.

1. Termasuk **supervised** atau **unsupervised**? Sebutkan dasar penentuannya.
2. Termasuk bentuk masalah apa: regresi, klasifikasi biner, klasifikasi multi-kelas, clustering, atau reduksi dimensi?
3. Untuk **kandidat model pertama** Anda, definisikan **ruang hipotesisnya**. Contoh rumusan: "seluruh fungsi berbentuk $f(x) = w^T x + b$ dengan norma w terbatas", atau "seluruh pohon keputusan dengan kedalaman maksimum 8".
4. **Bias induktif** apa yang ikut terbawa oleh pilihan model itu? Apakah asumsi tersebut masuk akal untuk data Anda? Jelaskan.

Tulis jawaban Anda di sini.

C.3 Rancangan Pembagian Data

Sebelum menjalankan sel di bawah, tentukan lebih dulu skema pembagian yang **tepat** untuk dataset Anda. Rujuk pembahasan pertemuan 3 tentang tiga situasi khusus: data tidak seimbang, data deret waktu, dan data berkelompok.

Butir	Isian
Skema yang dipilih (acak / stratified / berdasarkan waktu / group)	
Alasan pemilihan skema	
Proporsi latih : validasi : uji	
Kolom penentu pembagian (bila stratified atau group)	

```
In [ ]: # [KODE] Pembagian data – sesuaikan dengan skema yang Anda pilih
from sklearn.model_selection import train_test_split

KOLOM_TARGET = 'ganti_dengan_nama_kolom_target'

X = df.drop(columns=[KOLOM_TARGET])
y = df[KOLOM_TARGET]

# ---- Pilih SALAH SATU skema di bawah ini, beri tanda pagar pada yang ti
```

```

# Skema 1 – acak biasa
X_sisa, X_uji, y_sisa, y_uji = train_test_split(
    X, y, test_size=0.20, random_state=42)

# Skema 2 – stratified (untuk klasifikasi dengan kelas tidak seimbang)
# X_sisa, X_uji, y_sisa, y_uji = train_test_split(
#     X, y, test_size=0.20, random_state=42, stratify=y)

# Skema 3 – berdasarkan waktu (data deret waktu; JANGAN diacak)
# df_urut = df.sort_values('ganti_dengan_kolom_tanggal')
# batas = int(len(df_urut) * 0.80)
# latih_val, uji = df_urut.iloc[:batas], df_urut.iloc[batas:]

# ---- Pisahkan sisanya menjadi latih dan validasi ----
X_latih, X_val, y_latih, y_val = train_test_split(
    X_sisa, y_sisa, test_size=0.25, random_state=42)

print('Jumlah baris data latih      :', len(X_latih))
print('Jumlah baris data validasi  :', len(X_val))
print('Jumlah baris data uji       :', len(X_uji))
print()
print('Proporsi : {:.0f} : {:.0f} : {:.0f}'.format(
    len(X_latih)/len(df)*100, len(X_val)/len(df)*100, len(X_uji)/len(df)*

```

```

In [ ]: # [KODE] Periksa apakah proporsi kelas tetap terjaga (khusus masalah klas
# Lewati sel ini bila masalah Anda berupa regresi atau clustering.
try:
    banding = pd.DataFrame({
        'seluruh_data' : y.value_counts(normalize=True).round(3),
        'data_latih'    : y_latih.value_counts(normalize=True).round(3),
        'data_uji'      : y_uji.value_counts(normalize=True).round(3),
    })
    print(banding)
except Exception as e:
    print('Sel ini dilewati:', e)

```

[URAIAN C.3] Jawab dua pertanyaan berikut.

1. Apakah proporsi kelas pada data latih dan data uji tetap terjaga? Bila tidak, apa akibatnya dan bagaimana memperbaikinya?
2. Seandainya dataset Anda berupa data deret waktu tetapi tetap dibagi secara acak, apa tepatnya yang akan salah? Jelaskan mekanismenya, bukan sekadar menyebut istilahnya.

Tulis jawaban Anda di sini.

C.4 Audit Kebocoran Data

Pada pertemuan 3 dibahas empat sumber kebocoran data. Periksa rancangan kelompok Anda sendiri terhadap keempatnya.

Sumber kebocoran	Berisiko pada rancangan kami?	Bukti atau alasan	Tindakan pencegahan
Praproses dijalankan sebelum pembagian			
Ada fitur yang memuat jawaban			
Baris kembar tersebar di dua sisi			
Data uji dilihat berkali-kali			

[URAIAN C.4] Periksa **setiap kolom** yang Anda pakai sebagai **x**, lalu jawab: adakah kolom yang nilainya baru tersedia **setelah** kejadian yang hendak diprediksi berlangsung? Sebutkan kolomnya dan jelaskan mengapa kolom itu harus dibuang.

Bila menurut Anda tidak ada satu pun, tuliskan dasar pemeriksaan Anda — jangan hanya menulis "tidak ada".

Tulis jawaban Anda di sini.

C.5 Urutan Kerja yang Sahih

[URAIAN C.5] Tuliskan urutan enam langkah kerja yang akan kelompok Anda tempuh, dari data mentah sampai angka kinerja akhir dilaporkan. Untuk setiap langkah, sebutkan **data mana** yang dipakai.

Langkah	Yang dikerjakan	Data yang dipakai
---------	-----------------	-------------------

1		
---	--	--

2		
---	--	--

3		
---	--	--

4		
---	--	--

5		
---	--	--

6		
---	--	--

Tulis catatan tambahan Anda di sini.

Bagian D — Sintesis Kelompok

Dikerjakan bersama oleh ketiga anggota.

Bagian ini menghubungkan ketiga bagian sebelumnya. Setiap anggota harus dapat menjelaskan seluruh isi bagian ini saat ditanya.

D.1 Ringkasan Temuan

[URAIAN D.1] Ringkas dalam bentuk tabel: tiga temuan terpenting dari seluruh analisis, beserta bagian mana yang menghasilkannya dan akibatnya bagi rencana kerja.

No	Temuan	Berasal dari bagian	Akibat bagi rencana kerja
1			
2			
3			

D.2 Keputusan dan Alasannya

[URAIAN D.2] Kelompok Anda telah mengambil sejumlah keputusan sepanjang tugas ini. Daftarkan **empat** keputusan yang paling menentukan, beserta alternatif yang tidak dipilih dan alasan penolakannya.

Keputusan yang diambil	Alternatif yang tidak dipilih	Alasan

D.3 Kelayakan Analisis

[URAIAN D.3] Jawab jujur ketiga pertanyaan berikut. Jawaban yang mengakui keterbatasan memperoleh nilai lebih tinggi daripada jawaban yang menutupinya.

1. Berdasarkan kualitas datanya, apakah pertanyaan yang Anda rumuskan pada C.1 **benar-benar dapat dijawab** dengan dataset ini? Bila tidak sepenuhnya, bagian mana yang tidak dapat dijawab?
2. Apa satu hal yang paling Anda khawatirkan dapat membuat hasil analisis ini menyesatkan?
3. Data tambahan apa yang paling ingin Anda miliki, dan mengapa data itu yang paling berharga?

Tulis jawaban Anda di sini.

D.4 Pembagian Kerja dan Refleksi

Anggota	Bagian yang dikerjakan	Perkiraan waktu	Kesulitan terbesar yang dihadapi
1	Bagian A		
2	Bagian B		
3	Bagian C		
Bersama	Bagian D		

[URAIAN D.4] Tulis satu paragraf bersama: konsep dari pertemuan 1 sampai 3 mana yang **paling berbeda** dari yang Anda bayangkan sebelum mengerjakan tugas ini, dan apa yang mengubah pandangan Anda?

Tulis jawaban Anda di sini.

Lampiran — Pernyataan Penggunaan AI Generatif

Bagian yang dibantu	Nama alat	Bentuk bantuan	Cara kami memverifikasi

Dengan ini kami menyatakan bahwa seluruh analisis, justifikasi, dan kesimpulan dalam berkas ini merupakan hasil penalaran kelompok kami sendiri, dan seluruh bantuan alat AI generatif telah kami cantumkan secara jujur pada tabel di atas.

Anggota 1	Anggota 2	Anggota 3
(.....)	(.....)	(.....)

Rubrik Penilaian

Total 100 poin, dikonversi menjadi bobot 4% pada nilai akhir.

Bagian	Kriteria	Poin
A	Kelengkapan dan ketepatan identitas serta legalitas dataset	8
	Ketepatan menelaah data pribadi dan risiko re-identifikasi	9

Bagian	Kriteria	Poin
	Kedalaman telaah bias dan kekhususan jawaban enam pertanyaan pemeriksa	8
B	Ketepatan membaca struktur dan profil data	8
	Ketepatan mendiagnosis empat masalah kualitas beserta besarannya	10
	Ketepatan penalaran mengenai jenis nilai hilang	7
	Kesesuaian pilihan grafik dengan pertanyaan, dan mutu penafsirannya	8
	Kelayakan rencana praproses beserta alasannya	7
C	Ketajaman rumusan learning problem dan justifikasi loss function	9
	Ketepatan mendefinisikan ruang hipotesis dan bias induktif	8
	Kesesuaian skema pembagian data dengan sifat dataset	8
	Ketelitian audit kebocoran data	10
D	Mutu sintesis, kejujuran menilai kelayakan, dan refleksi	8
	Jumlah	100

Ketentuan penilaian

- **Kode yang berjalan tanpa uraian bernilai nol** untuk butir yang bersangkutan. Yang dinilai adalah penalaran.
- Jawaban umum yang dapat dipakai untuk dataset mana pun **tidak memperoleh nilai penuh**. Jawaban harus spesifik terhadap dataset kelompok Anda.
- Menyebut suatu prosedur keliru **tanpa menjelaskan mengapa** hanya memperoleh separuh poin.
- Mengakui keterbatasan secara jujur **menambah** nilai; menutupinya mengurangi nilai.
- Keterlambatan dikenakan pengurangan 10% nilai per hari kerja, maksimal tiga hari kerja.

Sumber rujukan

- Géron, A. (2022). *Hands-On Machine Learning*, edisi ke-3, Bab 2.
- VanderPlas, J. (2022). *Python Data Science Handbook*, edisi ke-2, bagian eksplorasi data.
- James, G. dkk. *An Introduction to Statistical Learning*, Bab 2.
- Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi.
- Materi kuliah pertemuan 1, 2, dan 3.