

TI24425

Anatomi Pipeline Data Science dan Kualitas Data

Pertemuan 2 · Sub-CPMK 2

Program Studi Teknologi Informasi · Politeknik Negeri Madiun

Di mana kita sekarang?

1

SELESAI

Pengantar & Etika Data

Kita sudah tahu apa itu Data Science dan batas etisnya.

2

HARI INI

Pipeline & Kualitas Data

Bagaimana data mentah menjadi layak dianalisis.

3

BERIKUTNYA

Learning Problem

Merumuskan masalah dan membagi data dengan benar.

Pertemuan lalu membahas apa yang boleh dan tidak boleh dilakukan dengan data. Hari ini kita menghadapi kenyataannya: data yang tersedia hampir tidak pernah siap pakai.

Setelah pertemuan ini Anda mampu...

1

Mengurutkan dan menjelaskan enam tahap pipeline Data Science beserta tujuan tiap tahap.

2

Mendiagnosis masalah kualitas data dari profil dataset yang disajikan.

3

Menjelaskan konsekuensi tiap masalah kualitas data terhadap kinerja model.

4

Menjelaskan alasan diperlukannya encoding dan penskalaan, serta urutan penerapannya.

5

Memilih bentuk visualisasi yang tepat untuk pertanyaan yang ingin dijawab.

DINILAI LEWAT DISKUSI KASUS

Bobot pertemuan ini 5% melalui komponen Aktivitas Partisipatif.



1

Anatomi Pipeline Data Science

Enam tahap yang dilewati setiap proyek data, tanpa kecuali

Enam tahap yang selalu dilewati



Sebelum satu model pun dilatih

1

Perumusan masalah

Menerjemahkan kebutuhan menjadi pertanyaan yang dapat dijawab data.

- Apa keputusan yang ingin dibantu?
- Siapa yang akan memakai hasilnya?
- Seperti apa keberhasilan diukur?

2

Pengumpulan data

Menentukan data apa yang diperlukan dan dari mana asalnya.

- Apakah data ini memang mengukur hal yang dimaksud?
- Siapa yang terlewat dari data ini?
- Apakah pengumpulannya sah dan beretika?

3

Praproses

Membuat data layak dipakai tanpa mengubah maknanya.

- Menangani nilai hilang dan pencilan
- Encoding variabel kategorik
- Penskalaan fitur numerik

Dari model menjadi keputusan

4

Pemodelan

Memilih dan melatih model yang sesuai dengan bentuk masalahnya.

Tahap ini paling sedikit memakan waktu, meski paling sering dibicarakan.

5

Evaluasi

Menilai kinerja model secara jujur pada data yang belum pernah dilihatnya.

Angka yang bagus belum tentu berarti model yang berguna.

6


Komunikasi hasil

Menerjemahkan angka menjadi penjelasan yang dapat ditindaklanjuti.

Analisis yang tidak dipahami pengguna sama nilainya dengan analisis yang tidak pernah dikerjakan.

ENAM TAHAP INI DIULANG BERKALI-KALI, BUKAN DIJALANKAN SEKALI DARI AWAL SAMPAI AKHIR

Ke mana waktu sebenarnya habis



Angka ini perkiraan kasar, bukan hasil pengukuran. Yang penting bukan angkanya, melainkan urutannya: tahap yang paling banyak menyita waktu justru tahap yang paling jarang dibicarakan.

2

Masalah Kualitas Data

Empat gangguan yang hampir selalu ada pada data nyata

Empat jenis gangguan yang harus dikenali

Nilai hilang

Missing value

Sebagian sel kosong. Modelnya tidak dapat menerima kekosongan, sehingga harus diisi atau barisnya dibuang.

Pencilan

Outlier

Nilai yang jauh menyimpang dari sebaran lainnya. Bisa berupa kesalahan, bisa pula kejadian nyata yang penting.

Duplikasi

Duplicate

Satu kejadian tercatat lebih dari sekali. Membuat model memberi bobot berlebih pada kejadian itu.

Ketidakseimbangan kelas

Class imbalance

Satu kelas jauh lebih sedikit daripada yang lain. Model belajar mengabaikan kelas minoritas.

KEEMPATNYA HARUS DITEMUKAN SEBELUM MODEL DILATIH, BUKAN SETELAH HASILNYA MENGECEWAKAN

Nilai hilang bukan satu jenis

Hilang acak sepenuhnya

Kekosongan tidak berhubungan dengan apa pun. Contoh: sensor mati beberapa jam karena listrik padam.

Paling aman. Boleh diisi rata-rata atau barisnya dibuang.

Hilang acak bersyarat

Kekosongan berhubungan dengan kolom lain yang terekam. Contoh: penumpang muda lebih jarang mengisi kolom pekerjaan.

Masih dapat ditangani, asalkan kolom penjelasnya ikut dipakai.

Hilang tidak acak

Kekosongan berhubungan dengan nilainya sendiri. Contoh: penumpang berpenghasilan tinggi enggan mengisi kolom penghasilan.

Paling berbahaya. Mengisi begitu saja akan memiringkan seluruh kesimpulan.

Pertanyaan yang wajib diajukan: mengapa data ini hilang? Jawabannya menentukan cara menanganinya — dan tidak dapat ditemukan hanya dengan melihat angkanya.

Pencilan: kesalahan atau kejadian nyata?

PERIKSA ULANG

Pencilan karena kesalahan

- Waktu tempuh bus tercatat 9.999 menit
- Jumlah penumpang bernilai negatif
- Tanggal keberangkatan tahun 1900

Tindakan: perbaiki bila memungkinkan, atau buang barisnya disertai catatan.

JANGAN DIBUANG

Pencilan yang benar-benar terjadi

- Keterlambatan 3 jam karena banjir
- Lonjakan penumpang saat hari raya
- Satu rute yang memang jauh lebih panjang

Tindakan: pertahankan. Justru kejadian seperti inilah yang sering paling penting dipelajari.

Membedakan keduanya tidak dapat dilakukan dengan rumus

Aturan seperti “buang nilai di luar tiga simpangan baku” hanya menandai calon pencilan. Menentukan mana yang kesalahan dan mana yang kejadian nyata menuntut pemahaman terhadap bidangnya — bukan perhitungan.

Duplikasi dan ketidakseimbangan kelas

DUPLIKASI

Satu kejadian, dua catatan

Duplikat jarang berupa baris yang persis sama. Lebih sering berupa dua catatan yang sedikit berbeda untuk kejadian yang sama.

- Akibatnya model memberi bobot berlebih pada kejadian yang terduplikasi
- Bila satu salinan masuk data latih dan salinan lain masuk data uji, terjadi kebocoran data
- Ditemukan dengan memeriksa kombinasi kolom penanda, bukan seluruh baris

KETIDAKSEIMBANGAN KELAS

Ketika satu kelas nyaris tidak ada

Contoh: dari 10.000 perjalanan, hanya 120 yang tercatat terlambat berat. Perbandingannya sekitar satu banding delapan puluh.

- Model dapat mencapai akurasi 98,8% hanya dengan selalu menjawab “tidak terlambat”
- Kelas minoritas justru sering yang paling penting dideteksi
- Ditangani dengan pemilihan metrik yang tepat, bukan dengan mengganti algoritma

Diagnosis profil sebuah dataset

BERPASANGAN · 15 MENIT · TANPA KOMPUTER

Berikut ringkasan profil dataset perjalanan bus kota. Temukan seluruh masalah kualitas datanya.

Kolom	Jumlah terisi	Nilai minimum	Rata-rata	Nilai maksimum	Nilai unik
id_perjalanan	10.000	—	—	—	9.940
jarak_km	10.000	2,1	11,4	18,7	842
jumlah_penumpang	9.980	-3	46,2	5.100	318
menit_keterlambatan	7.240	0	8,6	184	176
jenis_armada	10.000	—	—	—	3
status_terlambat	10.000	—	—	—	2 (ya: 120)

Empat masalah tersembunyi di tabel ini. Temukan keempatnya dan jelaskan akibatnya.

Petunjuk: bandingkan jumlah terisi antar-kolom, periksa nilai yang mustahil, dan perhatikan kolom paling kanan.

3

Konsep Praproses

Menyesuaikan bentuk data tanpa mengubah maknanya

Encoding variabel kategorik

Model hanya menerima angka. Kolom seperti jenis armada atau nama koridor harus diubah lebih dulu — dan cara mengubahnya menentukan apa yang bisa dipelajari model.

One-Hot Encoding

Tiap nilai menjadi kolom sendiri berisi 0 atau 1.

```
armada_kecil, armada_sedang,  
armada_besar
```

Untuk kategori tanpa urutan. Aman, tetapi jumlah kolom membengkak bila kategorinya banyak.

Ordinal Encoding

Tiap nilai diberi angka berurutan.

```
kecil = 1, sedang = 2, besar = 3
```

Hanya untuk kategori yang memang berjenjang. Salah pakai membuat model mengira ada jarak antar-kategori.

Target Encoding

Kategori diganti rata-rata nilai target pada kategori itu.

```
koridor A = 0,32 (rata-rata  
keterlambatan)
```

Hemat kolom, tetapi sangat rawan kebocoran data bila dihitung sebelum data dibagi.

MEMILIH ENCODING BERARTI MEMUTUSKAN APAKAH KATEGORI PUNYA URUTAN ATAU TIDAK

Penskalaan dan alasan diperlukannya

Masalahnya

Jarak rute bernilai 2 sampai 19 kilometer. Jumlah penumpang bernilai 5 sampai 300 orang. Bila keduanya dipakai bersamaan, kolom penumpang akan mendominasi seluruh perhitungan jarak semata-mata karena angkanya lebih besar.

Yang terdampak

- Model berbasis jarak: K-Means, K-Nearest Neighbors
- Model dengan regularisasi: Ridge, Lasso, logistic regression
- Neural network — pelatihannya jauh lebih lambat tanpa penskalaan

1 Standardisasi

Mengubah tiap kolom agar rata-ratanya nol dan simpangan bakunya satu.

Dipakai saat sebaran data mendekati normal dan pencilan sudah ditangani.

2 Normalisasi Min-Max

Memetakan seluruh nilai ke rentang nol sampai satu.

Dipakai saat batas atas dan bawah diketahui pasti dan bermakna.

3 Tahan pencilan

Memakai median dan rentang antar-kuartil, bukan rata-rata.

Dipakai saat pencilan memang nyata dan tidak boleh dibuang.

Model berbasis pohon tidak memerlukan penskalaan sama sekali — ia hanya membandingkan nilai, bukan menghitung jarak.

Urutan yang benar, dan mengapa penting

URUTAN YANG KELIRU

- 1 Hitung rata-rata seluruh data
- 2 Isi nilai hilang
- 3 Skalikan seluruh kolom
- 4 Baru bagi data latih dan uji

Statistik dari data uji ikut terserap ke dalam model. Angka kinerjanya menjadi terlalu bagus dan tidak dapat dipercaya.

URUTAN YANG BENAR

- 1 Bagi data latih dan uji lebih dulu
- 2 Hitung statistik hanya dari data latih
- 3 Terapkan hasilnya ke data uji
- 4 Ulangi di dalam tiap lipatan cross-validation

Data uji tetap bersih. Angka kinerja yang dihasilkan mencerminkan keadaan sesungguhnya.

Inilah bentuk kebocoran data yang paling sering terjadi, dan dibahas tuntas pada pertemuan 9. Untuk sekarang cukup ingat satu aturan: bagi data lebih dulu, baru hitung apa pun.

4

Exploratory Data Analysis

Melihat data sebelum memodelkannya, dan menyampaikannya kepada orang lain

Apa yang sebenarnya dicari saat menjelajah data

1

Memahami bentuk data

Berapa baris dan kolom, tipe apa saja, dan apa arti tiap kolom sesungguhnya.

2

Menemukan kesalahan

Nilai mustahil, satuan yang bercampur, kategori yang tertulis berbeda untuk hal yang sama.

3

Melihat sebaran

Apakah nilai menumpuk di satu sisi, apakah ada dua puncak, seberapa jauh ekornya.

4

Memeriksa hubungan

Kolom mana yang bergerak bersama, dan apakah hubungan itu masuk akal.

5

Menguji dugaan awal

Apakah yang diyakini pengguna tentang datanya memang terlihat pada datanya.

6

Menentukan arah

Berdasarkan semua di atas: model seperti apa yang masuk akal dicoba.

Statistik deskriptif: apa yang ditunjukkan tiap angka

Ukuran	Menjawab pertanyaan	Yang harus diwaspadai
Jumlah terisi	Berapa banyak data yang benar-benar ada di kolom ini?	Selisih antar-kolom menandakan nilai hilang
Rata-rata	Di mana pusat sebarannya?	Sangat mudah ditarik oleh pencilan
Median	Di mana nilai tengahnya?	Selisih jauh dari rata-rata menandakan sebaran miring
Simpangan baku	Seberapa lebar sebarannya?	Nilai nol berarti kolom itu tidak bervariasi sama sekali
Minimum dan maksimum	Sampai di mana batas nilainya?	Nilai mustahil paling cepat terlihat di sini
Jumlah nilai unik	Berapa banyak nilai berbeda yang muncul?	Lebih sedikit dari jumlah baris menandakan duplikat

Enam angka ini sudah cukup untuk menemukan sebagian besar masalah kualitas data — sebelum satu grafik pun dibuat. Itulah sebabnya profil dataset selalu diperiksa lebih dulu.

Visualisasi sebagai alat komunikasi

Bentuk grafik dipilih berdasarkan pertanyaan yang ingin dijawab, bukan berdasarkan mana yang terlihat paling menarik.

Histogram

Bagaimana sebaran satu kolom numerik?

Menemukan kemencengan, dua puncak, dan ekor panjang.

Boxplot

Di mana pencilan berada?

Meringkas median, kuartil, dan calon pencilan sekaligus.

Diagram sebar

Bagaimana hubungan dua kolom numerik?

Melihat pola, kelompok, dan hubungan yang tidak lurus.

Diagram batang

Bagaimana perbandingan antar-kategori?

Membandingkan jumlah atau rata-rata antar-kelompok.

Diagram garis

Bagaimana perubahannya sepanjang waktu?

Melihat tren, musiman, dan lonjakan mendadak.

Peta panas korelasi

Kolom mana yang bergerak bersama?

Menemukan kolom yang saling menggantikan.

Grafik adalah bentuk komunikasi, bukan hiasan. Bila pembaca harus bertanya artinya, grafiknya belum selesai.

Empat temuan, empat keputusan

A

Kolom menit_keterlambatan kosong pada 27% baris. Tim mengisinya dengan angka nol karena “lebih aman”.

B

Ditemukan 60 baris dengan id_perjalanan sama persis. Tim membuang seluruhnya, termasuk salinan pertamanya.

C

Beberapa perjalanan tercatat terlambat lebih dari tiga jam. Tim membuangnya karena dianggap merusak sebaran.

D

Kolom jenis_armada diubah menjadi angka 1, 2, dan 3 agar bisa langsung dipakai model.

Untuk tiap keputusan: apakah tepat? Bila keliru, apa akibatnya dan apa yang seharusnya dilakukan?

Diskusi kelompok empat orang · 12 menit

Empat salah kaprah tentang penyiapan data



Praproses adalah pekerjaan teknis tanpa pertimbangan

Setiap keputusan praproses mengubah makna data. Mengisi nilai hilang berarti menyatakan sesuatu tentang data yang tidak ada.



Pencilan harus selalu dibuang

Pencilan sering justru kejadian yang paling penting. Membuangnya berarti membuang apa yang paling perlu diantisipasi.



Data yang bersih berarti data yang baik

Data dapat bersih sempurna tetapi tetap tidak mewakili kenyataan, karena kelompok tertentu tidak pernah masuk ke dalamnya.



EDA cukup dilakukan sekali di awal

Setiap temuan baru memunculkan pertanyaan baru. EDA berlangsung sepanjang proyek.

Yang perlu Anda bawa pulang



Enam tahap pipeline

Perumusan, pengumpulan, praproses, pemodelan, evaluasi, komunikasi.



Praproses menyita waktu terbanyak

Dan paling jarang dibicarakan.



Empat masalah kualitas

Nilai hilang, pencilan, duplikasi, ketidakseimbangan kelas.



Tanyakan mengapa data hilang

Jawabannya menentukan cara menanganinya.



Encoding menyatakan asumsi

Ordinal berarti Anda menyatakan ada urutan.



Bagi data lebih dulu

Baru hitung statistik apa pun untuk praproses.



Enam angka deskriptif

Sudah cukup menemukan sebagian besar masalah.



Grafik adalah komunikasi

Bila harus ditanya artinya, belum selesai.

Sebelum pertemuan berikutnya

BELAJAR MANDIRI

180 menit

Membaca VanderPlas [5] mengenai eksplorasi dan visualisasi data, serta Géron [1] Bab 2 bagian penyiapan data.

PENUGASAN TERSTRUKTUR

180 menit

Menyusun daftar periksa kualitas data berdasarkan profil dataset yang disediakan dosen. Menjadi bahan diskusi kelas pertemuan berikutnya.

Latihan ini bersifat formatif — tidak berbobot tersendiri. Kontribusi Anda saat pembahasan di kelas dinilai melalui komponen Aktivitas Partisipatif.

Catatan untuk Studi Kasus Akhir: bagian B.2 dan B.3 dokumen tugas meminta Anda memaparkan pemahaman data dan rencana praproses beserta alasannya. Materi hari ini adalah bekal langsungnya.

PERTEMUAN BERIKUTNYA

Learning Problem dan Pembagian Data

Hari ini kita membuat data layak dipakai. Pertemuan depan kita menentukan pertanyaan apa yang hendak dijawab dengannya — dan bagaimana membagi data agar jawabannya dapat dipercaya.