

SUB-CPMK 3

Elemen Learning Problem dan Pembagian Data

Program Studi Teknologi Informasi · Politeknik Negeri Madiun

Di mana kita sekarang?

2

SELESAI

Pipeline & Kualitas Data

Kita sudah bisa membuat data layak dipakai.

3

HARI INI

Learning Problem

Merumuskan pertanyaan dan membagi data dengan benar.

4

BERIKUTNYA

Regresi & Gradient Descent

Model pertama, dan cara mesin benar-benar belajar.

Data yang bersih belum berarti pertanyaannya benar. Hari ini kita merumuskan apa yang sebenarnya hendak dipelajari mesin, dan bagaimana membagi data agar jawabannya dapat dipercaya.

Setelah pertemuan ini Anda mampu...

- 01 Mengidentifikasi data, model, dan loss function pada suatu kasus yang diberikan.
- 02 Menjelaskan pengertian ruang hipotesis dan pengaruh bias induktif terhadap pilihan model.
- 03 Membedakan supervised dan unsupervised learning beserta bentuk masalah masing-masing.
- 04 Menjelaskan peran data latih, validasi, dan uji, serta aturan pemakaian ketiganya.
- 05 Menemukan dan mengoreksi sumber kebocoran data pada skenario yang disajikan.

01

Elemen Learning Problem

Tiga komponen yang selalu ada, apa pun modelnya

Apa artinya “belajar” bagi sebuah model?

BUKAN INI

Model tidak memahami apa pun. Ia tidak tahu apa itu bus, apa itu keterlambatan, atau mengapa hujan memperlambat perjalanan.

TETAPI INI

Model mencari satu fungsi yang memetakan masukan ke keluaran, dengan cara meminimalkan sebuah ukuran kesalahan pada contoh yang diberikan.

Definisi kerja yang akan kita pakai sepanjang semester

Sebuah learning problem adalah usaha menemukan fungsi f dari sekumpulan fungsi yang mungkin, sedemikian rupa sehingga f meminimalkan kesalahan pada data yang belum pernah dilihat.

Perhatikan tiga hal yang tersirat di dalamnya: ada kumpulan fungsi yang mungkin, ada ukuran kesalahan, dan yang dituju adalah data baru — bukan data yang sudah dipelajari.

Tiga komponen yang selalu ada

01

Data

Pasangan masukan dan keluaran yang menjadi contoh bagi model.

Dilambangkan (x, y) . Kualitasnya menentukan batas atas kemampuan model.

02

Model

Bentuk fungsi yang boleh dipilih untuk memetakan masukan menjadi keluaran.

Menentukan pola seperti apa yang mungkin ditangkap, dan mana yang mustahil.

03

Loss function

Ukuran yang menyatakan seberapa jauh tebakan model dari kenyataan.

Menentukan apa arti “lebih baik”.
Mengganti loss berarti mengganti tujuannya.

MENGGANTI SALAH SATU KOMPONEN BERARTI MENGUBAH MASALAHNYA, BUKAN SEKADAR MENGUBAH CARANYA

Ruang hipotesis: kumpulan fungsi yang boleh dipilih

Ketika Anda memilih sebuah model, sebenarnya Anda sedang memilih sekumpulan fungsi yang boleh dipertimbangkan. Kumpulan itulah yang disebut ruang hipotesis.

Regresi linier

Seluruh garis lurus
 $f(x) = wx + b$

Sangat sempit. Hanya hubungan lurus yang dapat ditangkap.

Polinomial derajat 5

Seluruh kurva berderajat sampai lima

Lebih luas. Dapat melengkung, tetapi masih terbatas bentuknya.

Decision tree kedalaman 10

Seluruh pohon aturan sampai sepuluh lapis

Jauh lebih luas. Dapat menangkap pola berpatah-patah.

Neural network besar

Hampir semua bentuk fungsi yang mulus

Sangat luas. Justru keluasan inilah yang membuatnya mudah menghafal.

Semakin luas ruang hipotesis, semakin banyak pola yang dapat ditangkap — dan semakin mudah pula model menghafal derau. Ini kembali dibahas pada pertemuan 5.

Bias induktif: asumsi yang dibawa sejak awal

Data latih tidak pernah cukup untuk menentukan satu fungsi secara tunggal. Selalu ada tak terhingga banyak fungsi yang cocok dengan data yang sama. Yang menentukan mana yang dipilih adalah asumsi bawaan model — itulah bias induktif.

- | | | |
|---|------------------------------|--|
| 1 | Regresi linier | Hubungan antar-variabel diasumsikan lurus. |
| 2 | Decision tree | Data dapat dipisah dengan aturan bertingkat pada satu fitur. |
| 3 | K-Nearest Neighbors | Data yang berdekatan cenderung punya label yang sama. |
| 4 | Convolutional network | Pola yang penting bersifat lokal dan berlaku di mana pun letaknya. |

Tidak ada model tanpa bias induktif. Memilih model berarti memilih asumsi — dan asumsi itu harus dapat Anda pertanggungjawabkan.

Loss function: menentukan apa arti “lebih baik”

Loss function menerjemahkan kesalahan menjadi satu angka yang dapat diperkecil. Memilih loss berarti menyatakan kesalahan mana yang paling ingin dihindari.

Regresi

Mean Squared Error

Menghukum galat besar jauh lebih berat daripada galat kecil.

Regresi

Mean Absolute Error

Memperlakukan semua galat setara.
Lebih tahan terhadap pencilan.

Klasifikasi

Cross-Entropy

Menghukum keyakinan tinggi yang ternyata keliru.

Contoh mengapa pilihan ini penting

Untuk memperkirakan waktu tempuh ambulans, meleset 30 menit jauh lebih berbahaya daripada meleset 3 menit sepuluh kali. Mean Squared Error mencerminkan hal itu; Mean Absolute Error tidak. Dua model dengan data yang sama persis akan menghasilkan jawaban berbeda hanya karena lossnya berbeda.

Satu kasus, tiga komponen lengkap

Kasus: memperkirakan berapa menit sebuah bus kota akan terlambat pada suatu perjalanan.

Data

x = jarak rute, jam berangkat, cuaca, jumlah halte
 y = menit keterlambatan yang tercatat
8.400 perjalanan selama satu tahun

Model

Regresi linier
 $f(x) = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + b$
Ruang hipotesis: seluruh bidang lurus

Loss function

Mean Squared Error
 $L = \text{rata-rata dari } (y - f(x))^2$
Galat besar dihukum lebih berat



Bias induktif yang ikut terbawa: dengan memilih regresi linier, kita menyatakan bahwa pengaruh tiap fitur bersifat lurus dan saling menjumlah. Bila kenyataannya tidak demikian — misalnya hujan hanya berpengaruh pada jam sibuk — model ini tidak akan pernah menangkapnya.

02

Supervised dan Unsupervised

Ada tidaknya kunci jawaban mengubah segalanya

Taxonomy of Machine Learning



Dua cara belajar dari data

Supervised Learning

Belajar dengan kunci jawaban

- Setiap baris data punya label y yang benar
- Model belajar memetakan x menjadi y
- Kinerja diukur dengan membandingkan tebakan dan label
- Ada jawaban benar untuk dijadikan acuan

Pertanyaannya: seberapa tepat tebakan saya?

Unsupervised Learning

Belajar tanpa kunci jawaban

- Tidak ada label sama sekali
- Model mencari struktur yang tersembunyi di dalam x
- Kinerja diukur dari kerapatan dan pemisahan kelompok
- Tidak ada jawaban benar untuk dijadikan acuan

Pertanyaannya: pola apa yang ada di sini?

Bentuk masalah dan contohnya

Bentuk masalah	Keluaran yang dicari	Contoh pada data transportasi	Dibahas
Regresi	Satu angka bebas	Berapa menit bus ini akan terlambat?	Pertemuan 4–5
Klasifikasi biner	Salah satu dari dua kelas	Apakah bus ini akan terlambat lebih dari 10 menit?	Pertemuan 6
Klasifikasi multi-kelas	Salah satu dari beberapa kelas	Tepat waktu, terlambat ringan, atau terlambat berat?	Pertemuan 7
Clustering	Kelompok tanpa nama	Rute mana saja yang berperilaku mirip?	Pertemuan 11
Reduksi dimensi	Bentuk data yang lebih ringkas	Bagaimana meringkas 40 kolom menjadi beberapa saja?	Pertemuan 13

Tiga baris pertama supervised, dua baris terakhir unsupervised. Menentukan bentuk masalah adalah langkah pertama — sebelum memilih algoritma apa pun. Salah menentukan bentuk masalah membuat seluruh pekerjaan berikutnya sia-sia.

03

Pembagian Data

Tiga himpunan dengan tugas yang berbeda-beda

Tiga himpunan, tiga tugas berbeda

Data Latih

± 60%

Tugasnya

Melatih parameter

Model melihat data ini berulang kali dan menyesuaikan bobotnya sampai lossnya kecil.

Data Validasi

± 20%

Tugasnya

Memilih hyperparameter

Dipakai berkali-kali untuk membandingkan pilihan model, kedalaman, dan kekuatan regularisasi.

Data Uji

± 20%

Tugasnya

Menaksir kinerja nyata

Dibuka satu kali saja, di akhir, setelah seluruh keputusan sudah final.

ATURAN EMAS

Setiap kali Anda melihat data uji lalu mengubah sesuatu berdasarkan apa yang Anda lihat, data uji itu berhenti menjadi data uji.

Berapa proporsinya, dan kapan dibaginya

Proporsi bergantung ukuran data

- Data kecil, di bawah 10 ribu baris **60 : 20 : 20 • atau pakai cross-validation**
- Data sedang **70 : 15 : 15**
- Data sangat besar, jutaan baris **98 : 1 : 1 sudah memadai**

Kapan pembagian dilakukan

Paling awal, sebelum apa pun dihitung. Rata-rata untuk mengisi nilai hilang, simpangan baku untuk penskalaan, dan daftar kategori untuk encoding — semuanya dihitung hanya dari data latih, lalu diterapkan ke data validasi dan uji.

Urutan enam langkah yang sah

1 Pisahkan data uji dan simpan

2 Bagi sisanya menjadi latih dan validasi

3 Hitung statistik praproses dari data latih saja

4 Terapkan hasilnya ke validasi dan uji

5 Latih, bandingkan, pilih model terbaik

6 Buka data uji satu kali di akhir

Pembagian acak tidak selalu benar

Data tidak seimbang

Stratified split

Proporsi tiap kelas dipertahankan sama di semua bagian, agar kelas minoritas tidak hilang dari salah satu bagian.

Data deret waktu

Time-based split

Pembagian mengikuti urutan waktu. Data masa depan tidak boleh dipakai melatih model yang memprediksi masa lalu.

Data berkelompok

Group split

Bila satu bus menyumbang banyak baris, seluruh barisnya harus berada di bagian yang sama agar tidak bocor.

Contoh yang paling sering keliru: data perjalanan bus selama satu tahun diacak lalu dibagi 80:20 untuk memprediksi keterlambatan bulan depan. Model akan melihat masa depan, dan angka kinerjanya menjadi tidak berarti.

04

Kebocoran Data

Kesalahan yang membuat model tampak jauh lebih baik dari kenyataan

Ketika model melihat yang seharusnya tidak dilihat

Kebocoran data terjadi ketika informasi yang seharusnya hanya ada di data uji ikut memengaruhi proses pelatihan atau pemilihan model — baik secara langsung maupun tidak langsung.

Gejala yang harus membuat Anda curiga

Kinerja terlalu bagus

Akurasi 99% pada masalah yang menurut ahli sulit.

Jatuh saat dipakai

Brilian di laboratorium, buruk di lapangan.

Satu fitur mendominasi

Sering karena fitur itu diam-diam memuat jawaban.

Mengapa berbahaya

Kebocoran tidak menimbulkan pesan galat. Tidak ada yang rusak dan tidak ada yang gagal berjalan. Yang muncul justru angka indah yang membuat semua orang senang — sampai model itu dipakai sungguhan.

SATU-SATUNYA PERTAHANAN ADALAH MEMERIKSA PROSEDURNYA, BUKAN MEMERIKSA HASILNYA

Angka yang bagus tidak pernah menjadi bukti bahwa prosedurnya benar.

Empat cara data bocor tanpa disadari

01

Praproses sebelum pembagian

Normalisasi, pengisian nilai hilang, atau seleksi fitur dijalankan pada seluruh data lebih dulu, sehingga statistik dari data uji ikut terserap.

Bagi data lebih dulu, hitung statistik hanya dari data latih.

02

Fitur yang memuat jawaban

Fitur seperti “jumlah menit keterlambatan” dipakai untuk memprediksi “apakah terlambat”. Fitur itu baru ada setelah kejadian.

Tanyakan untuk tiap fitur: apakah nilainya sudah tersedia saat prediksi dibuat?

03

Baris kembar di dua sisi

Satu perjalanan tercatat dua kali dengan sedikit perbedaan, lalu satu salinan masuk data latih dan salinan lain masuk data uji.

Bersihkan duplikat sebelum pembagian; pakai group split bila berkelompok.

04

Data uji dilihat berkali-kali

Model diperbaiki terus-menerus berdasarkan hasil pada data uji. Setelah puluhan kali, data uji sudah tidak jujur lagi.

Pakai data validasi untuk semua keputusan, buka data uji tepat satu kali.

Audit empat prosedur pembagian data

BERPASANGAN · 15 MENIT · TANPA KOMPUTER

Untuk tiap prosedur: sah atau tidak? Bila tidak, di mana letak kesalahannya dan apa perbaikannya?

A

Data dibagi 80:20. Model dilatih pada 80%, lalu tiga nilai λ dicoba dan yang menghasilkan akurasi tertinggi pada 20% dilaporkan sebagai kinerja akhir.

B

Seluruh data dinormalisasi memakai rata-rata dan simpangan baku dari keseluruhan data, baru kemudian dibagi menjadi latih dan uji.

C

Data dibagi 60:20:20. Hyperparameter dipilih memakai bagian validasi, lalu model terbaik diuji satu kali pada bagian uji, dan angka itulah yang dilaporkan.

D

Data keterlambatan bus Januari sampai Desember diacak, lalu dibagi 80:20 untuk memprediksi keterlambatan bulan depan.

Petunjuk: tiga dari empat prosedur mengandung kesalahan. Cari titik di mana informasi dari data uji ikut memengaruhi keputusan.

Empat perumusan yang harus Anda nilai

A

Tim ingin “memprediksi kepadatan penumpang”. Belum ditentukan apakah keluarannya berupa angka, kategori, atau peringkat.

B

Untuk memprediksi keterlambatan, tim memasukkan fitur “jam tiba sebenarnya” karena tersedia di basis data.

C

Tim memilih neural network besar untuk data 300 baris, dengan alasan model itu paling fleksibel.

D

Tim ingin mengelompokkan rute, lalu melaporkan bahwa akurasi pengelompokannya mencapai 87%.

Untuk tiap kasus: komponen learning problem mana yang bermasalah, dan apa perbaikannya?

Diskusi kelompok empat orang · 12 menit

Empat salah kaprah yang paling sering



Model yang lebih fleksibel selalu lebih baik

Ruang hipotesis yang terlalu luas untuk data yang sedikit justru menghasilkan hafalan, bukan pembelajaran.



Loss function hanyalah detail teknis

Loss menyatakan kesalahan mana yang paling ingin dihindari. Mengganti loss berarti mengganti tujuannya.



Data validasi dan data uji sama saja

Validasi dipakai berkali-kali untuk memilih. Uji dibuka satu kali untuk menaksir. Menukarnya menghapus taksiran jujur Anda.



Melihat data uji boleh asal tidak dipakai melatih

Melihat lalu mengubah keputusan sudah cukup untuk merusaknya. Yang bocor adalah informasi, bukan hanya baris data.

Yang perlu Anda bawa pulang

Tiga komponen

Data, model, dan loss function. Mengganti satu berarti mengubah masalahnya.

Ruang hipotesis

Memilih model berarti memilih kumpulan fungsi yang boleh dipertimbangkan.

Bias induktif

Setiap model membawa asumsi. Tidak ada model tanpa asumsi.

Supervised vs unsupervised

Ada tidaknya label mengubah cara mengukur keberhasilan.

Tiga himpunan data

Latih untuk parameter, validasi untuk pilihan, uji untuk taksiran.

Aturan emas

Data uji dibuka satu kali, di akhir, setelah semua keputusan final.

Tugas Terstruktur 1

TUGAS TERSTRUKTUR 1 · 4%

Analisis tertulis elemen learning problem pada dua kasus, dan koreksi satu skenario pembagian data yang mengandung kebocoran.

BELAJAR MANDIRI · 180 MENIT

Membaca Burkov [3] mengenai komponen learning problem dan bias induktif, serta ISL [11] Bab 2.

Kriteria penilaian tugas

Ketepatan mengidentifikasi komponen (40%) · Ketepatan menemukan letak kebocoran (30%) · Kekuatan alasan yang diberikan (30%). Menyebut satu prosedur keliru tanpa menjelaskan mengapa tidak memperoleh nilai penuh.

Catatan untuk Studi Kasus Akhir: bagian B.1, B.4, dan B.5 dokumen tugas meminta Anda merumuskan learning problem, mendefinisikan ruang hipotesis, dan menunjukkan titik rawan kebocoran. Materi hari ini adalah bekal langsungnya.

PERTEMUAN BERIKUTNYA

Regresi Linier, Fungsi Loss, dan Gradient Descent

Hari ini kita menetapkan apa yang hendak dicari dan bagaimana menilainya.
Pertemuan depan kita melihat bagaimana model benar-benar menemukannya —
langkah demi langkah, sampai kesalahannya sekecil mungkin.