

DATA SCIENCE · TI24425 · PERTEMUAN 4

Regresi Linier, Fungsi Loss, dan Gradient Descent

Sub-CPMK 4 · Mampu menganalisis formulasi regresi linier dan fungsi loss, menjelaskan mekanisme Gradient Descent dan SGD, serta menginterpretasikan hasilnya.

Di mana kita sekarang?

3

SELESAI

Learning Problem

Kita sudah tahu cara merumuskan masalah dan membagi data.

4

HARI INI

Regresi & Gradient Descent

Model pertama kita.
Bagaimana mesin benar-benar "belajar" dari data.

5

BERIKUTNYA

Regularisasi & Bias-Variance

Apa yang terjadi kalau model belajar terlalu banyak dari data.

Sampai pertemuan 3 kita membahas bagaimana merumuskan masalah. Mulai hari ini kita membedah bagaimana model menemukan jawabannya.

Setelah pertemuan ini Anda mampu...

- 01 Menjelaskan formulasi regresi linier dan fungsi loss MSE, serta alasan di balik pengkuadratan galat.
- 02 Menghitung langkah iterasi Gradient Descent secara manual pada data kecil.
- 03 Menjelaskan akibat learning rate yang terlalu besar maupun terlalu kecil terhadap konvergensi.
- 04 Menginterpretasikan koefisien model dalam konteks masalah nyata, bukan sekadar menyebut angkanya.

Indikator 02 dinilai lewat latihan terbimbing hari ini. Sisanya diuji pada UTS pertemuan 8.

BAGIAN 1

Regresi Linier

Menarik satu garis melalui kekacauan data

Berapa lama perjalanan ini?

Dinas Perhubungan ingin memperkirakan waktu tempuh bus kota berdasarkan jarak rute.

Data yang tersedia:

Jarak (km)	Waktu (menit)
2	8
4	14
6	22
8	26

**Pertanyaannya sederhana:
garis seperti apa yang paling
baik menggambarkan pola ini?**

Dan yang lebih penting — apa yang kita maksud dengan kata "paling baik"?

$$\text{waktu} \approx w \times \text{jarak} + b$$

Diskusi 5 menit: menurut Anda, apa arti w dan b dalam konteks perjalanan bus?

Anatomi model regresi linier

$$f(x) = w \cdot x + b$$

$f(x)$

Prediksi

Keluaran model — nilai yang kita perkirakan, bukan nilai sebenarnya.

x

Fitur

Masukan yang kita amati.
Dalam kasus kita: jarak rute.

w

Bobot / Koefisien


Seberapa besar x memengaruhi keluaran.
Inilah yang dipelajari model.

b


Bias / Intersep

Nilai keluaran saat $x = 0$.
Juga dipelajari model.

w dan b disebut parameter. Nilainya tidak kita tentukan sendiri — model yang mencarinya dari data.



Simple linear regression



Multiple linear regression

Angka itu artinya apa?

$$\text{waktu} = 3.1 \times \text{jarak} + 1.8$$


 $w = 3.1$

Setiap tambahan 1 km rute
memperpanjang waktu tempuh
sekitar 3,1 menit.

Ini laju, bukan total.


 $b = 1.8$

Saat jarak nol, model tetap
memperkirakan 1,8 menit —
waktu naik-turun penumpang.

Tidak selalu bermakna fisik.

Peringatan: hubungan yang ditemukan model adalah korelasi, bukan sebab-akibat. Model tidak tahu bahwa jarak "menyebabkan" waktu — ia hanya menemukan pola dalam angka.

Seberapa meleset garis kita?

Untuk tiap titik data, ada selisih antara nilai sebenarnya dan nilai prediksi. Selisih itu disebut residual atau galat.


$$e_i = y_i - f(x_i)$$

- Residual positif: model menebak terlalu rendah
- Residual negatif: model menebak terlalu tinggi
- Residual nol: tebakan tepat (jarang terjadi)

Kenapa tidak dijumlahkan begitu saja?

Karena residual positif dan negatif akan saling meniadakan — garis yang buruk bisa tampak sempurna.


Data aktual vs prediksi garis



$$h_w(x) = w_1x + w_2x^2 + \dots + w_nx^n + b$$

Here, n -th power indicates the degree of the polynomial.

Polynomial regression is a type of linear regression. Although its features are non-linear, the relationship between its weight parameters w is still linear.



Comparison between linear and polynomial regression

Mean Squared Error

$$\text{MSE} = (1/n) \sum (y_i - f(x_i))^2$$

2

Kuadrat menghapus tanda

Positif dan negatif tidak lagi saling meniadakan.

↑

Galat besar dihukum lebih berat

Meleset 10 satuan terasa 100 kali, bukan 10 kali.

 $\int$

Mulus dan bisa diturunkan

Syarat mutlak agar Gradient Descent bisa bekerja.

MSE bukan satu-satunya pilihan — tetapi sifat ketiga inilah alasan ia mendominasi.

MSE atau MAE?

	MSE (Mean Squared Error)	MAE (Mean Absolute Error)
Rumus inti	rata-rata dari $(\text{galat})^2$	rata-rata dari $ \text{galat} $
Terhadap pencilan	Sangat sensitif — satu pencilan dapat menguasai seluruh nilai loss	Tahan pencilan — tiap galat dihitung setara
Turunan	Mulus di semua titik	Tidak terdefinisi saat galat = 0
Satuan hasil	Kuadrat dari satuan asli (sulit ditafsirkan langsung)	Sama dengan satuan asli (mudah ditafsirkan)
Dipakai saat	Galat besar memang harus dihindari sekuat tenaga	Data mengandung pencilan yang wajar dan tidak keliru

Tidak ada jawaban universal. Pilihan loss adalah keputusan perancangan yang harus Anda justifikasi.

Hitung MSE dua kandidat garis

Kerjakan berpasangan · 10 menit · Cukup kertas dan kalkulator

Jarak x	Waktu y	Garis A: $3x + 2$	Garis B: $4x$
2	8	8	8
4	14	14	16
6	22	20	24
8	26	26	32

Langkah kerja

- Hitung residual tiap baris
- Kuadratkan setiap residual
- Jumlahkan, lalu bagi 4
- Bandingkan MSE A dan B

Pertanyaan lanjutan yang wajib dijawab:

Garis mana yang lebih baik? Apakah keputusan Anda berubah bila digunakan MAE, bukan MSE? Jelaskan alasannya.

BAGIAN 2

Menemukan Minimum

Dua jalan menuju garis terbaik

Analitik atau iteratif?

1

Solusi Analitik

Persamaan Normal

- Selesaikan langsung dengan aljabar
- Hasilnya eksak, sekali hitung
- Perlu membalik matriks $X^T X$

*Runtuh ketika fitur sangat banyak
atau matriks tidak dapat dibalik.*

2

Solusi Iteratif

Gradient Descent

- Perbaiki tebakan sedikit demi sedikit
- Hasilnya hampiran, berulang
- Hanya perlu menghitung turunan

*Bekerja pada data raksasa dan pada
model yang tidak punya solusi tertutup.*

Regresi linier kebetulan punya solusi analitik. Sebagian besar model yang akan kita pelajari nanti tidak punya — karena itu kita mempelajari cara iteratif.

BAGIAN 3

Gradient Descent

Menuruni lembah selangkah demi selangkah

Turun bukit dalam kabut

Bayangkan Anda berada di lereng bukit, tertutup kabut tebal. Anda ingin turun ke titik terendah, tetapi hanya bisa merasakan kemiringan tanah tepat di bawah kaki.

Yang bisa Anda lakukan: rasakan arah paling curam menurun, melangkah sedikit ke sana, lalu ulangi.

Padanan istilah

Lereng bukit	→ Permukaan fungsi loss
Posisi Anda	→ Nilai w dan b saat ini
Kemiringan di bawah kaki	→ Gradien — turunan loss
Panjang langkah	→ Learning rate (α)
Titik terendah	→ Loss minimum

Kabut itu penting: model tidak pernah melihat keseluruhan permukaan loss. Ia hanya tahu kemiringan di titik tempatnya berdiri.

Empat langkah yang diulang

1

Tebak awal

Tetapkan w dan b sembarang, misalnya keduanya nol.

2

Hitung gradien

Cari turunan loss terhadap w dan terhadap b .

3

Perbarui parameter

Geser w dan b berlawanan arah gradien.

4

Ulangi

Kembali ke langkah 2 sampai kriteria berhenti terpenuhi.

Aturan pembaruan (langkah 3)

$$w \leftarrow w - \alpha \cdot \partial L / \partial w$$

$$b \leftarrow b - \alpha \cdot \partial L / \partial b$$

Tanda minus itu bukan hiasan. Gradien menunjuk arah loss naik paling cepat — kita bergerak ke arah sebaliknya.

Sebesar apa satu langkah?

α terlalu kecil

Konvergen, tetapi sangat lambat. Butuh ribuan iterasi untuk mencapai minimum — boros waktu dan komputasi.

Gejala: loss turun, tetapi nyaris tidak terasa.

α tepat

Turun cepat di awal, lalu melambat mendekati minimum dan berhenti dengan mulus.

Gejala: kurva loss menurun tajam lalu mendatar.


α terlalu besar

Melompati minimum. Loss dapat berosilasi naik-turun atau justru meledak menuju tak hingga.

Gejala: loss naik, berayun, atau menjadi NaN.

α tidak dipelajari model — Anda yang menentukannya. Inilah yang membedakan hyperparameter dari parameter.

Membaca kurva loss



Cara membacanya

- Kurva mendatar terlalu tinggi: α terlalu kecil atau model kurang mampu
- Kurva berayun atau naik: α terlalu besar, kecilkan sepuluh kali lipat
- Kurva turun lalu mendatar rendah: inilah yang kita harapkan
- Kurva turun terus tanpa henti: latih lebih lama

Kurva loss adalah alat diagnosis pertama Anda — lihat sebelum menyalahkan data.

Telusuri dua iterasi Gradient Descent

Kerjakan sendiri lalu bandingkan dengan teman sebangku · 15 menit

Diketahui

- Satu titik data: $x = 2, y = 10$
- Model disederhanakan: $f(x) = w \cdot x$ (tanpa b)
- Nilai awal: $w = 1$
- Learning rate: $\alpha = 0,1$
- Loss: $L = (y - w \cdot x)^2$

Yang harus dikerjakan



- Tuliskan $\partial L / \partial w$ untuk satu titik data
- Hitung gradien pada $w = 1$
- Perbarui w , catat nilai barunya
- Ulangi sekali lagi untuk iterasi kedua
- Bandingkan loss sebelum dan sesudah

Petunjuk: $\partial L / \partial w = -2x(y - wx)$. Anda tidak perlu menghafalnya — tetapi harus bisa menjelaskan mengapa tandanya negatif.

BAGIAN 4

Stochastic Gradient Descent

Ketika data terlalu besar untuk dilihat sekaligus



Kenapa perlu versi stokastik?

Gradient Descent biasa menghitung gradien dari SELURUH data pada setiap langkah. Dengan 10 juta baris data, satu langkah saja berarti 10 juta perhitungan — dan Anda butuh ribuan langkah.

Batch GD

Gradien dihitung dari

Seluruh data

- + Lintasan mulus dan stabil menuju minimum
- Sangat lambat pada data besar

Stochastic GD

Gradien dihitung dari

Satu baris data


- + Sangat cepat per langkah, dapat lepas dari minimum lokal
- Lintasan berisik dan berayun

Mini-batch GD

Gradien dihitung dari

32–256 baris

- + Kompromi terbaik, cocok untuk komputasi paralel
- Ukuran batch jadi hyperparameter baru



BGD

Use **all** training samples for each training pass.

SGD

One training sample is used for each training pass.

MBGD

A certain number of training samples are used for each training pass.

Empat skenario, empat keputusan

A

Loss turun tajam lalu naik lagi dan berayun tanpa henti setelah iterasi ke-50.

B

Setelah 5.000 iterasi, loss masih 48 dari nilai awal 50.

C

Model dilatih pada 8 juta baris data transaksi. Satu iterasi memakan 40 menit.

D

Loss menjadi NaN pada iterasi kedua.

Untuk tiap skenario: apa dugaan penyebabnya, dan apa satu tindakan pertama yang akan Anda lakukan?

Jawab dengan alasan, bukan tebakan. Diskusi kelompok 4 orang · 15 menit.

Empat salah kaprah yang paling sering



Gradient Descent adalah sebuah model

Bukan. Ia algoritma optimisasi — cara mencari parameter. Modelnya tetap regresi linier.



Learning rate dipelajari dari data

Tidak. α adalah hyperparameter yang Anda tetapkan sendiri sebelum pelatihan dimulai.



Loss nol berarti model sempurna

Justru mencurigakan. Loss nol pada data latih sering menandakan overfitting — dibahas pertemuan 5.



Gradien selalu membawa ke minimum global

Hanya untuk fungsi cembung seperti MSE pada regresi linier. Pada neural network, tidak ada jaminan itu.

Yang perlu Anda bawa pulang

Model

$f(x) = w \cdot x + b$. Hanya w dan b yang dipelajari dari data.

Ukuran kesalahan

MSE mengkuadratkan galat sehingga bisa diturunkan — syarat bagi GD.

Cara belajar

Gradient Descent bergerak berlawanan arah gradien, sedikit demi sedikit.

Kendali utama

Learning rate α menentukan konvergen, lambat, atau meledak.

Skala besar

SGD dan mini-batch menukar kestabilan dengan kecepatan.

Batas tafsir

Koefisien menunjukkan hubungan, bukan sebab-akibat.

Sebelum pertemuan berikutnya



Belajar Mandiri · 180 menit

Membaca Géron [1] Bab 4 mengenai pelatihan model dan Gradient Descent. Siapkan satu pertanyaan tertulis.



Penugasan Terstruktur · 180 menit

Latihan soal: penelusuran manual iterasi Gradient Descent dan interpretasi koefisien regresi. Dibahas bersama di kelas.

Latihan ini bersifat formatif — tidak berbobot tersendiri. Kontribusi Anda saat pembahasan di kelas dinilai melalui komponen Aktivitas Partisipatif.

Bacaan pendukung

[9] CS 189/289A, University of California Berkeley — <https://eecs189.org/>

[11] James, Witten, Hastie & Tibshirani, An Introduction to Statistical Learning, Bab 3 (tersedia bebas daring)

PERTEMUAN BERIKUTNYA

Regularisasi, MLE, dan Bias-Variance Trade-off

Hari ini kita membuat model belajar dari data.

Pertemuan depan kita bertanya: bagaimana kalau model belajar terlalu banyak?