

# Regularisasi, MLE, dan Bias-Variance Trade-off

---

Sub-CPMK 5 · Mampu menganalisis peran regularisasi dan Maximum Likelihood Estimation, serta mengevaluasi kondisi underfitting dan overfitting melalui kerangka bias-variance trade-off.

# Di mana kita sekarang?

4

SELESAI

## Regresi & Gradient Descent

Kita sudah bisa membuat model belajar dari data.

5

HARI INI

## Regularisasi & Bias-Variance

Bagaimana kalau model belajar terlalu banyak?

6

BERIKUTNYA

## Logistic Regression

Dari memprediksi angka menjadi memprediksi kelas.

*Pertemuan lalu kita puas ketika loss mengecil. Hari ini kita belajar bahwa loss yang terlalu kecil justru pertanda bahaya.*

# Setelah pertemuan ini Anda mampu...

- 01 Membedakan pengaruh regularisasi L1 (Lasso) dan L2 (Ridge) terhadap koefisien model.
- 02 Menjelaskan hubungan Maximum Likelihood Estimation dengan fungsi loss yang sudah Anda kenal.
- 03 Mendiagnosis kondisi underfitting dan overfitting dari kurva pembelajaran dan tabel skor.
- 04 Menyusun rekomendasi perbaikan model beserta alasan yang dapat dipertanggungjawabkan.


*Indikator 03 dan 04 dinilai lewat Tugas Terstruktur 2 (bobot 4%) yang diberikan di akhir pertemuan ini.*

BAGIAN 1

# Ketika Model Belajar Terlalu Banyak

Underfitting, overfitting, dan cara mengenalinya

# Tiga model, satu data yang sama



## Terlalu sederhana

Melewatkan pola yang jelas ada.  
Salah pada data latih maupun uji.

## Seimbang

Menangkap pola, mengabaikan  
derau. Inilah yang kita cari.

## Terlalu kompleks

Melewati setiap titik persis —  
termasuk derau. Loss latih nol.

*Model terlalu kompleks tidak digambar: garisnya akan berimpit sempurna dengan titik data pengamatan.*

# Underfitting dan overfitting

## UNDERFITTING

### Model terlalu kaku

- Galat besar pada data latih
- Galat besar pada data uji
- Kedua galat hampir sama besar
- Model tidak cukup mampu menangkap pola

---

*Perbaikan: tambah fitur, naikkan kompleksitas model, kurangi regularisasi, latih lebih lama.*

## OVERFITTING

### Model terlalu lentur


- Galat sangat kecil pada data latih
- Galat besar pada data uji
- Jurang lebar antara keduanya
- Model menghafal derau, bukan pola

---

*Perbaikan: tambah data, kurangi fitur, sederhanakan model, tambah regularisasi, early stopping.*

**Kuncinya bukan nilai galat itu sendiri, melainkan jurang antara galat latih dan galat uji.**

# Membaca kurva pembelajaran



## Yang harus dilihat

- Kedua kurva tinggi dan berdempetan: underfitting
- Kurva validasi berbalik naik sementara kurva latih terus turun: overfitting dimulai
- Titik balik itulah saat terbaik untuk berhenti melatih
- Jurang lebar di ujung kanan: model sudah menghafal

*Menghentikan pelatihan tepat di titik balik disebut early stopping — bentuk regularisasi yang paling murah.*

# Diagnosis empat model

Kerjakan berpasangan · 12 menit · Untuk tiap model: sebutkan kondisinya dan satu tindakan perbaikan

| Model | Galat data latih | Galat data validasi | Kondisi? | Tindakan perbaikan? |
|-------|------------------|---------------------|----------|---------------------|
| A     | 0,02             | 4,80                |          |                     |
| B     | 3,90             | 4,05                |          |                     |
| C     | 0,45             | 0,61                |          |                     |
| D     | 0,10             | 0,15                |          |                     |

Pertanyaan jebakan: Model D punya galat paling kecil di kedua kolom. Apakah otomatis berarti D yang terbaik? Apa satu informasi tambahan yang wajib Anda tanyakan sebelum memutuskan?

BAGIAN 2

# Bias-Variance Trade-off

Dua sumber kesalahan yang saling tarik-menarik

# Dari mana kesalahan datang?



## Bias

Kesalahan karena asumsi

Model terlalu menyederhanakan kenyataan. Ia konsisten meleset ke arah yang sama, berapa kali pun dilatih ulang.

Bias tinggi → underfitting



## Variance

Kesalahan karena kepekaan

Model terlalu peka pada data latih tertentu. Ganti sedikit datanya, hasilnya berubah drastis.

Variance tinggi → overfitting

$$\text{Galat total} = \text{Bias}^2 + \text{Variance} + \text{Galat tak tereduksi}$$

*Menurunkan yang satu biasanya menaikkan yang lain — itulah sebabnya disebut trade-off.*

# Empat kemungkinan lemparan panah



## Bias rendah Variance rendah

Semua panah menumpuk tepat di pusat sasaran.

**Ideal — jarang tercapai**



## Bias rendah Variance tinggi

Panah tersebar luas, tetapi rata-ratanya di pusat.

**Overfitting**



## Bias tinggi Variance rendah

Panah menumpuk rapat, tetapi jauh dari pusat.

**Underfitting**




## Bias tinggi Variance tinggi

Panah tersebar luas dan melenceng jauh dari pusat.

**Terburuk dari dua dunia**

*Bias mengukur seberapa jauh dari pusat. Variance mengukur seberapa tersebar.*

# Titik terbaik ada di tengah



## Titik optimum

Bukan saat bias terkecil, bukan pula saat variance terkecil — melainkan saat jumlah keduanya paling kecil.

## Yang perlu diingat

- Menambah kompleksitas menurunkan bias
- Menambah kompleksitas menaikkan variance
- Menambah data menurunkan variance tanpa menaikkan bias

# Ada galat yang tidak bisa dihapus

Galat tak tereduksi berasal dari derau bawaan data itu sendiri — pengukuran yang tidak sempurna, faktor yang tidak terekam, atau keacakan alami.

## Contoh pada kasus kita:

- Kemacetan mendadak yang tidak tercatat
- Cuaca dan perilaku pengemudi
- Kesalahan pencatatan waktu di halte

## Konsekuensi praktis

- Tidak ada model yang bisa mencapai galat nol pada data baru
- Mengejar galat nol pada data latih justru menghasilkan overfitting
- Menambah data atau fitur tidak akan menghapus bagian ini

**Pertanyaan yang harus Anda ajukan bukan "seberapa kecil galat bisa saya buat", melainkan "seberapa dekat saya dengan batas bawah yang wajar untuk data ini".**

### BAGIAN 3

# Regularisasi

Menghukum kompleksitas secara sengaja

# Menambahkan denda pada fungsi loss

Selama ini model hanya diminta satu hal: perkecil galat. Regularisasi menambahkan permintaan kedua: dan jangan jadi terlalu rumit.

$$\text{Loss baru} = \text{Loss data} + \lambda \cdot \text{Penalti kompleksitas}$$

## Loss data

Seberapa meleset prediksi dari kenyataan. Contoh: MSE.

## $\lambda$ (lambda)

Seberapa keras kita menghukum kerumitan. Anda yang menentukan.

## Penalti

Ukuran kerumitan model — biasanya besarnya koefisien.

*Model kini menghadapi dilema: mengecilkan galat menuntut koefisien besar, tetapi koefisien besar dikenai denda.*

# Ridge (L2) dan Lasso (L1)

|                     | Ridge · Regularisasi L2                                 | Lasso · Regularisasi L1                           |
|---------------------|---------------------------------------------------------|---------------------------------------------------|
| Bentuk penalti      | $\lambda \cdot \sum w^2$ (jumlah kuadrat bobot)         | $\lambda \cdot \sum  w $ (jumlah nilai mutlak)    |
| Efek pada koefisien | Semua koefisien mengecil, tetapi tidak pernah tepat nol | Sebagian koefisien menjadi tepat nol              |
| Kegunaan tambahan   | Menstabilkan model saat fitur saling berkorelasi kuat   | Melakukan seleksi fitur secara otomatis           |
| Dipakai saat        | Semua fitur diyakini relevan, hanya perlu diredam       | Diduga banyak fitur yang sebenarnya tidak berguna |
| Catatan             | Turunannya mulus — mudah dioptimasi                     | Tidak mulus di titik nol — butuh metode khusus    |

*Elastic Net menggabungkan keduanya — disebut sekilas di sini, dibahas tuntas pada mata kuliah lanjutan.*

# Seberapa keras menghukum?

$\lambda = 0$

Tidak ada denda sama sekali. Model bebas menjadi serumit apa pun — kembali ke risiko overfitting.

*Setara tanpa regularisasi*

$\lambda$  tepat

Koefisien diredam secukupnya. Model tetap menangkap pola, tetapi berhenti mengejar derau.

*Galat validasi minimum*

$\lambda$  sangat besar

Denda mendominasi. Semua koefisien tertekan mendekati nol dan model nyaris tidak memprediksi apa pun.

*Berbalik jadi underfitting*

Perhatikan polanya: sama seperti learning rate pada pertemuan lalu,  $\lambda$  adalah hyperparameter — Anda yang menetapkan, bukan model yang mempelajarinya. Cara memilihnya dibahas di pertemuan 9.

# Membaca efek $\lambda$ pada koefisien

Kerjakan sendiri, lalu bandingkan dengan teman sebangku · 12 menit

Sebuah model memprediksi waktu tempuh bus dari lima fitur. Berikut koefisien hasil pelatihan pada beberapa nilai  $\lambda$ .

| Fitur        | $\lambda = 0$ | $\lambda = 0,1$ | $\lambda = 1$ | $\lambda = 10$ | $\lambda = 100$ |
|--------------|---------------|-----------------|---------------|----------------|-----------------|
| Jarak rute   | 3,10          | 3,02            | 2,74          | 1,85           | 0,42            |
| Jumlah halte | 1,80          | 1,71            | 1,32          | 0,64           | 0,09            |
| Jam sibuk    | 2,40          | 2,28            | 1,90          | 0,97           | 0,15            |
| Warna bus    | 0,90          | 0,41            | 0,00          | 0,00           | 0,00            |
| Nomor armada | 0,75          | 0,28            | 0,00          | 0,00           | 0,00            |

Jawab tiga hal: (1) Jenis regularisasi apa yang dipakai — Ridge atau Lasso? Tunjukkan buktinya dari tabel.

(2) Fitur mana yang menurut model tidak berguna, dan apakah itu masuk akal? (3) Mengapa  $\lambda = 100$  berbahaya?

# Tiga hal yang sering terlewat

1

## Fitur wajib diskalakan lebih dulu

Penalti menghukum besarnya koefisien. Fitur dengan satuan besar (misalnya rupiah) menghasilkan koefisien kecil, dan sebaliknya. Tanpa penskalaan, denda menjadi tidak adil antar fitur.

2

## Intersep biasanya tidak dihukum

Bias  $b$  menggeser seluruh prediksi dan tidak menambah kerumitan bentuk model. Menghukumnya justru memaksa prediksi mendekati nol tanpa alasan.

3

## Regularisasi bukan pengganti data

Ia menahan model agar tidak menghafal, tetapi tidak menciptakan informasi baru. Bila datanya memang kurang, regularisasi hanya menunda masalah.

#### BAGIAN 4

# Maximum Likelihood Estimation

Dari mana fungsi loss itu sebenarnya berasal?

# Parameter mana yang paling masuk akal?

Selama ini kita memilih MSE begitu saja karena "masuk akal". MLE membalik urutan berpikirnya.

Alih-alih bertanya "seberapa meleset prediksi saya", MLE bertanya: dengan asumsi tertentu tentang data, nilai parameter mana yang membuat data yang saya amati paling mungkin terjadi?

**1 Asumsikan**  
Tetapkan asumsi tentang sebaran derau, misalnya berdistribusi normal.

**2 Hitung**  
Susun likelihood: peluang data teramati untuk suatu nilai parameter.

**3 Maksimalkan**  
Cari parameter yang membuat nilai likelihood paling besar.

## Hasil yang mengejutkan

Jika kita mengasumsikan derau berdistribusi normal, memaksimalkan likelihood ternyata setara persis dengan meminimalkan MSE. Fungsi loss yang kita pakai pertemuan lalu bukan pilihan sembarangan — ia punya landasan statistik.

# Bagaimana semuanya terhubung



*Asumsi statistik menentukan fungsi loss. Fungsi loss menentukan apa yang dioptimasi. Algoritma optimasi menentukan bagaimana mencapainya.*

## Kalau asumsinya berubah?

Asumsi derau Laplace menghasilkan MAE, bukan MSE. Asumsi Bernoulli menghasilkan cross-entropy — yang akan kita pakai pertemuan depan untuk klasifikasi.

## Di mana regularisasi masuk?

Menambahkan keyakinan awal tentang nilai parameter. Keyakinan normal menghasilkan Ridge, keyakinan Laplace menghasilkan Lasso. Itulah sudut pandang Bayesian.

# Empat laporan dari lapangan



Akurasi 99,8% pada data latih, 61% pada data uji. Tim mengusulkan menambah lapisan model.



Model dengan Lasso menghasilkan 18 dari 20 koefisien bernilai nol. Klien menganggapnya rusak.



Setelah regularisasi ditambahkan, galat latih naik dari 0,05 menjadi 0,31. Tim panik.



Galat latih dan galat uji sama-sama 4,8 dan tidak turun meski model dilatih tiga kali lebih lama.

**Untuk tiap laporan: apa diagnosis Anda, apakah usulan tim sudah tepat, dan apa satu tindakan pertama yang Anda sarankan?  
Jawab dengan alasan. Diskusi kelompok 4 orang · 15 menit.**

# Empat salah kaprah yang paling sering



**Regularisasi selalu memperbaiki model**

Tidak. Pada model yang sudah underfitting, regularisasi justru memperburuk keadaan.



**Galat latih naik berarti gagal**

Justru sering pertanda benar. Yang menentukan keberhasilan adalah galat validasi, bukan galat latih.



**Bias tinggi berarti model berat sebelah**

Bias di sini istilah statistik, bukan bias sosial. Keduanya penting, tetapi bukan hal yang sama.



**Trade-off berarti harus berkompromi selamanya**

Menambah data berkualitas menurunkan variance tanpa menaikkan bias — satu-satunya jalan keluar sejati.

# Yang perlu Anda bawa pulang

## Underfitting

Galat latih dan uji sama-sama besar.  
Model terlalu kaku.

## Overfitting

Galat latih kecil, galat uji besar.  
Model menghafal derau.

## Bias-Variance

Galat = Bias<sup>2</sup> + Variance + galat  
tak tereduksi. Optimum ada di tengah.

## Regularisasi

Menambah denda kerumitan pada loss.  
 $\lambda$  mengatur seberapa keras.

## Ridge vs Lasso

L2 mengecilkan semua koefisien.  
L1 dapat membuatnya tepat nol.

## MLE

Fungsi loss berasal dari asumsi  
statistik, bukan dipilih sembarangan.

# Sebelum pertemuan berikutnya



## Belajar Mandiri · 180 menit

Membaca Burkov [3] mengenai regularisasi dan bias-variance trade-off, serta ISL [11] Bab 6.



## Tugas Terstruktur 2 · Bobot 4%

Laporan diagnosis bias-variance dari kurva pembelajaran yang disediakan, disertai rekomendasi perbaikan beserta alasannya.

### Kriteria penilaian tugas

Ketepatan diagnosis (40%) · Kelayakan rekomendasi (30%) · Kekuatan alasan yang diberikan (30%). Rekomendasi tanpa alasan tidak mendapat nilai penuh, sekalipun tindakannya benar.

### Bacaan pendukung

[3] Burkov, The Hundred-Page Machine Learning Book · [11] James dkk., An Introduction to Statistical Learning, Bab 6

[9] CS 189/289A, University of California Berkeley — <https://eecs189.org/>

PERTEMUAN BERIKUTNYA

# Klasifikasi Linier: Logistic Regression

---

Sejauh ini kita memprediksi angka. Pertemuan depan kita memprediksi kelas — dan asumsi statistik yang berbeda akan melahirkan fungsi loss yang berbeda pula.