DATA SCIENCE · TI24425 · PERTEMUAN 6

Klasifikasi Linier: Logistic Regression

Sub-CPMK 6 · Mampu menganalisis model klasifikasi linier dan fungsi sigmoid, serta menginterpretasikan keluaran probabilistik dan pengaruh pemilihan ambang batas (threshold).

Program Studi Teknologi Informasi · Politeknik Negeri Madiun

ORIENTASI

Di mana kita sekarang?

5 SELESAI

Regularisasi & Bias-Variance

Kita sudah tahu cara menjaga model agar tidak menghafal.

6 HARI INI

Logistic Regression

Dari memprediksi angka menjadi memprediksi kelas.

7 BERIKUTNYA

Multi-Kelas & Metrik Evaluasi

Lebih dari dua kelas, dan cara menilai model klasifikasi.

Perubahan hari ini terlihat kecil — keluaran model berubah dari angka bebas menjadi angka antara 0 dan 1. Akibatnya jauh lebih besar dari kelihatannya.

CAPAIAN PEMBELAJARAN

Setelah pertemuan ini Anda mampu…

01 Menjelaskan peran fungsi sigmoid dan mengapa regresi linier biasa tidak memadai untuk klasifikasi.

02 Menghitung dan menginterpretasikan probabilitas keluaran model, termasuk makna odds dan log-odds.

03 Menjelaskan konsekuensi penggeseran ambang batas terhadap kesalahan tipe I dan tipe II dalam konteks nyata.

Catatan: metrik evaluasi seperti confusion matrix, precision, dan recall baru dibahas tuntas pada pertemuan 7. Hari ini kita cukup mengenali dua jenis kesalahan dan konsekuensinya.

BAGIAN 1

Dari Angka ke Kelas

Mengapa regresi linier tidak cukup

KASUS PEMBUKA

Akankah bus ini terlambat?

Dinas Perhubungan tidak lagi ingin memperkirakan berapa menit waktu tempuh, melainkan menjawab satu pertanyaan ya-atau-tidak:

“Apakah bus ini akan terlambat lebih dari 10 menit?”

Keluaran yang diinginkan hanya dua kemungkinan.

0 **TIDAK TERLAMBAT**

kelas negatif

1 **TERLAMBAT**

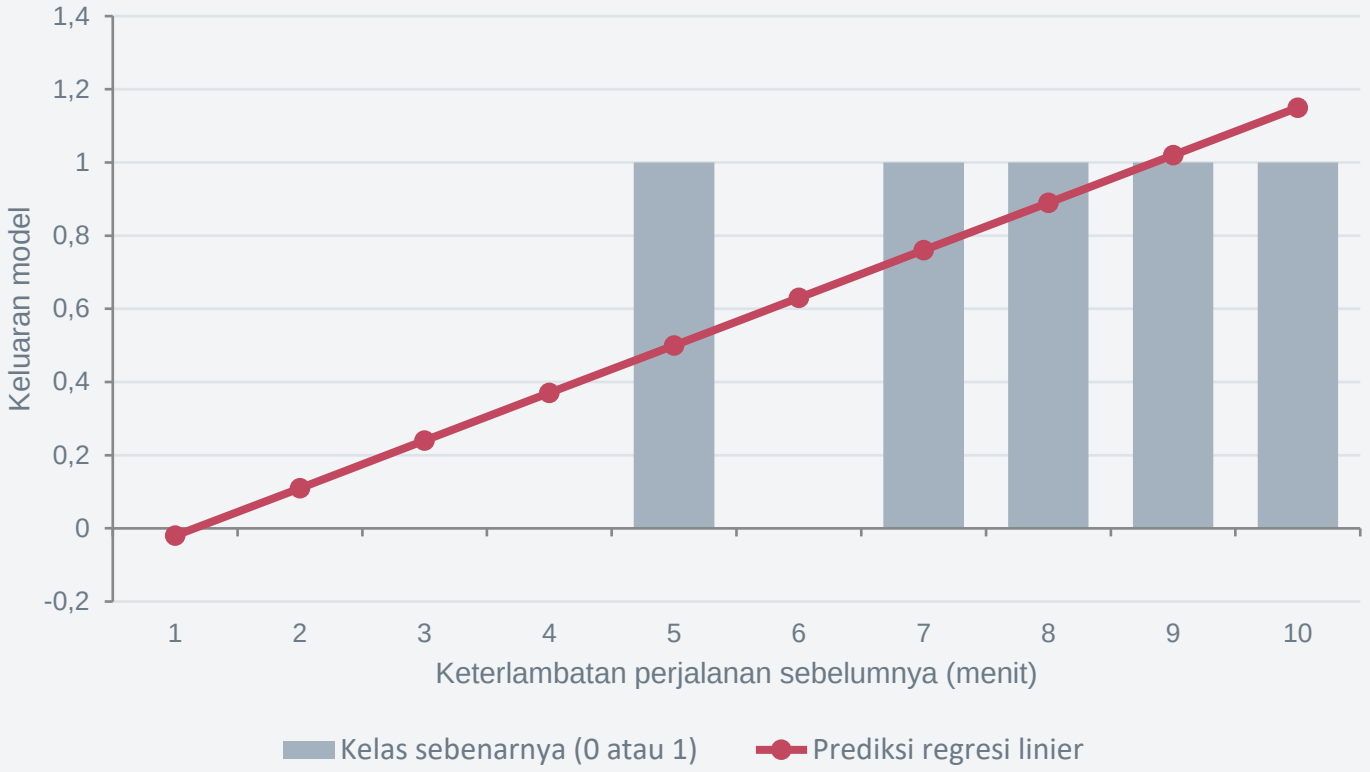
kelas positif

Pertanyaan pembuka untuk didiskusikan (5 menit)

Bisakah kita memakai regresi linier apa adanya, lalu membulatkan hasilnya — di atas 0,5 dianggap terlambat, di bawahnya dianggap tepat waktu? Apa yang mungkin salah dari cara itu?

MASALAHNYA

Apa yang terjadi kalau dipaksakan?



Keluar dari rentang

Prediksi turun di bawah 0 dan naik di atas 1. Apa arti peluang −0,02 atau 1,15?

Tidak bisa ditafsirkan

Angka 0,63 bukan peluang — ia hanya titik pada garis lurus.

Sangat peka pada pencilan

Satu perjalanan ekstrem menarik seluruh garis dan menggeser keputusan untuk semua data.

Yang kita butuhkan: fungsi yang selalu menghasilkan nilai antara 0 dan 1, berapa pun masukannya.

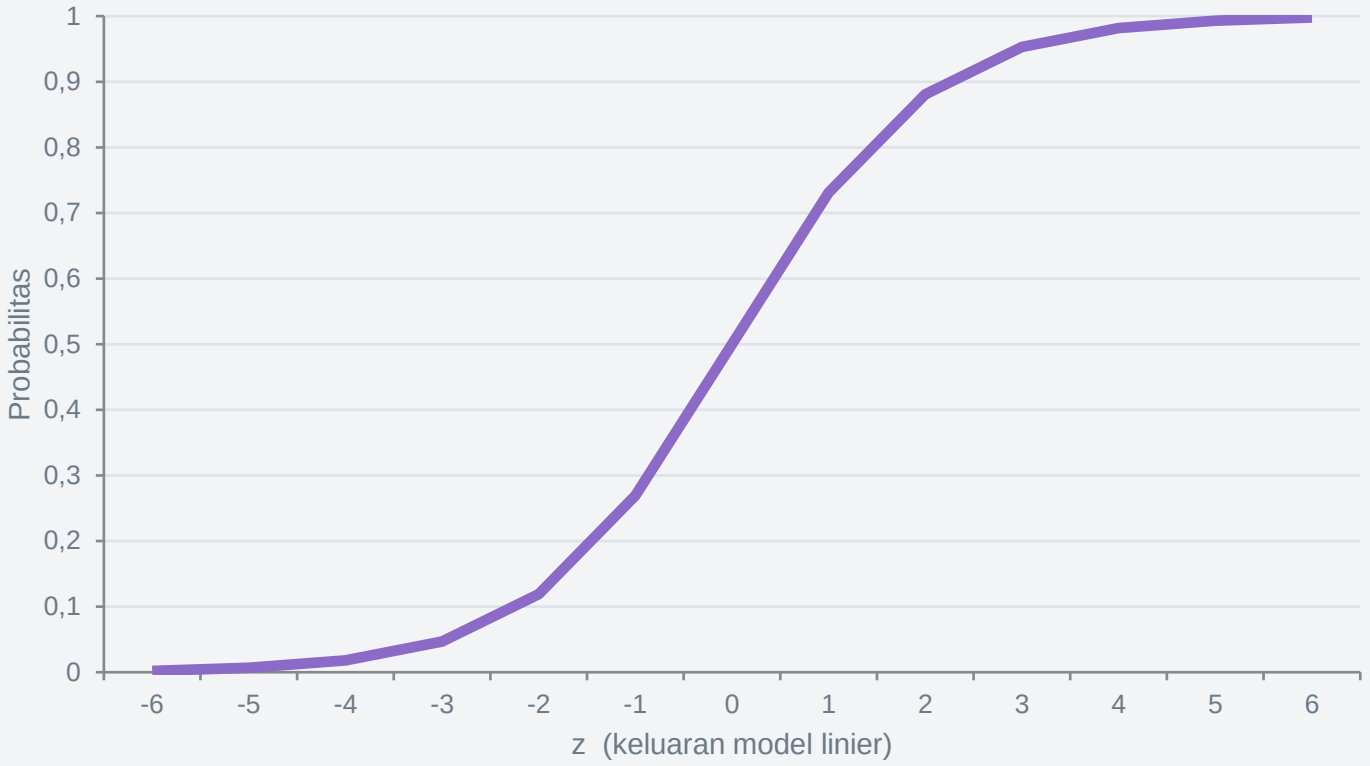
BAGIAN 2

Fungsi Sigmoid

Meremas garis lurus ke dalam rentang nol sampai satu

SOLUSI

Kurva berbentuk S



$$\sigma(z) = 1 / (1 + e^{-z})$$

Selalu antara 0 dan 1

Berapa pun nilai z, hasilnya tidak pernah keluar dari rentang itu.

Simetris di z = 0

Saat z = 0, hasilnya tepat 0,5 — model sepenuhnya ragu.

Melandai di kedua ujung

Perubahan z pada nilai ekstrem hampir tidak menggeser probabilitas.

Mulus dan bisa diturunkan

Syarat agar Gradient Descent tetap dapat dipakai.

Dua langkah, bukan satu

1

Skor linier

$z = w \cdot x + b$

Persis seperti regresi linier pertemuan lalu. Nilainya bebas, bisa negatif atau sangat besar.

2

Pemetaan

$p = \sigma(z)$

Sigmoid mengubah skor bebas itu menjadi probabilitas antara 0 dan 1.

3

Keputusan

$p \geq \text{ambang} \rightarrow 1$

Baru pada tahap ini probabilitas diubah menjadi keputusan kelas.

Model tetap linier. Yang dilengkungkan bukan modelnya, melainkan keluarannya.

Itulah sebabnya logistic regression digolongkan sebagai model linier, meskipun kurvanya berbentuk S.

INTERPRETASI

Odds dan log-odds

Koefisien logistic regression tidak bisa dibaca seperti regresi linier. Ia tidak menambah probabilitas secara langsung — ia menambah log-odds.

Probabilitas

p

Peluang kejadian terjadi.
Rentang 0 sampai 1.

p = 0,80

Odds

$\frac{p}{1-p}$

Perbandingan terjadi
lawan tidak terjadi.

0,80 / 0,20 = 4

Log-odds

$\ln\left(\frac{p}{1-p}\right)$

Inilah nilai z yang
dihasilkan bagian linier.

ln(4) ≈ 1,39

Cara membaca koefisien yang benar

Jika w = 0,5 untuk fitur "jam sibuk", maka pada jam sibuk log-odds keterlambatan naik 0,5 — artinya odds-nya menjadi $e^{0.5} \approx 1{,}65$ kali lipat. Bukan naik 0,5 satuan probabilitas.

Dari skor menjadi probabilitas

Kerjakan berpasangan · 12 menit · Gunakan tabel sigmoid di bawah, tidak perlu kalkulator ilmiah

```
z = −2,0 + 0,4 × (keterlambatan sebelumnya, menit) + 1,2 × (jam sibuk: 1 ya, 0 tidak)
```

Perjalanan	Keterlambatan sebelumnya	Jam sibuk	z = ?	p = σ(z) = ?	Keputusan (ambang 0,5)
P-01	2 menit	tidak			
P-02	5 menit	ya			
P-03	8 menit	tidak			
P-04	0 menit	ya			

Tabel bantu σ(z): z = −1,2 → 0,23 · z = −0,8 → 0,31 · z = 0 → 0,50 · z = 0,8 → 0,69 · z = 1,2 → 0,77

Pertanyaan lanjutan: perjalanan P-04 punya keterlambatan sebelumnya nol menit, tetapi berlangsung pada jam sibuk. Apakah model memprediksinya terlambat? Apa artinya secara praktis?

BAGIAN 3

Fungsi Loss: Cross-Entropy

Mengapa MSE tidak lagi memadai

PERTANYAAN

Kenapa tidak pakai MSE saja?

Masalah 1

Permukaan loss tidak lagi cembung

Menggabungkan MSE dengan sigmoid menghasilkan permukaan loss berbenjol-benjol. Gradient Descent bisa terjebak di lembah kecil yang bukan minimum sebenarnya.

Masalah 2

Hukuman terlalu ringan saat sangat salah

Bila model sangat yakin tetapi keliru, MSE hanya memberi hukuman kecil karena selisihnya dibatasi rentang 0 sampai 1.

Jawaban dari pertemuan lalu

Ingat kesimpulan MLE: fungsi loss lahir dari asumsi tentang sebaran data. Untuk keluaran yang hanya bernilai 0 atau 1, asumsi yang tepat bukan distribusi normal, melainkan distribusi Bernoulli.

Memaksimalkan likelihood Bernoulli setara dengan meminimalkan cross-entropy — sama persis seperti asumsi normal melahirkan MSE.

Cross-entropy: menghukum keyakinan yang keliru

$$L = -[\, y \cdot \ln(p) + (1 - y) \cdot \ln(1 - p) \,]$$

Rumusnya tampak rumit, tetapi bekerja sederhana: hanya satu dari dua suku yang aktif, tergantung kelas sebenarnya.

Bila kelas sebenarnya y = 1

Suku kedua hilang. Loss menjadi −ln(p).
Semakin p mendekati 1, loss mendekati nol.

Bila kelas sebenarnya y = 0

Suku pertama hilang. Loss menjadi −ln(1−p).
Semakin p mendekati 0, loss mendekati nol.

Kelas sebenarnya	Probabilitas prediksi	Nilai loss	Tafsiran
1	0,95	0,05	Yakin dan benar — hukuman hampir nol
1	0,50	0,69	Ragu — hukuman sedang
1	0,10	2,30	Yakin tetapi keliru — hukuman berat
1	0,01	4,61	Sangat yakin dan sangat keliru — hukuman sangat berat

BAGIAN 4

Ambang Batas dan Regularisasi

Keputusan terakhir ada di tangan Anda, bukan model

AMBANG BATAS

Angka 0,5 bukan hukum alam

Model menghasilkan probabilitas. Mengubahnya menjadi keputusan memerlukan satu pilihan tambahan yang tidak dipelajari dari data — ambang batas.

Ambang diturunkan (misalnya 0,3)

Model lebih mudah menyatakan "terlambat".

Lebih sedikit keterlambatan yang terlewat, tetapi lebih banyak peringatan palsu.

Ambang tetap 0,5

Perlakuan setara bagi kedua jenis kesalahan.

Pilihan bawaan, bukan pilihan terbaik untuk semua kasus.

Ambang dinaikkan (misalnya 0,7)

Model hanya menyatakan "terlambat" bila sangat yakin.

Lebih sedikit peringatan palsu, tetapi lebih banyak keterlambatan yang terlewat.

Menggeser ambang tidak membuat model lebih baik. Ia hanya memindahkan kesalahan dari satu jenis ke jenis lainnya.

KONTEKS MENENTUKAN

Dua jenis kesalahan, dua harga berbeda

Kesalahan tipe I

Peringatan palsu

Model menyatakan bus akan terlambat, ternyata tepat waktu.

Akibat: penumpang cemas tanpa perlu, petugas disiagakan sia-sia.

Kesalahan tipe II

Keterlambatan terlewat

Model menyatakan bus tepat waktu, ternyata terlambat 25 menit.

Akibat: penumpang tidak diberi tahu, kepercayaan pada layanan runtuh.

Pertanyaan yang wajib diajukan sebelum memilih ambang

Mana yang lebih merugikan bagi pengguna sistem ini — peringatan palsu atau keterlambatan yang terlewat? Jawabannya tidak ada di dalam data. Ia datang dari pemahaman terhadap masalahnya.

LATIHAN TERBIMBING 2

Memilih ambang batas

Kerjakan sendiri, lalu bandingkan dengan teman sebangku · 15 menit

Sepuluh perjalanan diurutkan menurut probabilitas keterlambatan yang diprediksi model. Kelas sebenarnya sudah diketahui.

Probabilitas	0,05	0,18	0,27	0,34	0,41	0,55	0,62	0,71	0,83	0,94
Kelas sebenarnya	0	0	0	1	0	0	1	1	1	1

Ambang batas	**Peringatan palsu (tipe I)**	**Keterlambatan terlewat (tipe II)**	**Total kesalahan**
0,30			
0,50			
0,70			

Setelah tabel terisi: ambang mana yang Anda pilih, dan untuk siapa? Jawab dua kali — sekali sebagai Dinas Perhubungan yang menjaga kepercayaan penumpang, sekali sebagai operator yang biaya penyiagaan petugasnya mahal.

PENERAPAN

Regularisasi pada model klasifikasi

Gagasan dari pertemuan lalu berlaku tanpa perubahan. Hanya bagian loss datanya yang berganti.

$$\text{Loss} = \text{Cross-Entropy} + \lambda \cdot \text{Penalti kompleksitas}$$

1. **Overfitting tetap mengancam**

   Dengan banyak fitur, model dapat memisahkan data latih dengan sempurna namun gagal pada data baru — sama seperti pada regresi.

2. **Ridge dan Lasso tetap berlaku**

   L2 meredam seluruh koefisien; L1 dapat membuat sebagian tepat nol dan sekaligus menyeleksi fitur.

3. **Pemisahan sempurna justru berbahaya**

   Bila data latih dapat dipisahkan tanpa cacat, koefisien cenderung membesar tanpa batas. Regularisasi yang menahannya.

Dalam pustaka seperti scikit-learn, parameternya bernama C — yang merupakan kebalikan dari λ. Nilai C kecil berarti regularisasi kuat.

DISKUSI KASUS

Empat keputusan yang harus Anda nilai

A Model menghasilkan probabilitas 0,49 dan 0,51 untuk dua perjalanan. Tim memperlakukan keduanya sebagai kasus yang sangat berbeda.

B Koefisien fitur "jam sibuk" bernilai 1,2. Tim melaporkan bahwa jam sibuk menaikkan peluang keterlambatan sebesar 120%.

C Model mencapai akurasi 97% pada data yang hanya 3% berisi kasus keterlambatan. Tim menganggapnya berhasil.

D Ambang dinaikkan ke 0,9 agar peringatan palsu hilang sama sekali. Peringatan palsu memang nol.

Untuk tiap kasus: apakah tim sudah benar? Bila keliru, di mana letak kekeliruannya dan apa perbaikannya?
Diskusi kelompok 4 orang · 15 menit.

WASPADAI

Empat salah kaprah yang paling sering

Logistic regression adalah model regresi	Namanya menyesatkan. Ia model klasifikasi. Kata "regresi" merujuk pada bagian liniernya, bukan tugasnya.
Karena kurvanya melengkung, modelnya non-linier	Batas keputusannya tetap garis lurus. Yang melengkung hanya pemetaan skor menjadi probabilitas.
Koefisien menambah probabilitas	Koefisien menambah log-odds, yang berarti mengalikan odds. Pengaruhnya pada probabilitas tidak tetap.
Ambang 0,5 adalah bawaan yang benar	Ia hanya nilai bawaan perangkat lunak. Pemilihan ambang adalah keputusan perancangan, bukan keputusan teknis.

RINGKASAN

Yang perlu Anda bawa pulang

Masalahnya

Regresi linier menghasilkan nilai di luar rentang 0–1 dan tidak dapat ditafsirkan.

Sigmoid

Meremas skor linier z menjadi probabilitas antara 0 dan 1.

Tetap linier

Batas keputusan tetap garis lurus. Hanya keluarannya yang dilengkungkan.

Interpretasi

Koefisien menambah log-odds, berarti mengalikan odds.

Cross-entropy

Lahir dari asumsi Bernoulli lewat MLE. Menghukum berat keyakinan yang keliru.

Ambang batas

Bukan bagian dari model. Keputusan perancangan yang bergantung konteks.

TINDAK LANJUT

Sebelum pertemuan berikutnya

BM

Belajar Mandiri · 180 menit

Membaca Géron [1] Bab 4 bagian logistic regression dan softmax, serta ISL [11] Bab 4.

PT

Penugasan Terstruktur · 180 menit

Latihan soal: perhitungan probabilitas sigmoid dan analisis pengaruh pergeseran ambang batas. Dibahas bersama di kelas.

Latihan ini bersifat formatif — tidak berbobot tersendiri. Kontribusi Anda saat pembahasan di kelas dinilai melalui komponen Aktivitas Partisipatif.

Persiapan pertemuan 7: bawa kembali tabel latihan ambang batas hari ini. Kita akan mengubahnya menjadi confusion matrix dan menghitung precision serta recall di atasnya.

Bacaan pendukung: [1] Géron Bab 4 · [11] James dkk. Bab 4 · [10] Catatan kuliah CS 189 — https://people.eecs.berkeley.edu/~jrs/189/

PERTEMUAN BERIKUTNYA

Klasifikasi Multi-Kelas dan Metrik Evaluasi

Hari ini kita membangun model klasifikasi dan menyadari bahwa satu angka akurasi tidak cukup. Pertemuan depan kita belajar mengukurnya dengan benar.