DATA SCIENCE · TI24425 · PERTEMUAN 7

Klasifikasi Multi-Kelas dan Metrik Evaluasi

Sub-CPMK 7 · Mampu membandingkan strategi klasifikasi multi-kelas serta memilih dan menjustifikasi metrik evaluasi yang sesuai dengan karakteristik masalah dan distribusi data.

Program Studi Teknologi Informasi · Politeknik Negeri Madiun

ORIENTASI

Pertemuan terakhir sebelum UTS

6 SELESAI

Logistic Regression

Kita sudah bisa memprediksi dua kelas dan menggeser ambang.

7 HARI INI

Multi-Kelas & Metrik Evaluasi

Lebih dari dua kelas, dan cara menilai model dengan benar.

8 BERIKUTNYA

Ujian Tengah Semester

Ujian tertulis 100 menit atas materi pertemuan 1–7.

Ingat kasus C pada diskusi pertemuan lalu — model dengan akurasi 97% pada data yang hanya 3% berisi keterlambatan, dan tim menganggapnya berhasil. Hari ini kita bongkar kenapa kesimpulan itu keliru.

CAPAIAN PEMBELAJARAN

Setelah pertemuan ini Anda mampu…

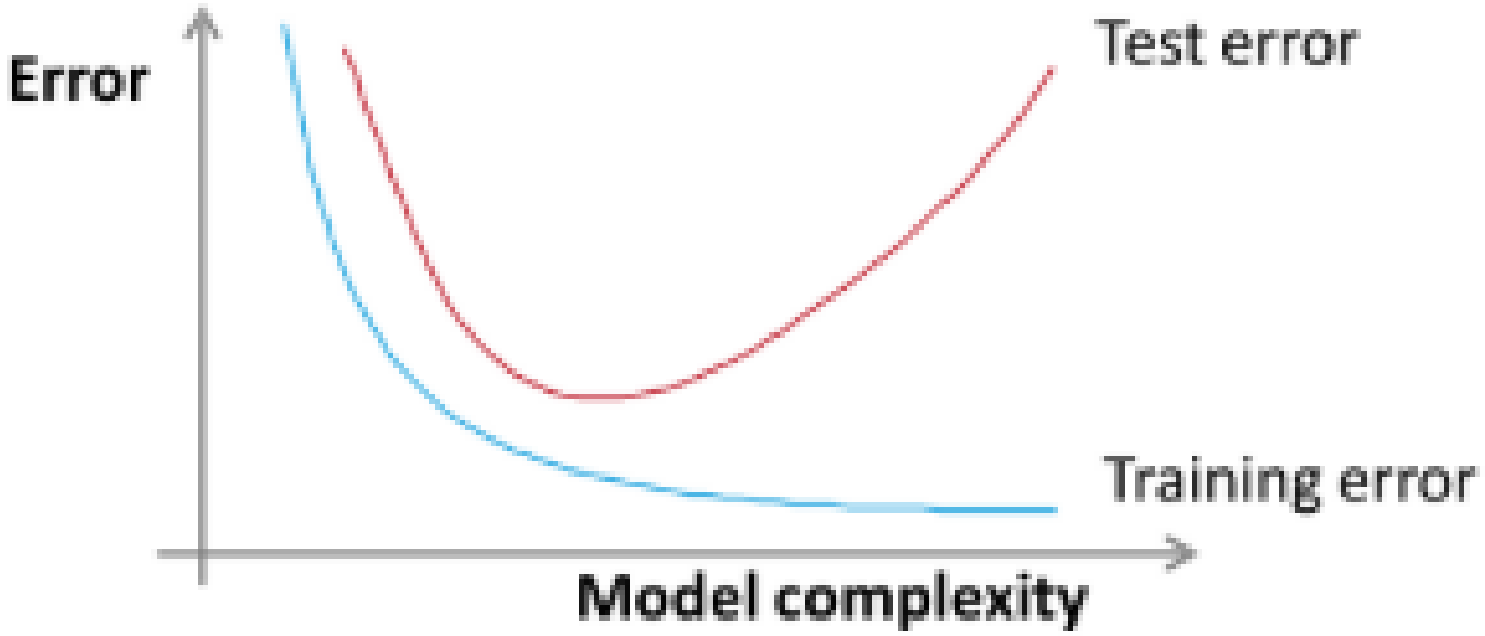
01 Membandingkan strategi klasifikasi multi-kelas one-vs-rest dan softmax beserta konsekuensinya.

02 Menghitung precision, recall, dan F1 dari sebuah confusion matrix dengan benar.

03 Menjelaskan mengapa akurasi menyesatkan pada data yang tidak seimbang.

04 Memilih dan menjustifikasi metrik evaluasi sesuai konteks masalah dan biaya kesalahan.

Indikator 02 dan 04 dinilai lewat Tugas Terstruktur 3 (bobot 4%) yang diberikan di akhir pertemuan ini, dan diuji kembali pada UTS.


Error
Test error
Training error
Model complexity

BAGIAN 1

Dari Dua Kelas ke Banyak Kelas

One-vs-Rest dan Softmax

KASUS PEMBUKA

Tiga status, bukan lagi dua

Dinas Perhubungan tidak lagi puas dengan jawaban terlambat atau tidak. Mereka ingin status yang lebih rinci untuk menentukan tindakan.

Tepat waktu	Terlambat ringan	Terlambat berat
Selisih di bawah 5 menit	Selisih 5 sampai 15 menit	Selisih di atas 15 menit
Tindakan:	**Tindakan:**	**Tindakan:**
Tidak perlu tindakan	**Umumkan lewat papan informasi**	**Siagakan armada cadangan**

Masalahnya

Sigmoid hanya menghasilkan satu angka antara 0 dan 1 — cukup untuk dua kelas, tidak untuk tiga. Kita perlu cara memperluasnya. Ada dua pendekatan, dan keduanya masih memakai model linier yang sama.

PENDEKATAN PERTAMA

One-vs-Rest: banyak model kecil

Latih satu model biner terpisah untuk setiap kelas. Tiap model menjawab satu pertanyaan sederhana: apakah ini kelas saya, atau bukan?

Model 1

Tepat waktu vs sisanya

keluaran sigmoid

0,20

Model 2

Terlambat ringan vs sisanya

keluaran sigmoid

0,75

Model 3

Terlambat berat vs sisanya

keluaran sigmoid

0,40

Keputusan akhir

Ambil kelas dengan keluaran tertinggi. Pada contoh di atas: terlambat ringan (0,75).

Untuk k kelas dibutuhkan k model terpisah.

Kelemahannya

Ketiga angka tidak dijamin berjumlah 1. Model dapat memberi 0,9 untuk dua kelas sekaligus, atau di bawah 0,3 untuk semuanya — keluarannya tidak dapat dibaca sebagai probabilitas yang utuh.

Softmax: satu model, banyak keluaran

Satu model menghasilkan satu skor mentah untuk tiap kelas. Softmax mengubah seluruh skor itu sekaligus menjadi probabilitas yang berjumlah tepat 1.

$$\text{softmax}(z_i) = e^{z_i} / \Sigma\, e^{z_j}$$

Kelas	Skor mentah z	e^z	Probabilitas softmax
Tepat waktu	0,5	1,65	0,15
Terlambat ringan	2,3	9,97	0,73
Terlambat berat	1,0	2,72	0,20
Jumlah	—	14,34	**1,00**

Karena berjumlah 1, keluaran softmax benar-benar dapat dibaca sebagai probabilitas — dan bisa dibandingkan antar-kelas secara adil.

Untuk dua kelas, softmax menghasilkan hasil yang persis sama dengan sigmoid. Ia bukan hal baru, melainkan perumuman.

PERBANDINGAN

One-vs-Rest atau Softmax?

	One-vs-Rest	Softmax
Jumlah model	k model biner terpisah	Satu model dengan k keluaran
Jumlah probabilitas	Tidak dijamin berjumlah 1	Selalu berjumlah tepat 1
Asumsi antar-kelas	Tiap kelas dinilai sendiri-sendiri	Kelas saling bersaing satu sama lain
Cocok untuk	Kasus di mana satu data boleh masuk lebih dari satu kelas	Kasus di mana kelas saling meniadakan (hanya satu benar)
Biaya pelatihan	Naik seiring jumlah kelas	Tetap satu kali pelatihan
Fungsi loss	Cross-entropy biner, k kali	Cross-entropy kategorik

Kasus kita — status perjalanan — bersifat saling meniadakan: satu bus tidak mungkin tepat waktu sekaligus terlambat berat. Softmax lebih tepat.

BAGIAN 2

Confusion Matrix

Membongkar satu angka akurasi menjadi empat

ANATOMI

Empat kotak yang menjelaskan segalanya

Ambil kembali hasil latihan ambang batas pertemuan lalu pada ambang 0,50, lalu susun ulang menjadi tabel ini.

KELAS SEBENARNYA \ PREDIKSI MODEL	Negatif (0)	Positif (1)
Negatif (0)	**TN** True Negative **4 kasus**	**FP** False Positive **1 kasus**
Positif (1)	**FN** False Negative **1 kasus**	**TP** True Positive **4 kasus**

Jembatan dari pertemuan lalu

FP adalah peringatan palsu — kesalahan tipe I. FN adalah keterlambatan yang terlewat — kesalahan tipe II.
Menggeser ambang batas memindahkan angka antara kedua kotak merah itu, tanpa mengubah jumlah data.

TURUNANNYA

Empat metrik dari empat kotak

Accuracy

`(TP + TN) / semua`

Berapa bagian prediksi yang benar

Menyesatkan bila kelas timpang

Precision

`TP / (TP + FP)`

Dari yang ditandai positif,
berapa yang benar-benar positif

Dipakai bila peringatan palsu mahal

Recall

`TP / (TP + FN)`

Dari seluruh positif yang ada,
berapa yang berhasil ditemukan

Dipakai bila kasus terlewat berbahaya

F1-score

`2·P·R / (P + R)`

Rata-rata harmonik precision
dan recall

Dipakai bila keduanya sama penting

Tidak ada metrik yang unggul secara mutlak. Yang ada hanyalah metrik yang sesuai atau tidak sesuai dengan konteks masalah.

Predicted / Actual	Yes	No	Total
Yes	TP	FN	P
No	FP	TN	N
Total	P'	N'	$P + N$

Confusion matrix

Measurement	Formula
Accuracy, recognition rate	$\frac{TP + TN}{P + N}$
Error rate, misclassification rate	$\frac{FP + FN}{P + N}$
True positive rate, sensitivity, recall	$\frac{TP}{P}$
True negative rate, specificity	$\frac{TN}{N}$
Precision	$\frac{TP}{TP + FP}$
F_1 value, harmonic mean of precision and recall	$\frac{2 \times precision \times recall}{precision + recall}$
F_β value, where β is a non-negative real number	$\frac{(1 + \beta^2) \times precision \times recall}{\beta^2 \times precision + recall}$

Hitung dan bandingkan dua model

Kerjakan berpasangan · 15 menit · Dari 1.000 perjalanan, 60 di antaranya benar-benar terlambat

MODEL A

TP = 27
FN = 33
FP = 18
TN = 922

MODEL B

TP = 51
FN = 9
FP = 210
TN = 730

Metrik	Model A	Model B
Accuracy		
Precision		
Recall		
F1-score		

Setelah tabel terisi, jawab tiga hal

- Model mana yang punya akurasi lebih tinggi? Apakah itu berarti model tersebut lebih baik?
- Model mana yang lebih banyak menemukan keterlambatan sebenarnya? Metrik mana yang menunjukkannya?
- Bila Anda Kepala Dinas Perhubungan yang bertanggung jawab atas kepercayaan penumpang, model mana yang Anda pilih, dan apa harga yang harus Anda bayar untuk pilihan itu?

BAGIAN 3

Ketika Akurasi Berbohong

Data tidak seimbang dan biaya kesalahan

Model yang tidak melakukan apa pun

Bayangkan sebuah model yang selalu menjawab "tidak terlambat" untuk setiap perjalanan, tanpa melihat data sama sekali.

	Prediksi: Negatif	Prediksi: Positif
Sebenarnya negatif	TN = 940	FP = 0
Sebenarnya positif	FN = 60	TP = 0

Accuracy	94,0%	Terlihat mengesankan
Recall	0%	Tidak satu pun keterlambatan ditemukan
Precision	tak terdefinisi	Pembaginya nol — tidak ada prediksi positif

Model ini sepenuhnya tidak berguna, tetapi akurasinya 94%. Setiap kali Anda melihat akurasi tinggi, pertanyaan pertama yang wajib diajukan adalah: berapa proporsi kelas positif dalam data ini?

TARIK-MENARIK

Precision dan recall jarang naik bersama

Mengutamakan Precision

Model hanya menandai positif bila sangat yakin. Peringatan palsu sedikit, tetapi banyak kasus nyata terlewat.

Contoh penerapan

- Penyaringan lamaran kerja otomatis
- Rekomendasi produk berbayar
- Penandaan konten untuk dihapus

Mengutamakan Recall

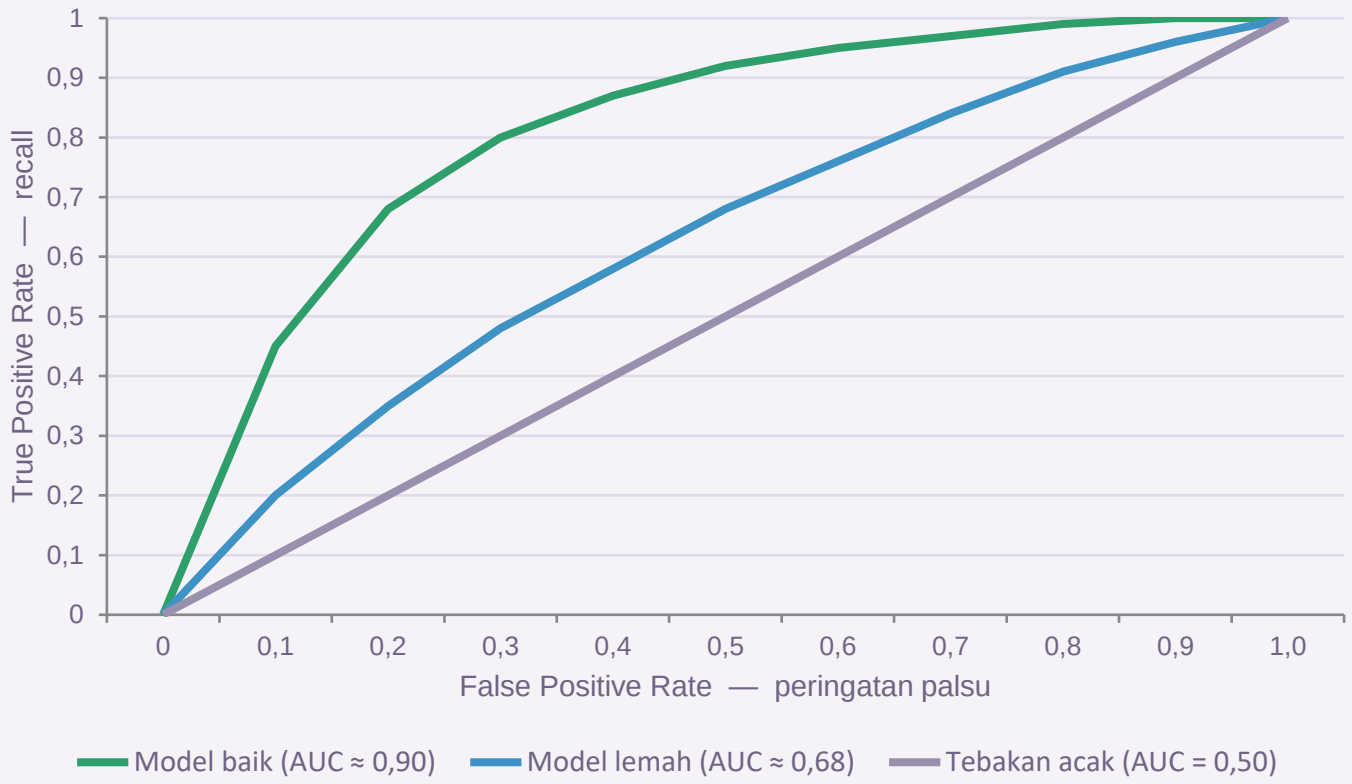
Model menandai positif meski ragu. Hampir semua kasus nyata tertangkap, tetapi peringatan palsu membanjir.

Contoh penerapan

- Penapisan awal penyakit menular
- Deteksi penipuan transaksi
- Peringatan dini bencana

F1-score memakai rata-rata harmonik, bukan rata-rata biasa. Akibatnya, model dengan precision 0,95 dan recall 0,05 hanya memperoleh F1 sebesar 0,095 — tidak bisa menyembunyikan kelemahan di salah satu sisi.

Kurva ROC dan AUC



Apa yang digambar

Setiap titik pada kurva mewakili satu nilai ambang batas. Kurva menelusuri seluruh kemungkinan sekaligus.

Cara membaca

Semakin melengkung ke pojok kiri atas, semakin baik. Garis diagonal berarti model tidak lebih baik dari menebak.

AUC

Luas di bawah kurva. Nilainya satu angka antara 0,5 dan 1 yang meringkas kinerja di semua ambang.

Keterbatasan

Pada data yang sangat timpang, AUC tetap dapat terlihat tinggi. Precision-Recall Curve lebih jujur untuk kasus itu.

Confusion matrix tiga kelas

	Diprediksi Tepat waktu	Diprediksi Terlambat ringan	Diprediksi Terlambat berat	Jumlah sebenarnya
Sebenarnya tepat waktu	410	35	5	450
Sebenarnya terlambat ringan	48	92	30	170
Sebenarnya terlambat berat	12	26	42	80
Jumlah diprediksi	470	153	77	**700**

Diagonal utama

Kotak hijau adalah prediksi yang benar. Semua kotak lain adalah kesalahan.

Precision per kelas

Dibaca menurut kolom. Untuk terlambat berat: 42 dari 77, atau 0,55.

Recall per kelas

Dibaca menurut baris. Untuk terlambat berat: 42 dari 80, atau 0,53.

Untuk memperoleh satu angka ringkasan, precision dan recall tiap kelas dirata-ratakan — macro average memperlakukan semua kelas setara, weighted average menimbang menurut jumlah data.

BAGIAN 4

Metrik untuk Regresi

Ketika keluarannya kembali berupa angka

PELENGKAP

Empat metrik untuk model regresi

Metrik	Rumus inti	Satuan hasil	Kapan dipilih
MSE	rata-rata (galat)²	Kuadrat satuan asli	Saat galat besar harus dihindari sekuat tenaga
RMSE	akar dari MSE	Sama dengan satuan asli	Saat ingin sifat MSE tetapi hasilnya mudah dibaca
MAE	rata-rata |galat|	Sama dengan satuan asli	Saat data mengandung pencilan yang wajar
R^2	1 − (galat model / galat rata-rata)	Tanpa satuan, 0 sampai 1	Saat ingin tahu seberapa baik dibanding tebakan rata-rata

Contoh membaca RMSE

RMSE = 4,2 menit berarti model rata-rata meleset sekitar 4,2 menit — langsung dapat dijelaskan kepada Kepala Dinas tanpa penerjemahan.

Peringatan tentang R^2

R^2 selalu naik ketika fitur ditambahkan, meski fitur itu tidak berguna. Gunakan Adjusted R^2 bila membandingkan model dengan jumlah fitur berbeda.

DISKUSI KASUS

Empat konteks, empat metrik berbeda

A Penapisan awal penumpang bergejala penyakit menular di terminal bus antarkota.

B Sistem otomatis yang memblokir akun penumpang yang diduga menyalahgunakan kartu langganan.

C Perkiraan waktu kedatangan bus yang ditampilkan pada papan informasi halte.

D Model yang memprediksi kerusakan mesin bus, dengan hanya 1,2% data berlabel rusak.

Untuk tiap konteks: metrik apa yang Anda jadikan patokan utama, dan mengapa? Sebutkan juga metrik yang justru berbahaya bila dipakai di situ.

Diskusi kelompok 4 orang · 15 menit.

WASPADAI

Empat salah kaprah yang paling sering

Akurasi tinggi berarti model baik

Pada data timpang, model yang tidak melakukan apa pun bisa mencapai akurasi di atas 95%.

F1 selalu metrik yang paling aman

F1 memperlakukan precision dan recall setara. Bila biaya keduanya jauh berbeda, F1 menyembunyikan hal yang penting.

Precision dan recall bisa dimaksimalkan bersama

Pada model yang sama, menaikkan satu hampir selalu menurunkan yang lain. Yang bisa dinaikkan bersama hanya lewat model yang lebih baik.

AUC tinggi berarti aman dipakai

AUC menilai pemeringkatan, bukan keputusan. Model dengan AUC 0,95 tetap bisa buruk pada ambang yang Anda pilih.

RINGKASAN

Yang perlu Anda bawa pulang

Multi-kelas

One-vs-Rest melatih k model terpisah; softmax satu model berjumlah 1.

Confusion matrix

Empat kotak: TP, TN, FP, FN. Semua metrik lahir dari sini.

Precision

Dari yang ditandai positif, berapa yang benar. Kolom prediksi positif.

Recall

Dari seluruh positif nyata, berapa yang ditemukan. Baris positif nyata.

Akurasi

Menyesatkan pada data timpang. Selalu tanyakan proporsi kelas.

Pemilihan metrik

Keputusan berdasarkan biaya kesalahan, bukan kebiasaan.

TINDAK LANJUT

Tugas Terstruktur 3 dan persiapan UTS

PT

Tugas Terstruktur 3 · Bobot 4%

Soal kasus: menghitung metrik dari confusion matrix yang diberikan, lalu menjustifikasi pemilihan metrik untuk kasus dengan biaya kesalahan asimetris.

BM

Belajar Mandiri · 180 menit

Membaca Géron [1] Bab 3 mengenai evaluasi model klasifikasi, serta ISL [11] Bab 4.

Persiapan Ujian Tengah Semester · Pertemuan 8

Ujian tertulis terjadwal 100 menit atas materi pertemuan 1 sampai 7. Komposisi soal: 40% konsep dan 60% analisis kasus. Tidak ada soal yang menuntut menulis kode.

- Bentuk soal analisis: diberikan keluaran model, confusion matrix, atau kurva pembelajaran — Anda diminta menafsirkan dan merekomendasikan perbaikan
- Rekomendasi tanpa alasan tidak memperoleh nilai penuh, sekalipun tindakannya benar
- Bawa kalkulator sederhana. Tabel rumus metrik akan disediakan pada lembar soal

PERTEMUAN BERIKUTNYA

Ujian Tengah Semester

Tujuh pertemuan terakhir membangun satu kemampuan: menilai apakah sebuah model benar-benar bekerja, dan mengatakannya dengan jujur. Itulah yang diuji.

Setelah UTS: cross-validation dan tuning hyperparameter, model berbasis pohon, clustering, neural network, hingga CNN, RNN, dan Large Language Model.