DATA SCIENCE · TI24425 · PERTEMUAN 9

Validasi Model dan Tuning Hyperparameter

Sub-CPMK 8 · Mampu menganalisis prosedur cross-validation dan tuning hyperparameter, serta mengevaluasi validitas suatu prosedur evaluasi model.

Program Studi Teknologi Informasi · Politeknik Negeri Madiun

ORIENTASI

Kembali setelah ujian

8 SELESAI

Ujian Tengah Semester

Materi pertemuan 1–7
sudah diuji.

9 HARI INI

Validasi & Tuning

Bagaimana memastikan
angka evaluasi kita jujur.

10 BERIKUTNYA

Model Berbasis Pohon

Keluarga model baru:
decision tree dan ensemble.

Tujuh pertemuan pertama mengajarkan cara membangun dan menilai model. Hari ini kita bertanya satu tingkat lebih dalam: dari mana kita tahu bahwa angka penilaian itu sendiri dapat dipercaya?

CAPAIAN PEMBELAJARAN

Setelah pertemuan ini Anda mampu…

01 Membedakan parameter dan hyperparameter, serta menjelaskan mengapa keduanya diperlakukan berbeda.

02 Menjelaskan mekanisme dan tujuan k-fold cross-validation, termasuk cara membaca hasilnya.

03 Menilai validitas sebuah prosedur evaluasi dan menunjukkan letak kebocoran data bila ada.

04 Membandingkan grid search dan random search dari sisi biaya komputasi.

Indikator 03 adalah inti pertemuan ini, dan akan diuji kembali pada Studi Kasus Akhir maupun Ujian Akhir Semester.

BAGIAN 1

Parameter dan Hyperparameter

Dua jenis angka yang sering tertukar

PEMBEDAAN DASAR

Siapa yang menentukan angkanya?

PARAMETER

Dipelajari model dari data

- Ditemukan selama pelatihan berlangsung
- Nilainya berubah tiap iterasi Gradient Descent
- Jumlahnya bisa ribuan hingga miliaran
- Anda tidak menyentuhnya secara langsung

Contoh: bobot w dan bias b pada regresi

HYPERPARAMETER

Ditetapkan manusia sebelum pelatihan

- Ditetapkan sebelum pelatihan dimulai
- Nilainya tetap selama satu kali pelatihan
- Jumlahnya biasanya di bawah sepuluh
- Andalah yang bertanggung jawab memilihnya

Contoh: learning rate α dan λ pada regularisasi

Hyperparameter tidak bisa dipilih dengan menebak. Diperlukan prosedur pencarian yang sistematis — dan prosedur itulah isi pertemuan hari ini.

REKAPITULASI

Hyperparameter yang sudah kita temui

α	**Learning rate** Pertemuan 4	Terlalu besar: loss meledak. Terlalu kecil: konvergensi lambat.
λ	**Kekuatan regularisasi** Pertemuan 5	Terlalu besar: underfitting. Terlalu kecil: overfitting kembali.
$-$	**Ambang batas keputusan** Pertemuan 6	Menggeser komposisi kesalahan tipe I dan tipe II.
k	**Jumlah fold** Hari ini	Menentukan keseimbangan antara ketelitian dan biaya komputasi.

Setiap model baru membawa hyperparameternya sendiri. Pertemuan depan bertambah lagi: kedalaman pohon dan jumlah pohon.

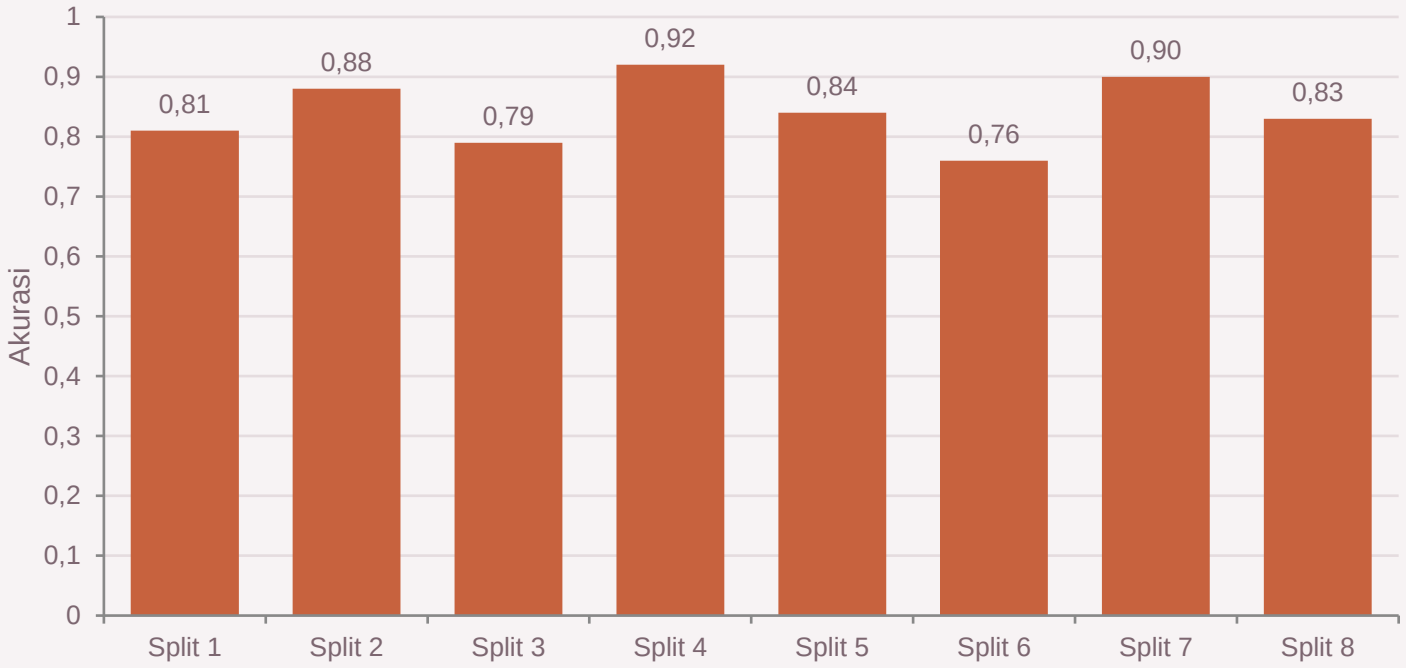
BAGIAN 2

Masalah dengan Satu Pembagian

Mengapa satu train-test split tidak cukup

Model yang sama, delapan jawaban berbeda

Model yang persis sama dilatih dan diuji delapan kali. Yang berubah hanya satu hal: baris mana yang kebetulan masuk ke data uji.



Rentang 0,76 sampai 0,92

Selisihnya 16 poin persentase — cukup besar untuk mengubah keputusan pembelian sistem.

Mana yang benar?

Semuanya benar, dan semuanya menyesatkan bila dilaporkan sendirian.

Godaan yang berbahaya

Menjalankan ulang sampai muncul angka yang bagus, lalu melaporkan angka itu saja.

Satu angka dari satu pembagian bukan pengukuran — ia satu lemparan dadu.

Tiga bagian, tiga tugas berbeda

DATA LATIH

≈ 60%

Model mempelajari parameternya di sini. Boleh dilihat berkali-kali.

DATA VALIDASI

≈ 20%

Tempat membandingkan hyperparameter dan memilih model. Boleh dilihat berulang.

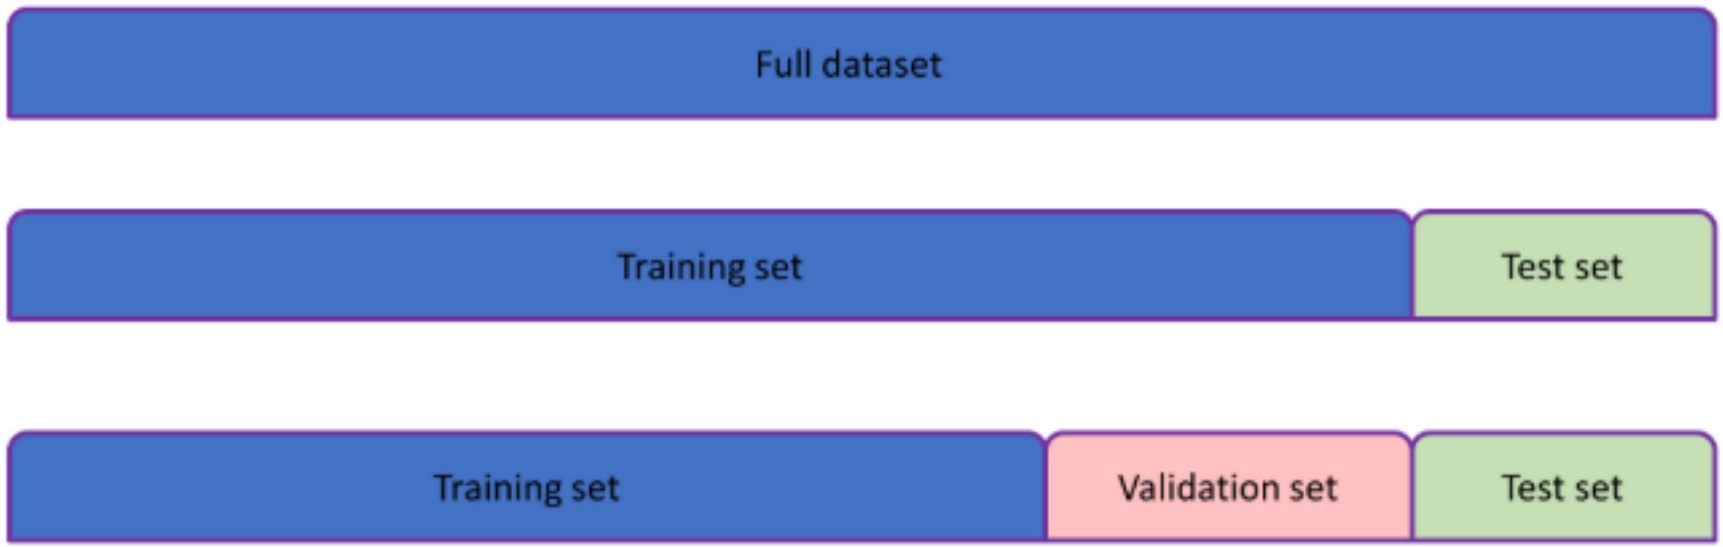
DATA UJI

≈ 20%

Disegel sampai akhir. Dibuka satu kali saja, untuk melaporkan hasil.

Aturan yang tidak boleh dilanggar

Begitu data uji dipakai untuk memilih sesuatu — model, hyperparameter, bahkan ambang batas — ia berhenti menjadi data uji. Sejak saat itu angkanya tidak lagi menggambarkan kinerja pada data yang benar-benar baru.


Full dataset
Training set
Test set
Training set
Validation set
Test set

BAGIAN 3

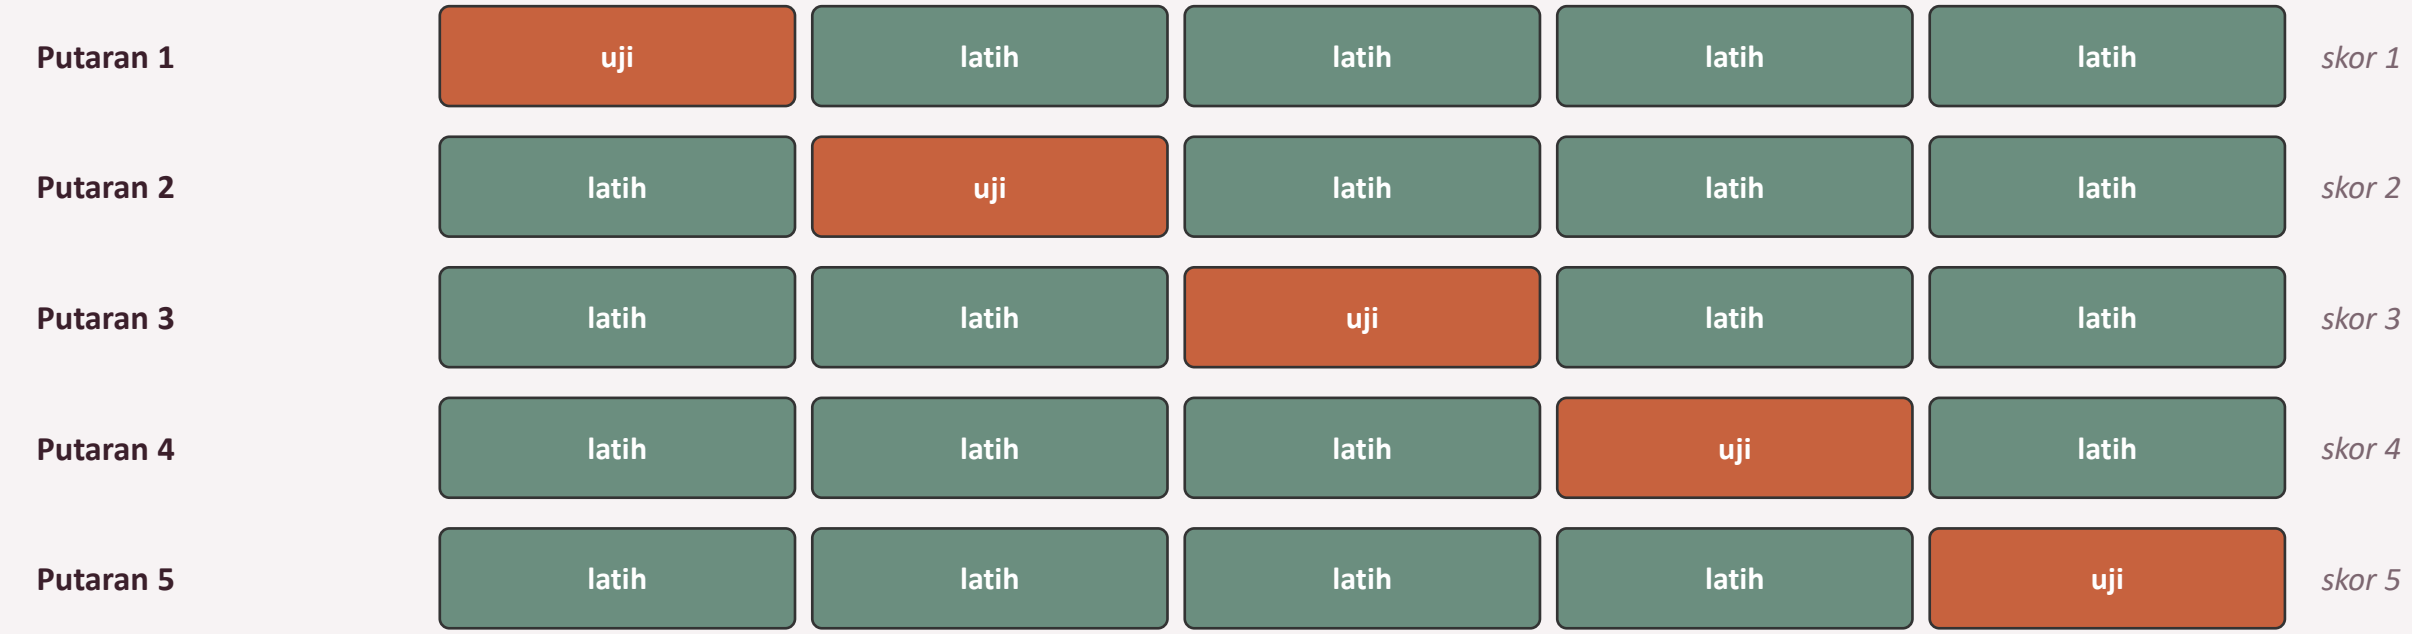
k-Fold Cross-Validation

Memakai seluruh data sebagai penguji, bergantian

MEKANISME

Lima putaran, lima penguji berbeda

Data latih dibagi menjadi k bagian sama besar. Setiap putaran, satu bagian menjadi penguji dan sisanya menjadi pelatih. Diulang sampai semua bagian pernah menjadi penguji.



Hasil akhir adalah rata-rata dari kelima skor — bukan salah satu di antaranya.

Setiap baris data pernah menjadi penguji tepat satu kali, dan menjadi pelatih k−1 kali. Tidak ada data yang terbuang.

Dua angka, bukan satu

Rata-rata

Perkiraan kinerja model pada data baru. Ini angka yang biasanya dilaporkan.

Simpangan baku

Seberapa goyah kinerja itu antar-fold. Sering diabaikan, padahal sama pentingnya.

Hasil 5-fold	Rata-rata	Simpangan baku	Cara membacanya
0,84 0,86 0,85 0,84 0,86	0,850	0,009	Stabil — dapat dipercaya
0,92 0,74 0,95 0,71 0,93	0,850	0,115	Goyah — rata-rata menyembunyikan kekacauan
0,62 0,64 0,63 0,62 0,64	0,630	0,010	Stabil tetapi lemah — kemungkinan underfitting

Baris kedua adalah peringatan penting: dua model dengan rata-rata identik bisa sangat berbeda kualitasnya. Simpangan baku yang besar biasanya menandakan data terlalu sedikit atau ada fold yang komposisinya jauh berbeda.

VARIAN PENTING

Ketika pembagian acak tidak cukup

Stratified k-fold	**Menjaga proporsi tiap kelas tetap sama di setiap fold.**	Wajib dipakai pada data tidak seimbang. Dengan 3% kelas positif, pembagian acak bisa menghasilkan fold yang sama sekali tidak berisi kelas positif.
Time series split	**Fold disusun menurut urutan waktu, tidak diacak.**	Wajib untuk data berurut waktu. Melatih dengan data masa depan untuk memprediksi masa lalu adalah kebocoran yang sering tidak disadari.
Group k-fold	**Menjaga data dari satu sumber tidak terpecah antar-fold.**	Dipakai bila satu bus, satu pasien, atau satu pengguna menyumbang banyak baris data yang saling berkaitan.

Pembagian acak adalah bawaan perangkat lunak, bukan pilihan yang selalu benar. Periksa dulu sifat data Anda.

LATIHAN TERBIMBING 1

Membaca hasil cross-validation

Kerjakan berpasangan · 12 menit · Cukup kertas dan kalkulator sederhana

Dua model diuji dengan 5-fold cross-validation pada data yang sama. Berikut skor akurasi tiap fold.

Model	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Rata-rata	Simpangan
Model A	0,86	0,84	0,87	0,85	0,83		
Model B	0,92	0,74	0,95	0,71	0,93		

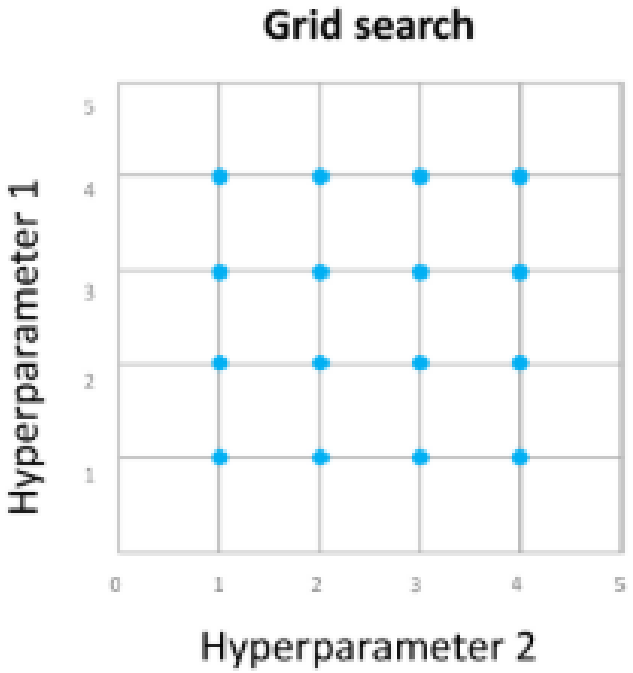
Setelah tabel terisi, jawab empat hal

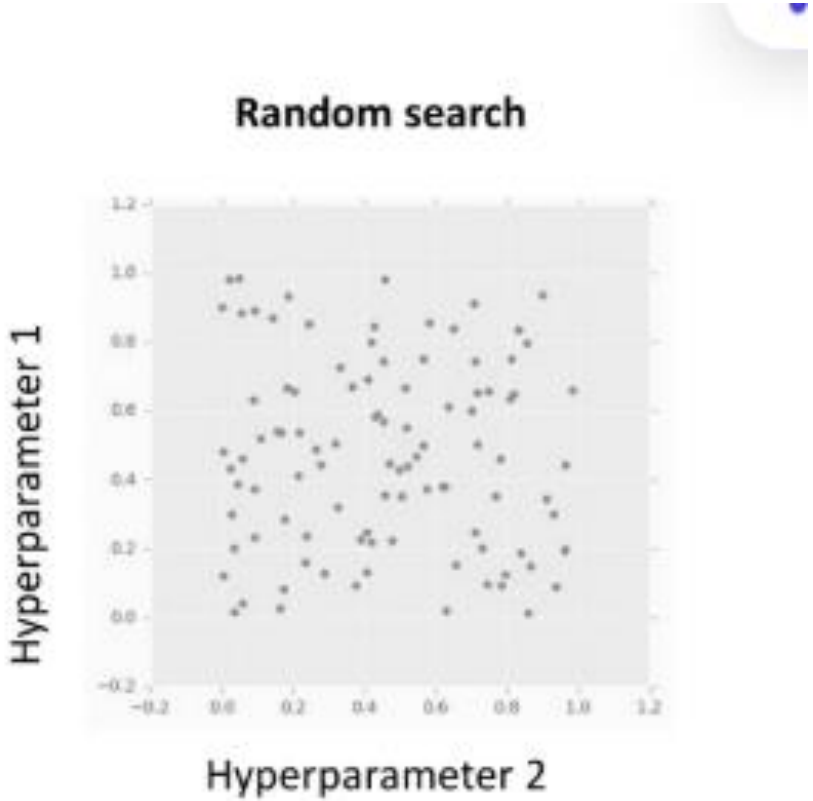
- Berapa rata-rata masing-masing? Apakah keduanya sama?
- Model mana yang simpangan bakunya jauh lebih besar? Apa artinya?
- Bila Anda hanya melihat Fold 3, model mana yang tampak lebih unggul? Apa bahayanya kesimpulan itu?
- Model mana yang Anda pilih untuk dipakai, dan apa satu langkah yang akan Anda lakukan lebih dulu sebelum memutuskan?

BAGIAN 4

Tuning Hyperparameter

Mencari kombinasi terbaik secara sistematis


Grid search
Hyperparameter 1
Hyperparameter 2
0
1
2
3
4
5


Random search
Hyperparameter 1
Hyperparameter 2

Grid search: coba semua kombinasi

Tentukan daftar nilai untuk tiap hyperparameter, lalu uji setiap kombinasi yang mungkin dengan cross-validation.

Contoh daftar nilai

$\lambda \in \{ 0{,}01 ; 0{,}1 ; 1 ; 10 \}$

$\alpha \in \{ 0{,}001 ; 0{,}01 ; 0{,}1 \}$

$\text{jenis} \in \{ \text{Ridge} ; \text{Lasso} \}$

$$4 \times 3 \times 2 = 24 \text{ kombinasi}$$
$$\times 5 \text{ fold}$$
$$= 120 \text{ kali pelatihan}$$

+ Menyeluruh — tidak ada kombinasi dalam daftar yang terlewat
+ Hasilnya dapat diulang persis oleh orang lain
− Biaya tumbuh secara perkalian — menambah satu hyperparameter dapat melipatgandakan waktu
− Banyak waktu terbuang pada hyperparameter yang ternyata tidak berpengaruh

PENDEKATAN KEDUA

Random search: ambil sampel acak

Alih-alih mencoba semua kombinasi, tentukan rentang untuk tiap hyperparameter lalu ambil sejumlah kombinasi acak dari rentang itu.

	Grid Search	Random Search
Cara memilih kombinasi	Semua kombinasi dari daftar	Sejumlah n kombinasi acak dari rentang
Jumlah percobaan	Ditentukan oleh perkalian daftar	Ditentukan sendiri oleh Anda
Bila anggaran waktu terbatas	Harus memangkas daftar nilai	Cukup kurangi n, rentang tetap luas
Nilai yang dapat ditemukan	Hanya yang ada dalam daftar	Nilai apa pun dalam rentang
Saat sebagian hyperparameter tidak berpengaruh	Waktu terbuang mengulanginya	Tetap menjelajah yang berpengaruh

Temuan yang mengejutkan: pada sebagian besar kasus, random search dengan 60 percobaan menemukan hasil yang setara dengan grid search yang mencoba ratusan kombinasi — karena biasanya hanya satu atau dua hyperparameter yang benar-benar berpengaruh.

ALUR KERJA

Urutan yang benar dari awal sampai akhir

1	**Pisahkan data uji lebih dulu**	Sebelum melihat apa pun. Segel dan jangan disentuh.
2	**Lakukan praproses hanya pada data latih**	Rata-rata dan simpangan untuk penskalaan dihitung dari data latih saja.
3	**Jalankan pencarian hyperparameter dengan cross-validation**	Seluruh pencarian berlangsung di dalam data latih.
4	**Latih ulang model terbaik pada seluruh data latih**	Dengan hyperparameter yang sudah terpilih.
5	**Buka segel data uji, evaluasi satu kali**	Angka inilah yang dilaporkan. Tidak boleh diulang.

Bila langkah 5 menghasilkan angka yang mengecewakan, Anda tidak boleh kembali ke langkah 3 lalu mengulang langkah 5. Itu mengubah data uji menjadi data validasi.

BAGIAN 5

Kebocoran Data

Kesalahan yang membuat seluruh angka tidak berarti

DUA BENTUK UTAMA

Dari mana informasi masa depan menyusup

Praproses sebelum pembagian

Bentuknya

Data dinormalisasi memakai rata-rata dan simpangan dari seluruh dataset, baru kemudian dibagi.

Akibatnya

Statistik data uji ikut masuk ke dalam data latih. Model sudah tahu sesuatu tentang data yang seharusnya asing baginya.

Gejalanya: skor pada data uji terlihat terlalu bagus dan tidak pernah tercapai lagi setelah sistem dipakai.

Memilih berdasarkan data uji

Bentuknya

Beberapa model dicoba, semuanya dinilai pada data uji, lalu yang skornya tertinggi dilaporkan.

Akibatnya

Data uji berubah fungsi menjadi data validasi. Angka yang dilaporkan sudah dioptimalkan terhadapnya.

Gejalanya: model juara di laporan, tetapi biasa saja ketika benar-benar dipakai.

Kebocoran data tidak membuat model menjadi buruk. Ia membuat kita tidak tahu apakah model itu baik atau buruk.

LATIHAN TERBIMBING 2

Audit empat prosedur evaluasi

Kerjakan berkelompok tiga orang · 15 menit · Untuk tiap prosedur: valid atau tidak, dan tunjukkan letak masalahnya

P-1 Seluruh dataset dinormalisasi terlebih dahulu, kemudian dibagi menjadi data latih dan data uji. Model dilatih dan dievaluasi.

P-2 Data dibagi latih dan uji. Grid search dijalankan dengan 5-fold cross-validation di dalam data latih. Model terbaik dievaluasi satu kali pada data uji.

P-3 Data dibagi latih dan uji. Enam model dicoba, semuanya dievaluasi pada data uji, lalu model dengan skor tertinggi dilaporkan sebagai hasil akhir.

P-4 Data catatan perjalanan bus selama tiga tahun dibagi secara acak menjadi lima fold untuk cross-validation.

Petunjuk: tiga dari empat prosedur mengandung masalah. Bagian tersulit bukan menemukan yang salah, melainkan menjelaskan mengapa itu salah.

DISKUSI KASUS

Empat laporan dari lapangan

A Tim melaporkan akurasi 0,91 dari 5-fold cross-validation, tanpa menyebutkan simpangan bakunya sama sekali.

B Grid search dengan lima hyperparameter dan sepuluh nilai tiap hyperparameter diusulkan. Tenggat proyek tinggal tiga hari.

C Model deteksi kerusakan mesin dengan 1,5% kasus positif dievaluasi memakai k-fold biasa. Dua fold tidak berisi satu pun kasus positif.

D Setelah data uji dibuka dan hasilnya mengecewakan, tim kembali menyetel hyperparameter lalu menguji ulang pada data uji yang sama.

Untuk tiap laporan: apa masalahnya, dan apa satu tindakan pertama yang Anda sarankan? Jawab dengan alasan.

Diskusi kelompok 4 orang · 15 menit.

WASPADAI

Empat salah kaprah yang paling sering

Cross-validation membuat model lebih baik

Tidak. Ia hanya membuat penilaian kita lebih dapat dipercaya. Modelnya sendiri tidak berubah.

Semakin besar k semakin baik

k besar memberi perkiraan lebih teliti tetapi jauh lebih mahal, dan hasilnya menjadi lebih goyah antar-fold.

Data validasi dan data uji itu sama saja

Data validasi boleh dilihat berkali-kali untuk memilih. Data uji hanya boleh dibuka sekali, di akhir.

Kebocoran data selalu terlihat dari hasilnya

Justru sebaliknya. Gejalanya adalah hasil yang bagus — dan itulah yang membuatnya sulit disadari.

RINGKASAN

Yang perlu Anda bawa pulang

Dua jenis angka

Parameter dipelajari model.
Hyperparameter ditetapkan Anda.

Satu split rapuh

Skornya bergantung pada baris mana yang kebetulan masuk data uji.

k-fold

Semua data bergiliran menjadi penguji. Laporkan rata-rata dan simpangan.

Stratified

Wajib pada data tidak seimbang.
Time series split untuk data berurut.

Grid vs Random

Grid menyeluruh tetapi mahal.
Random lebih hemat pada anggaran ketat.

Data uji disegel

Dibuka satu kali di akhir. Sekali dipakai memilih, ia tidak sah lagi.

TINDAK LANJUT

Sebelum pertemuan berikutnya

BM

Belajar Mandiri · 180 menit

Membaca Géron [1] Bab 2 mengenai cross-validation dan pencarian hyperparameter, serta ISL [11] Bab 5.

PT

Penugasan Terstruktur · 180 menit

Latihan audit: menilai validitas empat skenario prosedur evaluasi model dan menunjukkan letak kesalahannya.

Latihan ini bersifat formatif — tidak berbobot tersendiri. Kontribusi Anda saat pembahasan di kelas dinilai melalui komponen Aktivitas Partisipatif.

Catatan untuk Studi Kasus Akhir: bagian B.5 dokumen tugas meminta Anda menunjukkan di titik mana prosedur Anda berpotensi mengalami kebocoran data. Materi hari ini adalah bekal langsung untuk bagian itu.

Bacaan pendukung: [1] Géron Bab 2 · [11] James dkk. Bab 5 · [9] CS 189/289A — https://eecs189.org/

PERTEMUAN BERIKUTNYA

Model Berbasis Pohon dan Ensemble

Hari ini kita belajar memastikan angka penilaian kita jujur. Pertemuan depan kita memakai prosedur itu untuk menilai keluarga model yang sama sekali baru — dan Anda akan memaparkan satu algoritma pilihan Anda sendiri lewat Presentasi Kilat.