DATA SCIENCE · TI24425 · PERTEMUAN 10

Model Berbasis Pohon dan Ensemble

Sub-CPMK 9 · Mampu menganalisis mekanisme model berbasis pohon dan ensemble, serta membandingkan karakteristiknya dengan model linier.

Program Studi Teknologi Informasi · Politeknik Negeri Madiun

ORIENTASI

Di mana kita sekarang?

9 SELESAI

Validasi & Tuning

Kita sudah bisa mengukur kinerja model dengan jujur.

10 HARI INI

Model Berbasis Pohon

Keluarga model baru yang bekerja dengan cara berbeda.

11 BERIKUTNYA

Clustering & Probabilitas

Belajar tanpa label — menemukan kelompok sendiri.

Selama enam pertemuan kita hanya mengenal satu bentuk model: garis lurus. Hari ini kita berkenalan dengan bentuk yang sama sekali berbeda — dan justru inilah yang paling banyak dipakai industri untuk data berbentuk tabel.

CAPAIAN PEMBELAJARAN

Setelah pertemuan ini Anda mampu…

01 Menghitung kriteria pemisahan (Gini atau information gain) dan menentukan simpul pemisah pertama.

02 Menjelaskan mekanisme bagging dan boosting serta perbedaan mendasar keduanya.

03 Menjustifikasi pemilihan antara model linier dan model berbasis pohon untuk suatu kasus.

04 Menjelaskan prinsip kerja satu algoritma di luar materi kuliah secara mandiri.

Indikator 01 dan 03 dinilai lewat Tugas Terstruktur 4 (bobot 4%). Indikator 04 dinilai lewat Presentasi Kilat Algoritma di akhir pertemuan ini.

BAGIAN 1

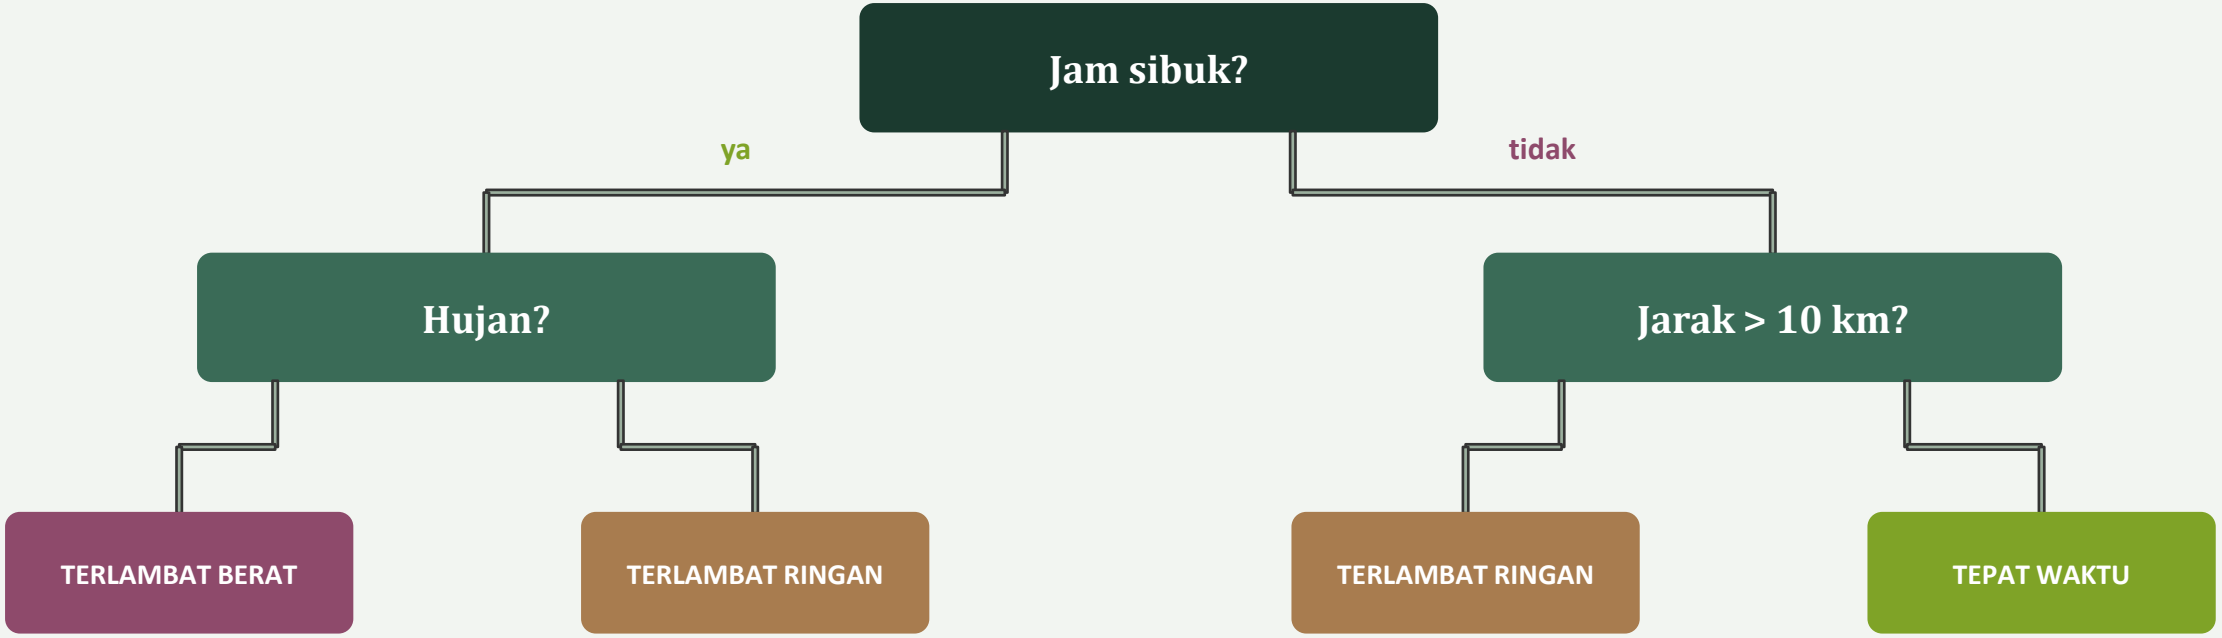
Decision Tree

Model yang menjelaskan dirinya sendiri

KASUS PEMBUKA

Model yang bisa dibaca manusia

Kepala Dinas Perhubungan menolak model regresi karena tidak bisa dijelaskan kepada petugas lapangan. Ia meminta aturan yang bisa dibaca. Inilah yang dihasilkan sebuah decision tree.



Petugas lapangan dapat membacanya tanpa pelatihan: bila jam sibuk dan hujan, siagakan armada cadangan. Tidak ada koefisien, tidak ada log-odds, tidak ada yang perlu diterjemahkan.

Bagian-bagian sebuah pohon

simpul

Simpul akar

Pertanyaan pertama yang diajukan model kepada seluruh data. Dipilih karena paling tajam memisahkan kelas.

simpul

Simpul internal

Pertanyaan lanjutan yang hanya berlaku bagi data yang sampai ke cabang itu.

cabang

Cabang

Jawaban atas pertanyaan. Untuk fitur ya-tidak ada dua cabang; untuk fitur numerik, dipecah pada satu ambang nilai.

daun

Daun

Ujung jalur. Tidak ada pertanyaan lagi — di sinilah keputusan atau nilai prediksi diberikan.

Setiap jalur dari akar ke daun adalah satu aturan lengkap. Sebuah pohon dengan delapan daun berarti delapan aturan — dan seluruhnya dapat ditulis di selembar kertas.

PERTANYAAN INTI

Pertanyaan mana yang harus diajukan lebih dulu?

Pohon tidak menebak. Ia mencoba setiap fitur, mengukur seberapa murni hasil pemisahannya, lalu memilih yang paling tajam.

Gini impurity

$$\text{Gini} = 1 - \sum p_i^2$$

Peluang salah menebak bila label diambil acak dari kelompok itu.

Nol berarti murni sempurna.
Maksimum 0,5 untuk dua kelas.

Entropy

$$H = -\sum p_i \log_2 p_i$$

Ukuran ketidakpastian dalam kelompok, dinyatakan dalam bit.

Nol berarti murni sempurna.
Maksimum 1 untuk dua kelas.

Yang dimaksimalkan: penurunan ketidakmurnian

Hitung ketidakmurnian sebelum pemisahan, lalu rata-rata tertimbang ketidakmurnian setelah pemisahan. Selisihnya disebut gain. Fitur dengan gain terbesar menjadi simpul pemisah.

CONTOH TERBIMBING

Menghitung gain untuk satu kandidat

Sepuluh perjalanan, lima terlambat dan lima tepat waktu. Kandidat pemisah: fitur "jam sibuk".

Sebelum dipisah

5 terlambat · 5 tepat waktu

Gini = 1 − (0,5² + 0,5²) = 0,500

Jam sibuk = YA

5 data · 4 terlambat, 1 tepat waktu

`Gini = 1 − (0,8² + 0,2²) = 0,320`

Jam sibuk = TIDAK

5 data · 1 terlambat, 4 tepat waktu

`Gini = 1 − (0,2² + 0,8²) = 0,320`

1 **Rata-rata tertimbang setelah pemisahan** `(5/10) × 0,320 + (5/10) × 0,320 = 0,320`

2 **Gain = ketidakmurnian sebelum − sesudah** `0,500 − 0,320 = 0,180`

3 **Bandingkan dengan kandidat fitur lain** `Fitur dengan gain terbesar menjadi simpul pemisah`

Perhatikan: pohon tidak menghitung jarak, tidak mengalikan bobot, tidak memakai gradien. Ia hanya menghitung proporsi.

LATIHAN TERBIMBING 1

Tentukan simpul pemisah pertama

Kerjakan berpasangan · 15 menit · Cukup kertas dan kalkulator sederhana

Data yang sama: 10 perjalanan, 5 terlambat dan 5 tepat waktu, Gini awal 0,500. Hitung gain untuk dua kandidat fitur berikut, lalu bandingkan dengan hasil "jam sibuk" (gain 0,180).

Kandidat A — Hujan

Hujan = YA

4 data · 3 terlambat, 1 tepat waktu

Hujan = TIDAK

6 data · 2 terlambat, 4 tepat waktu

Kandidat B — Jarak > 10 km

Jarak > 10 km = YA

5 data · 3 terlambat, 2 tepat waktu

Jarak > 10 km = TIDAK

5 data · 2 terlambat, 3 tepat waktu

Setelah selesai, jawab tiga hal

- Fitur mana yang menjadi simpul akar? Tunjukkan angkanya.
- Kandidat B menghasilkan gain sangat kecil. Apa artinya secara praktis tentang fitur jarak?
- Bila dua fitur menghasilkan gain persis sama, apa yang sebaiknya dijadikan pertimbangan berikutnya?

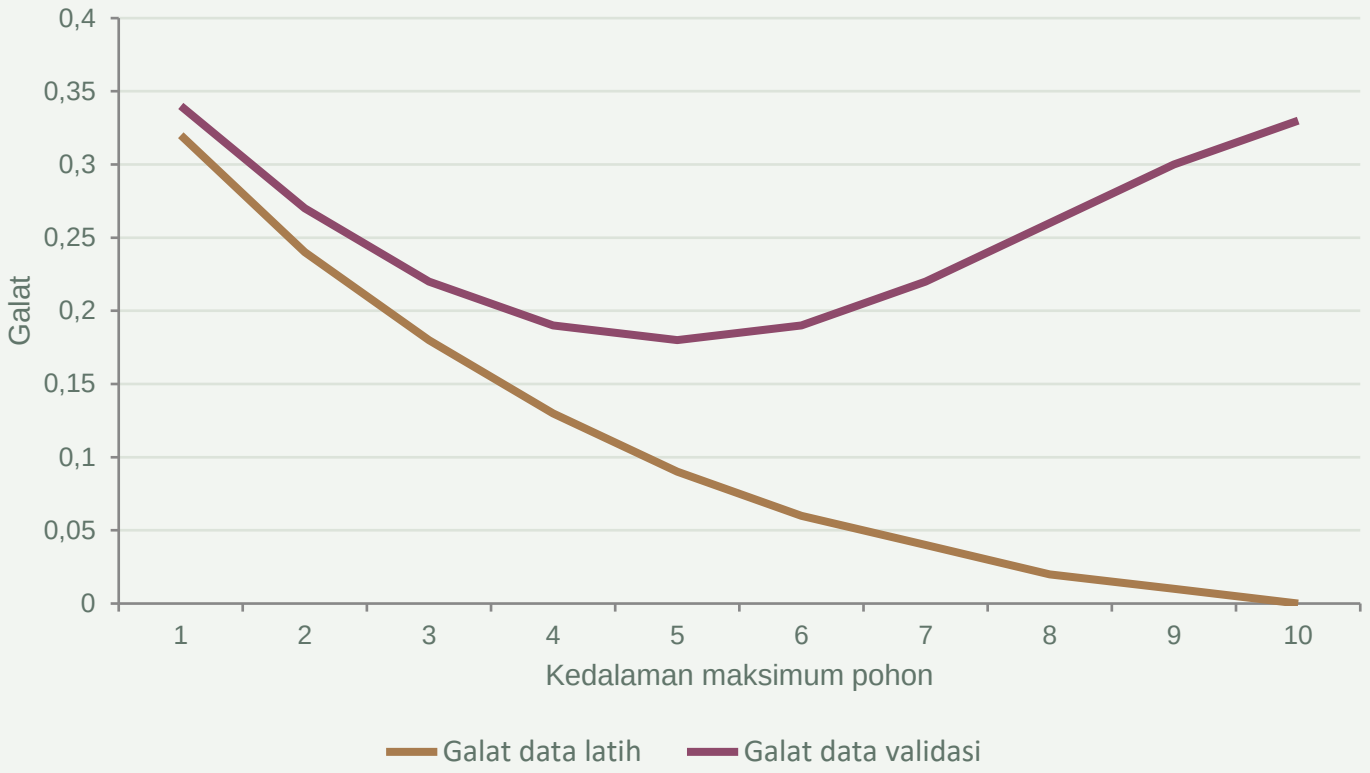
BAGIAN 2

Kedalaman dan Pemangkasan

Pohon yang dibiarkan tumbuh akan menghafal

BAHAYA

Pohon yang tumbuh tanpa henti



Galat latih menuju nol

Pohon yang cukup dalam dapat memisahkan setiap baris data ke daunnya sendiri.

Galat validasi berbalik naik

Mulai kedalaman 6, pohon berhenti belajar pola dan mulai menghafal derau.

Titik terbaik di kedalaman 5

Bukan yang paling dalam, bukan pula yang paling dangkal.

Gejala yang sudah kita kenal

Ini overfitting persis seperti pertemuan 5 — hanya penyebabnya kini kedalaman pohon.

Kedalaman maksimum adalah hyperparameter — dan dipilih persis dengan cara yang kita pelajari pertemuan lalu.

Tiga cara menahan pohon

Batasi kedalaman

`max_depth`

Tetapkan berapa lapis pertanyaan yang boleh diajukan. Cara paling langsung dan paling mudah dijelaskan.

Pra-pemangkasan

Batasi ukuran daun

`min_samples_leaf`

Sebuah daun harus memuat sekurang-kurangnya sejumlah data. Mencegah daun yang hanya berisi satu baris.

Pra-pemangkasan

Pangkas setelah tumbuh

`pruning`

Biarkan pohon tumbuh penuh, lalu potong cabang yang tidak memperbaiki kinerja pada data validasi.

Pasca-pemangkasan

Ada cara keempat yang jauh lebih ampuh, dan itulah isi bagian berikutnya: alih-alih menahan satu pohon, tanamlah banyak pohon sekaligus.

BAGIAN 3

Ensemble

Banyak model biasa mengalahkan satu model hebat

GAGASAN INTI

Kebijaksanaan orang banyak

Satu pohon tunggal punya variance tinggi — ganti sedikit datanya, bentuk pohonnya berubah drastis. Kelemahan itu justru menjadi bahan bakunya.

Bila kita menanam banyak pohon yang saling berbeda, lalu menggabungkan suaranya, kesalahan masing-masing cenderung saling meniadakan — sementara pola yang benar saling menguatkan.

Klasifikasi

Ambil suara terbanyak dari seluruh pohon.

Regresi

Ambil rata-rata prediksi seluruh pohon.

Syarat mutlak

Pohon-pohon itu harus benar-benar berbeda satu sama lain. Seribu pohon yang identik tidak lebih baik dari satu pohon — mereka akan salah bersama-sama.

Dua cara menciptakan perbedaan itu — bagging dan boosting — melahirkan dua keluarga algoritma yang sangat berbeda watak.

Bagging dan Random Forest

Latih banyak pohon secara sejajar dan saling bebas, masing-masing pada versi data yang sedikit berbeda.

1. **Ambil sampel data** — Dari data latih, ambil contoh acak dengan pengembalian — sebagian baris terambil berulang, sebagian tidak terambil sama sekali.
2. **Acak juga fiturnya** — Pada tiap simpul, hanya sebagian fitur yang boleh dipertimbangkan. Inilah yang membedakan Random Forest dari bagging biasa.
3. **Tanam pohon penuh** — Tiap pohon dibiarkan tumbuh dalam. Overfitting satu pohon tidak masalah karena akan diredam oleh yang lain.
4. **Gabungkan suaranya** — Suara terbanyak untuk klasifikasi, rata-rata untuk regresi.

Apa yang diperbaiki

Variance turun tajam tanpa menaikkan bias — satu-satunya perbaikan tanpa kompromi yang kita bahas di pertemuan 5.

Sifat praktis

- Sangat sulit dibuat overfitting
- Dapat dilatih paralel
- Hampir tidak perlu tuning
- Kehilangan keterbacaan

KELUARGA KEDUA

Boosting: belajar dari kesalahan

Latih pohon secara berurutan. Setiap pohon baru dibangun khusus untuk memperbaiki kesalahan yang ditinggalkan pohon-pohon sebelumnya.

Pohon 1

Menebak kasar. Banyak yang keliru.

›

Pohon 2

Fokus pada kasus yang keliru tadi.

›

Pohon 3

Fokus pada sisa kesalahan berikutnya.

›

Pohon n

Sisa kesalahan tinggal sedikit.

Yang diperbaiki

Bias turun tajam. Boosting mengubah sekumpulan pohon dangkal yang lemah menjadi satu model yang sangat akurat.

Harga yang dibayar

Rentan overfitting bila dibiarkan terlalu lama. Tidak bisa diparalelkan karena tiap pohon menunggu pendahulunya. Butuh tuning yang cermat.

Nama yang akan Anda temui: Gradient Boosting, XGBoost, LightGBM, CatBoost. Keempatnya varian dari gagasan yang sama.

PERBANDINGAN

Bagging atau boosting?

	Bagging · Random Forest	Boosting · XGBoost dan sejenisnya
Cara melatih	Sejajar dan saling bebas	Berurutan, saling bergantung
Sumber perbedaan	Sampel data dan fitur yang diacak	Fokus pada sisa kesalahan sebelumnya
Bentuk tiap pohon	Dalam dan penuh	Dangkal dan lemah
Yang diperbaiki	Variance	Bias
Risiko overfitting	Sangat rendah	Nyata bila iterasi berlebihan
Kebutuhan tuning	Ringan	Cermat — terutama learning rate
Waktu pelatihan	Dapat diparalelkan	Harus berurutan

Anjuran praktis: mulai dari Random Forest karena hampir bebas tuning. Beralih ke boosting hanya bila Anda punya waktu untuk menyetelnya dengan benar.

BAGIAN 4

Pohon atau Garis?

Memilih keluarga model dengan alasan

PERBANDINGAN

Model linier dan model berbasis pohon

Aspek	Model linier	Model berbasis pohon
Bentuk hubungan	Hanya lurus. Non-linearitas harus dibuatkan fitur sendiri.	Menangkap non-linearitas dan interaksi antar-fitur secara otomatis.
Variabel kategorik	Harus di-encode lebih dulu.	Ditangani langsung tanpa encoding.
Penskalaan fitur	Wajib, terutama bila diregularisasi.	Tidak diperlukan sama sekali.
Keterbacaan	Koefisien terbaca, tetapi maknanya perlu diterjemahkan (log-odds).	Pohon tunggal sangat terbaca. Ensemble justru sulit dibaca.
Ekstrapolasi	Dapat memprediksi di luar rentang data latih.	Tidak bisa — prediksi terkunci pada rentang yang pernah dilihat.
Data sedikit	Lebih tahan.	Mudah menghafal.

Baris ekstrapolasi sering terlewat: model pohon yang dilatih pada rute 2–15 km tidak akan pernah memprediksi apa pun di luar rentang nilai target yang pernah ia lihat.

PANDUAN MEMILIH

Empat pertanyaan sebelum memutuskan

1	**Apakah hasilnya harus bisa dijelaskan kepada orang awam?**	Ya → pohon tunggal. Cukup dijelaskan kepada sesama teknisi → ensemble boleh.
2	**Apakah datanya berbentuk tabel dengan banyak variabel kategorik?**	Ya → pohon dan ensemble hampir selalu unggul tanpa perlu banyak persiapan data.
3	**Apakah hubungan antar-variabel diduga lurus dan sederhana?**	Ya → model linier lebih hemat, lebih stabil, dan lebih mudah dipertanggungjawabkan.
4	**Apakah Anda perlu memprediksi di luar rentang data yang ada?**	Ya → model pohon tidak bisa melakukannya. Gunakan model linier.

Jawaban yang benar hampir selalu: coba keduanya, bandingkan dengan cross-validation, lalu pilih dengan alasan.

DISKUSI KASUS

Empat situasi, empat pilihan

A Sistem penentu prioritas perbaikan halte yang keputusannya harus dapat diaudit dan dijelaskan kepada DPRD.

B Prediksi jumlah penumpang harian dari 40 variabel campuran: cuaca, hari libur, jenis armada, dan wilayah.

C Model memperkirakan biaya perawatan armada baru yang harganya jauh di atas seluruh armada dalam data latih.

D Random Forest mencapai akurasi 0,91; satu pohon tunggal 0,84. Tim memilih pohon tunggal untuk dipakai.

Untuk tiap situasi: keluarga model apa yang Anda pilih, dan apa satu alasan yang paling menentukan? Untuk kasus D, apakah keputusan tim dapat dibenarkan?

Diskusi kelompok 4 orang · 12 menit.

KEGIATAN KELAS

Presentasi Kilat Algoritma · Sesi 1

Tiap kelompok memaparkan satu algoritma yang diundi selama 5–7 menit. Rujukan utama: dokumentasi scikit-learn User Guide, ISL [11], dan catatan kuliah CS 189 [10].

Daftar topik sesi 1

- Support Vector Machines (SVM)
- Generalized Linear Models
- Naive Bayes
- Nearest Neighbors
- Kernel Ridge Regression
- Stochastic Gradient Descent
- Gradient Boosting
- AdaBoost

Struktur yang wajib dipenuhi

1. Prinsip kerja algoritma
2. Asumsi yang mendasarinya
3. Kelebihan dan keterbatasan
4. Kapan tepat digunakan
5. Satu contoh penerapan nyata

Penilaian

Sesi ini masuk komponen Aktivitas Partisipatif pertemuan 10 dan dinilai dengan rubrik partisipasi. Yang dinilai bukan kelancaran berbicara, melainkan ketepatan menjelaskan prinsip kerja dan kejujuran menyebut keterbatasan algoritma.

WASPADAI

Empat salah kaprah yang paling sering

Decision tree selalu mudah dibaca	Hanya bila dangkal. Pohon berkedalaman 15 punya ribuan aturan dan sama tidak terbacanya dengan model lain.
Random Forest tidak bisa overfitting	Ia sangat tahan, tetapi bukan kebal — terutama pada data yang sangat sedikit atau sangat berderau.
Pohon lebih baik karena lebih canggih	Tidak ada keluarga model yang unggul secara mutlak. Pada hubungan yang memang lurus, model linier lebih tepat.
Feature importance menunjukkan sebab-akibat	Ia hanya menunjukkan fitur mana yang banyak dipakai memisahkan data. Itu bukan bukti hubungan sebab-akibat.

RINGKASAN

Yang perlu Anda bawa pulang

Decision tree

Mengajukan pertanyaan berjenjang. Setiap jalur adalah satu aturan.

Kriteria pemisahan

Gini atau entropy. Pilih fitur dengan penurunan terbesar.

Kedalaman

Hyperparameter. Terlalu dalam berarti menghafal derau.

Bagging

Pohon sejajar dan saling bebas. Menurunkan variance.

Boosting

Pohon berurutan yang memperbaiki kesalahan. Menurunkan bias.

Pohon vs linier

Pohon unggul pada data tabel. Linier unggul untuk ekstrapolasi.

TINDAK LANJUT

Tugas Terstruktur 4

PT

Tugas Terstruktur 4 · Bobot 4%

Analisis perbandingan model linier dan model berbasis pohon untuk satu kasus yang ditentukan, disertai justifikasi pemilihan.

BM

Belajar Mandiri · 180 menit

Membaca Géron [1] Bab 6 dan 7 mengenai decision tree dan metode ensemble, serta ISL [11] Bab 8.

Kriteria penilaian tugas

Ketepatan menjelaskan mekanisme kedua keluarga model (30%) · Kesesuaian analisis dengan karakteristik data pada kasus (30%) · Kekuatan justifikasi pemilihan (40%).

Menyebut satu model "lebih baik" tanpa mengaitkannya pada ciri data dan kebutuhan pengguna tidak memperoleh nilai penuh.

Persiapan pertemuan 11: kelompok yang mendapat topik clustering dan reduksi dimensi mulai menyiapkan bahan Presentasi Kilat sesi 2.

PERTEMUAN BERIKUTNYA

Clustering dan Dasar Probabilitas

Sepanjang sepuluh pertemuan, setiap data selalu punya jawaban yang benar.

Pertemuan depan label itu kita cabut — dan model harus menemukan kelompoknya sendiri.